

Классический ML — конспект по билетам

ml_tickets.md, обновляется по ходу подготовки

Раздел 1. Линейная регрессия

Билет 1. Формализация задачи машинного обучения

Опр: Три компоненты: объекты $x \in X$, признаки $f(x) \in \mathbb{R}^m$, целевая переменная $y \in Y$. Матрица объект–признак X размера $[n \times (m + 1)]$, первый столбец — фиктивная единица под w_0 . Типы обучения: supervised (есть y), unsupervised (нет y), semi-supervised (частично есть y). Типы задач: регрессия ($Y = \mathbb{R}$), классификация (Y — конечное неупорядоченное множество), ранжирование (Y — порядок). **Фишка:** SSL работает, только если структура $p(x)$ (кластеры/многообразие) коррелирует с $p(y|x)$ — cluster assumption, manifold assumption.

Билет 2. Линейная регрессия: модель и МНК

Модель: $f(x, w) = w_0 + w_1 f_1(x) + \dots + w_m f_m(x) = w^\top x$. Критерий (МНК): $w = \arg \min_w \|y - Xw\|_2^2$. **Фишка:** Линейность по весам w , не по x — подстановка $\varphi(x)$ (полиномы, RBF) даёт нелинейные модели, оставаясь линейными по w . Геометрия: МНК = ортогональная проекция y на линейную оболочку столбцов X .

Билет 3. Нормальное уравнение и матрица Грама

Вывод: $\nabla \text{RSS}(w) = -2X^\top y + 2X^\top Xw = 0 \Rightarrow X^\top Xw = X^\top y$.

$$w = (X^\top X)^{-1} X^\top y$$

$X^\top X$ — матрица Грама: симметрична, положительно полуопределена ($v^\top X^\top Xv = \|Xv\|^2 \geq 0$). **Вывод:** $X^\top(y - Xw) = 0$ — невязка ортогональна каждому столбцу $X \Leftrightarrow$ ортогональна всей линейной оболочке $\Leftrightarrow$ проекция. Необратима при мультиколлинеарности или $n < m$. **Фишка:** Обратимость ломается либо мультиколлинеарностью ($\text{rank} < m+1$), либо $n < m$ — разные причины; увеличение n не лечит первую.

Билет 4. Мультиколлинеарность и вырожденность матрицы Грама

Точная зависимость столбцов $\Rightarrow$ проекция $\hat{y}$ не меняется, но w неединственно (бесконечно много решений с одинаковой $\hat{y}$). Приближённая мультиколлинеарность $\Rightarrow X^\top X$ не вырождена формально, но плохо обусловлена — взрыв весов при малом шуме. Способы борьбы: отбор признаков, регуляризация (τE сдвигает собственные числа на $+\tau$), PCA, псевдообратная через SVD. **Фишка:** $\text{VIF}_j = 1/(1 - R_j^2)$ (регрессия x_j на остальные признаки) — $\text{VIF} > 5$ –10 сигнал мультиколлинеарности.

Билет 5. Градиентный спуск для линейной регрессии

$$w_{k+1} = w_k - h \nabla L(w_k), \quad \nabla L = 2X^\top(Xw - y)$$

h большой $\Rightarrow$ расходимость; h малый $\Rightarrow$ медленная сходимость. Критерии останова: $\|\nabla L\| < \varepsilon$, $\|w_{k+1} - w_k\| < \varepsilon$, лимит итераций. **Фишка:** Безопасный шаг $h \leq 1/L$, $L = \lambda_{\max}(X^\top X)$ (билет 17–18).

Билет 6. SVD: определение и свойства

$$X = USV^\top, \quad U^\top U = I, \quad V^\top V = I, \quad S = \text{diag}(\sigma_1 \geq \dots \geq \sigma_r \geq 0)$$

Геометрия: поворот ($V^\top$) $\rightarrow$ растяжение (S) $\rightarrow$ поворот (U). **Вывод:** $X^\top X = VS^\top SV^\top$ — σ_j^2 = собственные числа $X^\top X$, столбцы V = её собственные векторы. $\text{cond}(X) = \sigma_{\max}/\sigma_{\min}$. **Фишка:** SVD существует для ЛЮБОЙ матрицы; собственное разложение — только для квадратных диагонализующих.

Билет 7. Решение МНК через SVD и псевдообратная

$$w = \sum_{j=1}^r \frac{1}{\sigma_j} V_j (U_j^\top y)$$

Псевдообратная Мура–Пенроуза $X^+ = VS^+U^\top$. При полном ранге совпадает с $(X^\top X)^{-1}X^\top y$; при вырожденности — даёт решение минимальной нормы (не добавляет вес в направления с $\sigma_j = 0$). **Вывод:** $\text{cond}(X^\top X) = \text{cond}(X)^2$, т.к. σ_j^2 — собств. числа $X^\top X$ — явное обращение $X^\top X$ численно вдвое хуже, чем SVD напрямую с X . **Фишка:** Малое σ_j в знаменателе $1/\sigma_j$ усиливает шум y непропорционально — усечение малых σ_j = регуляризация без явного τ .

Билет 8. Метрики качества регрессии

- $\text{MSE} = \frac{1}{n} \sum (y_i - \hat{y}_i)^2$ — не робастна, единицы y^2 .
- $\text{RMSE} = \sqrt{\text{MSE}}$ — единицы y , всё ещё чувствительна к выбросам.
- $\text{MAE} = \frac{1}{n} \sum |y_i - \hat{y}_i|$ — робастна, не диф. в 0.
- MAPE — в %, ломается при $y_i \approx 0$, НЕ робастна (не путать с масштабной независимостью).
- $R^2 = 1 - \text{SS}_{\text{res}}/\text{SS}_{\text{tot}}$ — доля объяснённой дисперсии, может быть < 0 .

$$R_{\text{adj}}^2 = 1 - (1 - R^2) \frac{n-1}{n-p-1}$$

Фишка: Обычный R^2 никогда не убывает при добавлении признаков (даже шума); $\text{adj. } R^2 \rightarrow -\infty$ при $p \rightarrow n$.

Билет 9. Предобработка признаков: масштабирование и кодирование

Стандартизация $x' = (x - \mu)/\sigma$; min-max $x' = (x - \min)/(\max - \min)$. **Фишка:** Масштабирование делает эллипс $X^\top X$ ближе к окружности $\Rightarrow$ быстрее сходится GD (билет 5/11/18). One-hot: dummy trap — сумма K столбцов = вектор единиц = $f_0 \Rightarrow$ мультиколлинеарность, убрать 1 столбец. Target encoding: утечка без out-of-fold + сглаживания (см. билет 45). Деревьям масштабирование не нужно (пороговые сплиты инвариантны к монотонным преобразованиям).

Билет 10. Вероятностный взгляд на линейную регрессию

$y = w^\top x + \varepsilon$, $\varepsilon \sim N(0, \sigma^2)$. **Вывод:** $\arg \max_w \log L(w) = \arg \min_w \sum (y_i - w^\top x_i)^2$ — МНК = MLE при гауссовом шуме. Байесовски (MAP): Ridge = гауссово априорное $N(0, \sigma_0^2 I)$ на w ; Lasso = лапласово априорное (острый пик в 0 $\rightarrow$ зануление); MAE = лапласовский шум. Предположения: независимость наблюдений, гауссов шум, гомоскедастичность ($\sigma^2 = \text{const}$).

Раздел 2. Регуляризация и теория оптимизации

Билет 11. Число обусловленности и устойчивость решения

$$\text{cond}(A) = \|A\| \cdot \|A^{-1}\| = \sigma_{\max}/\sigma_{\min}, \quad \frac{\|\Delta x\|}{\|x\|} \leq \text{cond}(A) \frac{\|\Delta b\|}{\|b\|}$$

Геометрия: «почти параллельные прямые» — малый угол между строками $A \Rightarrow$ почти линейная зависимость строк $\Rightarrow \sigma_{\min} \rightarrow 0$ (последнее независимое направление вырождается, не главное). **Фишка:** Высокий $\text{cond} \Leftrightarrow$ мультиколлинеарность $\Leftrightarrow$ взрыв весов — одно явление, три описания.

Билет 12. Переобучение и недообучение

Overfitting: train мал, test велик (высокая variance). Underfitting: оба велики (высокий bias). Train/Validation/Test: гиперпараметры — только по validation, test — один раз в конце. **Фишка:** Early stopping = implicit регуляризация: норма весов растёт по ходу итераций GD, обрыв обучения не даёт $\|w\|$ дорасти до overfit-уровня (примерно эквивалентно Ridge с $\tau \propto 1/\text{итераций}$).

Билет 13. Ridge-регрессия (L2)

$$L = \frac{1}{n} \|Xw - y\|^2 + \tau \|w\|_2^2, \quad w = (X^\top X + \tau E)^{-1} X^\top y$$

w_0 обычно не регуляризуют (bias — не про сложность модели). Никогда не зануляет веса точно (алгебраически). **Фишка:** τ = отношение дисперсии шума к дисперсии априорного σ^2/σ_0^2 (байесовский вывод).

Билет 14. Lasso-регрессия (L1)

$$L = \frac{1}{n} \|Xw - y\|^2 + \lambda \|w\|_1$$

Нет аналитики ($\|w\|$ не диф. в 0, нужен субградиент). Координатный спуск, soft-thresholding:

$$w_j^* = \text{sign}(\rho_j) \cdot \max(|\rho_j| - \lambda, 0)$$

Фишка: Вычитание-с-обрезкой (soft-threshold) даёт точный ноль; Ridge — умножение на коэфф. < 1 , ноль недостижим.

Билет 15. Геометрия регуляризации: L1 vs L2

Условная форма: $\min \text{RSS}$ при $R(w) \leq \beta$. L1 — ромб (углы на осях), L2 — круг (гладкий). Эллипсы RSS касаются ромба часто в углу (зануление), круга — нигде на оси (просто сжатие). **Фишка:** При коллинеарных, но обоих полезных признаках L2 честно делит вес (нет привилегированных направлений), L1 нестабилен — шум решает, какой признак занулить (грань ромба).

Билет 16. Elastic Net и функция потерь Хубера

Elastic Net: $\lambda_1 \|w\|_1 + \lambda_2 \|w\|_2^2$. L2-часть «склеивает» коррелирующую группу (grouping effect: $|w_i - w_j| \leq \text{const}/\lambda_2 \cdot \sqrt{2(1 - \rho_{ij})}$), L1 зануляет группу целиком.

$$L_\delta(r) = \begin{cases} \frac{1}{2}r^2, & |r| \leq \delta \\ \delta(|r| - \delta/2), & |r| > \delta \end{cases}$$

Huber непрерывна и диф. на стыке. $\delta \rightarrow 0$: MAE; $\delta \rightarrow \infty$: MSE. Чувствительность к выбросам: MSE $\gg$ Huber $>$ MAE.

Билет 17. Выпуклость, L-гладкость, сильная выпуклость

Выпуклость: $f(\lambda x + (1-\lambda)y) \leq \lambda f(x) + (1-\lambda)f(y)$ — любой лок. мин. = глобальный. L-гладкость: $\|\nabla f(x) - \nabla f(y)\| \leq L\|x - y\|$ — НЕ гарантирует выпуклость (нейросети L-гладкие, но невыпуклые). μ -сильная выпуклость: $f(x) - \frac{\mu}{2}\|x\|^2$ выпукла — единственный минимум. МНК: $L = \lambda_{\max}(X^T X)$, может не быть сильно выпуклой ($\mu = \lambda_{\min} \approx 0$). Ridge: $\mu = \tau$ гарантированно.

Билет 18. Скорость сходимости градиентного спуска

$$\|w^{(k+1)} - w^*\|^2 \leq q^k \|w^{(0)} - w^*\|^2, \quad K \approx O\left(\frac{L}{\mu} \ln \frac{1}{\varepsilon}\right)$$

$L/\mu = \text{cond}(X^T X)$ для МНК. $\ln(1/\varepsilon)$ растёт медленно — геометрическая сходимость. **Фишка:** Рост τ в Ridge: $L/\mu = (\lambda_{\max} + \tau)/\tau$ УБЫВАЕТ (сходимость быстрее), но решение смещается (bias) — скорость оптимизации и качество решения — разные оси.

Билет 19. SGD и mini-batch

$\nabla L_i(w)$ несмещена ($\mathbb{E} = \nabla L$), но высокой дисперсии. Условия Роббинса–Монро: $\sum \alpha_k = \infty$ (дотянуться до минимума) и $\sum \alpha_k^2 < \infty$ (успокоиться, не дрожать вечно). **Фишка:** Два разных эффекта шума: (1) выпрыгивание из плохой ямы — навигация по невыпуклому ландшафту; (2) implicit regularization — шум не даёт дойти до острого/переобученного дна ВНУТРИ хорошей ямы. Оба работают одновременно, не последовательно.

Билет 20. Momentum, Adam

$$v = \gamma v + \eta g, \quad w = w - v \quad (\text{Momentum})$$

Гасит зигзаг вдоль крутого направления (знакопеременный g), ускоряет вдоль пологого (стабильный g).

$$m = \beta_1 m + (1 - \beta_1)g, \quad v = \beta_2 v + (1 - \beta_2)g^2, \quad \hat{m} = \frac{m}{1 - \beta_1^t}, \quad \hat{v} = \frac{v}{1 - \beta_2^t}, \quad w = w - \eta \frac{\hat{m}}{\sqrt{\hat{v}} + \varepsilon}$$

Вывод: $m_0 = 0 \Rightarrow m_1 = (1 - \beta_1)g_1$ — заниженная оценка в $t=1$; коррекция $\hat{m}_1 = g_1$ точно восстанавливает. AdamW: weight decay отдельно от адаптивной нормировки (иначе штраф делится на $\sqrt{\hat{v}}$ непредсказуемо). **Фишка:** SGD+Momentum часто лучше ФИНАЛЬНОЕ обобщение (CV), Adam/AdamW — дефолт для NLP/трансформеров, быстрее сходится.

Билет 21. Bias-variance разложение

$$\text{EPE}(x) = \underbrace{(f(x) - \bar{f}(x))^2}_{\text{Bias}^2} + \underbrace{\mathbb{E}[(\bar{f}(x) - \hat{f}(x))^2]}_{\text{Variance}} + \underbrace{\sigma^2}_{\text{Noise}}$$

Bias — вопрос К МОДЕЛИ (форма/сложность), не лечится данными. Variance — вопрос К ВЫБОРКЕ, падает с ростом n (bias — нет). **Фишка:** Регуляризация и упрощение модели двигают ОБА рычага (bias $\uparrow$, var $\downarrow$); бэггинг и рост n снижают variance почти бесплатно, не трогая bias.

Билет 22. Энтропия, кросс-энтропия, KL-дивергенция

$$H(p) = -\sum p_i \log p_i, \quad H(p, q) = -\sum p_i \log q_i, \quad KL(p||q) = \sum p_i \log \frac{p_i}{q_i} = H(p, q) - H(p)$$

$H(p)$ = среднее число бит для оптимального кодирования p . $KL \geq 0$, $= 0 \Leftrightarrow p = q$, НЕ симметрична.

Фишка: Forward $KL(p||q)$: штраф ∞ если $q \rightarrow 0$ там где $p > 0$ (mean-seeking, покрывает все моды); reverse $KL(q||p)$: штраф ∞ если $p \rightarrow 0$ там где $q > 0$, НЕТ штрафа за игнор моды p (mode-seeking).

Билет 23. Кросс-валидация и утечки данных

K-fold, stratified (баланс классов), LOO ($k = n$, дорого, высокая дисперсия), time series split (только прошлое $\rightarrow$ будущее). Nested CV: внешний цикл — честная оценка, внутренний — подбор гиперпараметров (иначе оптимистичное смещение). **Фишка:** Препроцессинг (стандартизация/target encoding) — fit ТОЛЬКО на train КАЖДОГО фолда отдельно; статистика по всей выборке до разбиения утекает через μ, σ , коррелирующие со значениями validation той же группы.

Раздел 3. Оптимизация второго порядка

Билет 24. Метод Ньютона

$$x_{k+1} = x_k - [\nabla^2 L(x_k)]^{-1} \nabla L(x_k)$$

Квадратичная аппроксимация по Тейлору. Для квадратичной функции — точный минимум за 1 шаг.

Билет 25. Проблемы Ньютона, Левенберг–Марквардт

Минусы: гессиан дорог ($O(m^3)$ на обращение), может быть необратим, вдали от минимума расходится.

$$(J^\top J + \lambda I)p = -J^\top f$$

λI как Ridge: большой $\lambda \rightarrow$ GD (надёжно), малый $\lambda \rightarrow$ Гаусс–Ньютон (быстро).

Билет 26. Демпфированный Ньютон и линейный поиск

$x_{k+1} = x_k + \gamma_k H^{-1} \nabla f$. Line search: $\gamma_k^* = \arg \min_{\gamma} f(x_k + \gamma p_k)$, неточный поиск — условия Армихо/Вульфа.

Билет 27. Квазиньютоновские методы: секущее уравнение

Приближаем $B_k \approx [\nabla^2 f]^{-1}$ по истории градиентов. $s_k = x_{k+1} - x_k$, $y_k = \nabla f(x_{k+1}) - \nabla f(x_k)$: секущее уравнение $s_k = B_{k+1} y_k$ (недоопределено).

Билет 28. SR-1

Ранг-1 добавка: $B_{k+1} = B_k + \frac{(s_k - B_k y_k)(s_k - B_k y_k)^\top}{(s_k - B_k y_k)^\top y_k}$. Минус: может терять положительную определённость.

Билет 29. BFGS и L-BFGS

Ранг-2 добавка, гарантия: если $B_0 \succ 0$ и $y_k^\top s_k > 0$ (line search) — все $B_k \succ 0$. L-BFGS: хранит только последние ~ 10 – 20 пар (s_k, y_k) . **Фишка:** Иерархия GD $\rightarrow$ BFGS $\rightarrow$ Ньютон = сколько информации о кривизне (0/1/2-й порядок) используется; BFGS плохо совместим с mini-batch (шумная история градиентов ломает оценку кривизны) — не используется в deep learning.

Раздел 4. Снижение размерности

Билет 30. Теорема Эккарта–Янга

$$\min_{B: \text{rank}(B)=k} \|X - B\| \Rightarrow B = \sum_{j=1}^k u_j \sigma_j v_j^\top, \quad \|X - B\| = \sigma_{k+1}$$

Фишка: Оптимальность ГЛОБАЛЬНАЯ (сумма по всем объектам), не поточечная — нетипичный объект (вариация в отброшенных направлениях) может реконструироваться плохо, даже если B оптимальна в среднем.

Билет 31. PCA через максимизацию дисперсии

$$\max_{\text{Rot}} \|X \cdot \text{Rot}\|^2 \text{ при } \|\text{Rot}\| = 1 \Rightarrow (X^\top X) \text{Rot} = \lambda \text{Rot}$$

Направления макс. дисперсии = собственные векторы $X^\top X = \text{столбцы } V$ (SVD), $\lambda = \sigma^2$. Эквивалентность: $\max$ дисперсии вдоль $\text{Rot} \Leftrightarrow \min$ ошибки реконструкции $\perp \text{Rot}$ (сумма $= \sum \|x_i\|^2 = \text{const}$, теорема Пифагора почленно). **Фишка:** PCA (unsupervised, max дисперсия) vs LDA (supervised, max разделимость классов) — направление max дисперсии данных может быть ПЕРПЕНДИКУЛЯРНО направлению разделения классов (два вытянутых сдвинутых облака вдоль одной оси) — PCA как препроцессинг может уничтожить разделимость.