

Классический ML

конспект по билетам для собеса

14 разделов, 99 билетов
источник: ml_tickets.md

обновляется по ходу подготовки;
каждый билет: определения, выводы, численные примеры, фишки на собесах

Раздел 1. Линейная регрессия

Билет 1. Формализация задачи машинного обучения

Любая задача обучения с учителем формализуется через тройку компонент.

Определение: Три компоненты задачи обучения

- **Объекты** $x \in X$ — сущности, про которые предсказываем (клиент, картинка, дом). Сами по себе абстрактны; модель работает не с объектом, а с его числовым описанием.
- **Признаки** (features) $f_j: X \rightarrow \mathbb{R}$ — функции, сопоставляющие объекту измеримую характеристику. Вектор признаков $f(x) = (f_1(x), \dots, f_m(x)) \in \mathbb{R}^m$.
- **Целевая переменная** $y \in Y$ — то, что предсказываем. Существует истинная неизвестная зависимость $y: X \rightarrow Y$, которую восстанавливаем по данным.

Типы признаков

Бинарный ($\{0, 1\}$), числовой ($\mathbb{R}$), категориальный (номинальный, неупорядоченное конечное множество), порядковый (ординальный, упорядоченное: школа < бакалавр < магистр).

Матрица «объект–признак»

Выборка из n объектов даёт матрицу X размера $[n \times (m + 1)]$:

$$X = \begin{pmatrix} 1 & x_{11} & \cdots & x_{1m} \\ 1 & x_{21} & \cdots & x_{2m} \\ \vdots & & & \vdots \\ 1 & x_{n1} & \cdots & x_{nm} \end{pmatrix}, \quad y = (y_1, \dots, y_n)^\top.$$

Строка i — объект x_i ; столбец j — значения признака f_j по всем объектам. **Первый столбец из единиц** $f_0 \equiv 1$ — фиктивный признак под свободный член w_0 (bias). Отсюда размер $(m+1)$, а не m : это уловка, чтобы модель $f = w_0 + w_1x_1 + \dots$ записывалась одним скалярным произведением $w^\top x$ без отдельного слагаемого.

Определение: Типы обучения (по наличию y)

- **С учителем** (supervised): y_i известны для всех обучающих объектов. Учимся по парам (x_i, y_i) .
- **Без учителя** (unsupervised): y нет вообще. Ищем внутреннюю структуру — кластеры, плотность, снижение размерности. Нет «правильного ответа».
- **Частичное** (semi-supervised): y известны у малой части объектов. Разметка дорогая, сырых данных много.

Типы задач с учителем (по виду Y)

Регрессия ($Y = \mathbb{R}$, непрерывное число: цена, спрос) → Раздел 1. **Классификация** (Y — конечное неупорядоченное множество меток: спам/не спам) → Раздел 5. **Ранжирование** (Y — порядок объектов: поисковая выдача) → Билет 91.

Ключевое отличие регрессии от классификации — **тип** Y : непрерывный vs дискретный неупорядоченный. Это определяет функцию потерь, метрики и семейство моделей.

Фишка на собеседе

Semi-supervised работает, только если структура $p(x)$ коррелирует с $p(y | x)$. Два предположения (см. билет 67): **cluster assumption** — объекты в одном плотном кластере имеют один y , граница классов проходит через разреженные области; **manifold assumption** — данные лежат на низкоразмерном многообразии, y гладко меняется вдоль него. Если y не связан со структурой $p(x)$ (например, y — чётность случайного ID), неразмеченные данные не помогут вообще — кластеры есть, но с y не связаны.

Билет 2. Линейная регрессия: модель и метод наименьших квадратов

Определение: Модель линейной регрессии

$$f(x, w) = w_0 + w_1 f_1(x) + \dots + w_m f_m(x) = w^\top x,$$

где $x = (1, f_1(x), \dots, f_m(x))^\top$, $w = (w_0, \dots, w_m)^\top$. Для всей выборки: $\hat{y} = Xw$.

Определение: Критерий МНК (метод наименьших квадратов)

$$w = \arg \min_w \|y - Xw\|_2^2 = \arg \min_w \sum_{i=1}^n (y_i - w^\top x_i)^2.$$

Квадрат ошибки выбран не случайно: (1) даёт гладкую всюду дифференцируемую функцию (в отличие от $|\cdot|$); (2) сильнее штрафует большие отклонения (ошибка в 2 раза больше → вклад в 4 раза больше); (3) даёт аналитическое решение (билет 3) и статистическую интерпретацию как MLE при гауссовом шуме (билет 10).

Линейность по весам, а не по x

Модель «линейна», потому что линейна по параметрам w , а НЕ по признакам x . Замена $x \rightarrow \varphi(x)$ (полиномы $\varphi = (x, x^2, x^3)$, RBF $\varphi = e^{-\|x-c\|^2}$) оставляет модель линейной по w (тот же МНК, та же машинерия), но как функция от исходного x она нелинейна. **Полиномиальная регрессия** — это линейная регрессия над признаками $\{x, x^2, \dots, x^k\}$.

Геометрическая интерпретация

y — вектор в $\mathbb{R}^n$. Столбцы X (каждый — один признак по всем объектам) натягивают линейное подпространство (линейную оболочку) в $\mathbb{R}^n$. Модель Xw для любого w — точка этого подпространства. МНК ищет **ближайшую точку подпространства к y** — ортогональную проекцию y на линейную оболочку столбцов

X . Отсюда условие ортогональности невязки (билет 3).

Билет 3. Нормальное уравнение и матрица Грама

Вывод нормального уравнения

$\text{RSS}(w) = \|y - Xw\|^2 = (y - Xw)^T(y - Xw) = y^T y - 2w^T X^T y + w^T X^T X w$. Это квадратичная функция с единственным минимумом; берём градиент и приравниваем к нулю:

$$\nabla \text{RSS}(w) = -2X^T y + 2X^T X w = 0 \implies \boxed{X^T X w = X^T y} \implies w = (X^T X)^{-1} X^T y.$$

Определение: Матрица Грама

$X^T X$ размера $[(m+1) \times (m+1)]$. Свойства:

- **Симметрична:** $(X^T X)^T = X^T X$.
- **Положительно полуопределена:** $\forall v: v^T (X^T X) v = (Xv)^T (Xv) = \|Xv\|^2 \geq 0$.
Отсюда все собственные числа ≥ 0 (пригодится в SVD, билет 6).

Матрица $(X^T X)^{-1} X^T$ — псевдообратная Мура–Пенроуза (при полном ранге столбцов).

Геометрический смысл нормального уравнения

$X^T(y - X\hat{w}) = 0$ покомпонентно означает: $x^{(j)T}(y - \hat{y}) = 0$ для каждого столбца $x^{(j)}$, т.е. скалярное произведение = 0 — **невязка ортогональна каждому столбцу X** . Раз ортогональна всем векторам базиса плоскости — ортогональна всей линейной оболочке. Это ровно определение ортогональной проекции: кратчайшее расстояние от точки y до плоскости — по перпендикуляру.

Проблема обратимости и сложность

$X^T X$ обратима $\Leftrightarrow$ столбцы X линейно независимы ($\text{rank } X = m+1$). Ломается: (1) при **мультиколлинеарности** ($\text{rank } X < m+1$); (2) при $n < m$ ($\text{rank } X \leq n < m+1$ по размерности). Обращение стоит $O(m^3)$ — дорого при большом числе признаков; отсюда мотивация градиентного спуска (билет 5).

Фишка на собеседе

Обратимость ломается по ДВУМ разным причинам: мультиколлинеарность (зависимость столбцов) и $n < m$ (объектов меньше признаков). Это не одно и то же: при $n \gg m$ с одним признаком-дубликатом матрица всё равно вырождена — увеличение n не лечит, т.к. проблема в ранге по **СТОЛБЦАМ**, а не по строкам.

Билет 4. Мультиколлинеарность и вырожденность матрицы Грама

Определение: Мультиколлинеарность

Линейная зависимость (точная) или сильная корреляция (приближённая) между столбцами-признаками X .

- **Точная** ($x_3 = 2x_1 + x_2$): $X^T X$ строго вырождена, $\det = 0$, обратной нет.
- **Приближённая** (рост в см и в дюймах, $\rho \approx 0.999$): $X^T X$ формально обратима, но плохо обусловлена (cond огромен).

Взрыв весов и его смысл

При точной зависимости проекция $\hat{y} = Xw$ НЕ меняется, но w неединственно: бесконечно много комбинаций дают ту же $\hat{y}$ (можно забрать вес у x_1 и отдать эквивалент x_3). При приближённой — решение единственно, но крайне чувствительно к шуму: малое возмущение y или X даёт огромный скачок w , у коррелирующих признаков появляются большие веса ПРОТИВОПОЛОЖНОГО знака (модель «взаимно компенсирует» два похожих признака). Это переобучение под шум конкретной выборки.

Замечание: $n < m$ — отдельная причина

Это НЕ мультиколлинеарность, а размерность: $\text{rank } X \leq \min(n, m+1)$. Если признаков больше объектов, ранг упирается в n , матрица Грама $(m+1) \times (m+1)$ гарантированно вырождена, даже если признаки не коррелируют (геномные данные: сотни образцов, десятки тысяч генов).

Способы борьбы

Отбор признаков; регуляризация (Ridge: τE на диагональ гарантирует обратимость, сдвигая собственные числа на $+\tau$); PCA (декорреляция); псевдообратная через SVD (отбрасывание малых σ).

Фишка на собесе

VIF (Variance Inflation Factor): регрессируем x_j на остальные признаки, $\text{VIF}_j = 1/(1 - R_j^2)$. $\text{VIF} > 5-10$ — признак сильно объясняется остальными, кандидат на удаление.

Важно: мультиколлинеарность НЕ портит качество предсказаний ($\hat{y}$ та же), она портит интерпретируемость и устойчивость весов.

Билет 5. Градиентный спуск для линейной регрессии

Определение: Градиентный спуск

$$w_{k+1} = w_k - h \nabla L(w_k), \quad \nabla L(w) = 2X^T(Xw - y).$$

h — learning rate. Итерация: считаем $\hat{y} = Xw_k$, невязку $(Xw_k - y)$, проецируем через X^T (вклад каждого признака в ошибку), шаг против градиента.

Learning rate h

h большой $\rightarrow$ перепрыгивание минимума, расходимость. h малый $\rightarrow$ медленная сходимость. Безопасная граница $h \leq 1/L$, где $L = \lambda_{\max}(X^T X)$ — максимальная кривизна чаши потерь (билеты 17–18).

Критерии останова

$\|\nabla L(w_k)\| < \varepsilon$ (почти на дне); $\|w_{k+1} - w_k\| < \varepsilon$ (шаги микроскопические); лимит итераций.

Пример: Пошаговый расчёт GD

Данные: $x = (1, 2, 3)$, $y = (3, 5, 6)$, модель $w_0 + w_1x$, старт $w = (0, 0)$, $h = 0.1$.

Шаг 1: $\hat{y} = (0, 0, 0)$; невязка $r = \hat{y} - y = (-3, -5, -6)$; $X^T r = (-3-5-6, -3-10-18) = (-14, -31)$; $\nabla L = 2(-14, -31) = (-28, -62)$; $w \leftarrow (0, 0) - 0.1(-28, -62) = (2.8, 6.2)$. На сходимости $\nabla L = 2X^T r = 0 \Leftrightarrow X^T r = 0$ — то же условие ортогональности, что нормальное уравнение достигает за один шаг, а GD — постепенно.

	Нормальное уравнение	Градиентный спуск
Точность	точное за один расчёт	приближённое, зависит от # итераций
Сложность	$O(m^3)$ на обращение	$O(nm)$ за итерацию, итераций много
Обратимость $X^T X$	требуется	не требуется
Большие n, m	плохо	хорошо (+ mini-batch, билет 19)

Билет 6. Сингулярное разложение (SVD): определение и свойства**Определение: SVD**

Любую матрицу X $[n \times m]$ можно разложить:

$$X = USV^T, \quad U^T U = I \ (n \times n), \quad V^T V = I \ (m \times m), \quad S = \text{diag}(\sigma_1 \geq \dots \geq \sigma_r \geq 0),$$

U — левые, V — правые сингулярные векторы, σ_j — сингулярные числа, $r = \text{rank } X$.

Замечание

SVD существует для ЛЮБОЙ матрицы (прямоугольной, вырожденной). Собственное разложение — только для квадратных диагонализуемых. В этом огромное практическое преимущество SVD.

Связь с матрицей Грама

$$X^T X = (USV^T)^T (USV^T) = VS^T U^T USV^T = V(S^T S)V^T = V \operatorname{diag}(\sigma_j^2)V^T.$$

Использовали $U^T U = I$. Это форма собственного разложения: σ_j^2 — собственные числа $X^T X$, столбцы V — её собственные векторы. Отсюда $\sigma_j^2 \geq 0$ (полуопределённость). Мостик к PCA (билет 31): там $(X^T X)\operatorname{Rot} = \lambda \operatorname{Rot}$ даёт $\operatorname{Rot} = V$, $\lambda = \sigma^2$.

Геометрия: поворот–растяжение–поворот

Умножение на $X = USV^T$ — три действия: (1) поворот V^T в пространстве признаков; (2) растяжение по осям на $\sigma_1, \dots, \sigma_r$; (3) поворот U в пространстве объектов. Любое линейное отображение = поворот → растяжение → поворот.

Усечённое SVD и обусловленность

$X_k = \sum_{j=1}^k \sigma_j u_j v_j^T$ — оставляем top- k , отбрасываем остальные (наилучшее приближение ранга k , теорема Эккарта–Янга, билет 30). Число обусловленности $\operatorname{cond}(X) = \sigma_{\max}/\sigma_{\min} = \sigma_1/\sigma_r$.

Фишка на собесе

При усечении (оставляем top- k): $\operatorname{cond}(X_k) = \sigma_1/\sigma_k \leq \sigma_1/\sigma_r = \operatorname{cond}(X)$ — обусловленность **УМЕНЬШАЕТСЯ** (устойчивость растёт). Не путай направление: чем **БОЛЬШЕ** cond , тем **ХУЖЕ** устойчивость.

Билет 7. Решение МНК через SVD и псевдообратная матрица**Вывод**

Подставим $X = USV^T$ в $w = (X^T X)^{-1} X^T y$. Знаем $X^T X = V(S^T S)V^T$, значит $(X^T X)^{-1} = V(S^T S)^{-1}V^T$ (т.к. V ортогональна). $X^T = VS^T U^T$. Тогда

$$w = V(S^T S)^{-1}V^T \cdot VS^T U^T y = V(S^T S)^{-1}S^T U^T y = \sum_{j=1}^r \frac{1}{\sigma_j} V_j (U_j^T y).$$

Определение: Псевдообратная Мура–Пенроуза

$X^+ = VS^+U^T$, S^+ — S с ненулевыми σ_j , заменёнными на $1/\sigma_j$. $w = X^+ y$. Всегда определена, даже при вырожденной $X^T X$. При полном ранге совпадает с $(X^T X)^{-1} X^T y$; при вырожденности даёт решение **минимальной нормы** $\|w\|$ среди всех w с одинаковой (минимальной) ошибкой.

Смысл формулы по шагам

$U_j^T y$ — проекция y на j -е направление (сколько y вдоль него). Делим на σ_j — обратное растяжение (компенсируем, что X растягивал в σ_j раз). Умножаем на V_j — переносим в пространство весов.

Пример: Почему малое σ опасно

Пусть $\sigma_1 = 10$, $\sigma_2 = 0.001$, шум в y даёт $U_j^\top y = 0.5$ на обоих направлениях. Вклад в w : $(1/10) \cdot 0.5 = 0.05$ (норм) против $(1/0.001) \cdot 0.5 = 500$ (взрыв!). Одинаковый шум усилен в 10000 раз из-за деления на почти-ноль. Усечение (отбрасывание σ_2) убирает этот взрыв.

Фишка на собеседе

$\text{cond}(X^\top X) = \text{cond}(X)^2$, т.к. собственные числа $X^\top X$ — это σ_j^2 . Значит явное обращение $X^\top X$ численно вдвое хуже, чем работа напрямую с X через SVD. При $\text{cond}(X) = 100$ имеем $\text{cond}(X^\top X) = 10000$. Поэтому `numpy.linalg.lstsq`, `sklearn` решают МНК через SVD/QR, а не через обращение матрицы Грама.

Билет 8. Метрики качества регрессии**Замечание: Функция потерь $\neq$ метрика**

Функция потерь оптимизируется при обучении (MSE в МНК — дифференцируема, даёт аналитику). Метрика измеряет результат постфактум и может быть другой (обучали через MSE, отчитываемся через MAE ради интерпретируемости).

Определение: Метрики

- $\text{MSE} = \frac{1}{n} \sum (y_i - \hat{y}_i)^2$ — квадратичный штраф, не робастна к выбросам, единицы y^2 .
- $\text{RMSE} = \sqrt{\text{MSE}}$ — единицы y (интерпретируема), всё ещё чувствительна к выбросам.
- $\text{MAE} = \frac{1}{n} \sum |y_i - \hat{y}_i|$ — линейный штраф, робастна, не диф. в 0. Всегда $\text{MAE} \leq \text{RMSE}$.
- $\text{MAPE} = \frac{1}{n} \sum \frac{|y_i - \hat{y}_i|}{|y_i|}$ — в %, масштабно-независима, но ломается при $y_i \approx 0$ и НЕ робастна (чувствительна через знаменатель).
- $R^2 = 1 - \text{SS}_{\text{res}}/\text{SS}_{\text{tot}}$, $\text{SS}_{\text{res}} = \sum (y_i - \hat{y}_i)^2$, $\text{SS}_{\text{tot}} = \sum (y_i - \bar{y})^2$ — доля объяснённой дисперсии. $R^2 = 1$ идеал, $R^2 = 0$ — константный прогноз $\bar{y}$, $R^2 < 0$ хуже среднего.

Диагностика по соотношению RMSE/MAE

$\text{RMSE} \gg \text{MAE}$ — есть отдельные большие выбросы (квадрат раздувает RMSE). $\text{RMSE} \approx \text{MAE}$ — ошибки распределены равномерно. Для прода, где критичны редкие катастрофические ошибки, смотрят RMSE.

Определение: Adjusted R^2

$$R_{\text{adj}}^2 = 1 - (1 - R^2) \frac{n - 1}{n - p - 1}, \quad p = \# \text{ признаков.}$$

Фишка на собеседе

Обычный R^2 НИКОГДА не убывает при добавлении признаков (даже случайного шума) — у модели больше степеней свободы, в худшем случае вес нового признака = 0. Adjusted R^2 штрафует за p : при $p \rightarrow n$ знаменатель $(n - p - 1) \rightarrow 0$, дробь $\rightarrow \infty$, $R^2_{\text{adj}} \rightarrow -\infty$ — жёстко сигнализирует о переобучении, даже если обычный $R^2 \approx 1$.

Билет 9. Предобработка признаков: масштабирование и кодирование**Определение: Масштабирование числовых признаков**

Стандартизация (z-score): $x' = (x - \mu)/\sigma$ — центр 0, дисперсия 1. **Min-max**: $x' = (x - \min)/(\max - \min)$ — диапазон $[0, 1]$, чувствительна к выбросам.

Зачем масштабировать

(1) **Ускоряет GD**: разные масштабы признаков $\rightarrow$ разброс собственных чисел $X^T X \rightarrow$ плохая обусловленность $\rightarrow$ вытянутая эллиптическая чаша $\rightarrow$ зигзаг (билет 5/11). Масштабирование делает чашу круглее. (2) **Методы на расстояниях** (kNN, k-means, SVM-RBF): без масштабирования признак с большим диапазоном доминирует в евклидовом расстоянии. (3) **Сопоставимость весов** и справедливость регуляризации (иначе штраф сильнее давит на признаки малого масштаба).

Определение: Кодирование категорий

One-hot: столбец на значение. **Ordinal**: номер по порядку (ложный порядок для неупорядоченных). **Target/mean encoding**: категория $\rightarrow$ среднее y по ней (риск утечки). **Hashing**: хэш в фикс. число столбцов (коллизии). **Embeddings**: обучаемый плотный вектор.

Dummy trap

Если оставить все K one-hot столбцов: их сумма = вектор единиц = f_0 (фиктивный признак) $\Rightarrow$ точная линейная зависимость $\Rightarrow$ мультиколлинеарность, $X^T X$ вырождена. Решение: убрать один столбец ($K-1$ достаточно).

Замечание: Деревья

Деревьям масштабирование НЕ нужно: пороговые сплиты $[f_j \geq d_j]$ инвариантны к монотонным преобразованиям. По той же причине ordinal/target encoding для деревьев ОК даже без «настоящего» порядка.

Фишка на собеседе

Target encoding без out-of-fold — утечка: для объекта его собственный y_i участвует в его же признаке. Правильно: считать среднее по остальным фолдам + сглаживание (взвешивание с глобальным средним для редких категорий). Формально сглаживание = байесовская априорная оценка (см. билет 45, сглаживание Лапласа).

са).

Билет 10. Вероятностный взгляд на линейную регрессию

Определение: Вероятностная модель

$y = w^T x + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, \sigma^2)$, т.е. $p(y | x, w) = \mathcal{N}(y | w^T x, \sigma^2)$: среднее линейно по x , дисперсия σ^2 постоянна (гомоскедастичность).

МНК = максимум правдоподобия при гауссовом шуме

$L(w) = \prod_i \frac{1}{\sqrt{2\pi\sigma^2}} e^{-(y_i - w^T x_i)^2 / 2\sigma^2}$. Логарифм:

$$\log L(w) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_i (y_i - w^T x_i)^2.$$

Первое слагаемое не зависит от w , значит $\arg \max_w \log L = \arg \min_w \sum (y_i - w^T x_i)^2$ — это МНК.

Регуляризация как байесовская MAP-оценка

$p(w | y, X) \propto p(y | X, w) p(w)$. Максимизация log-апостериора = минимизация $\frac{1}{2\sigma^2} \|Xw - y\|^2 + [-\log p(w)]$:

- **Ridge** = гауссово априорное $p(w) = \mathcal{N}(0, \sigma_0^2 I)$: $-\log p(w) \propto \tau \|w\|^2$, $\tau = \sigma^2 / \sigma_0^2$.
- **Lasso** = лапласово априорное $p(w) \propto e^{-\lambda \sum |w_j|}$: острый пик в 0 $\rightarrow$ зануление.
- **MAE** = лапласовский шум (тяжёлые хвосты $\rightarrow$ робастность к выбросам).

τ = отношение дисперсии шума к дисперсии априорного: чем увереннее, что веса малы (малое σ_0^2), тем сильнее регуляризация.

Предположения модели

Независимость наблюдений; гауссов шум; гомоскедастичность (σ^2 не зависит от x).

Фишка на собеседе

Гетероскедастичность (дисперсия шума растёт с x): МНК-оценка w **ОСТАЁТСЯ** несмещённой (несмещённость требует лишь $\mathbb{E}[\varepsilon | X] = 0$, не постоянства σ^2). Ломается **ЭФФЕКТИВНОСТЬ**: по теореме Гаусса–Маркова МНК = BLUE только при гомоскедастичности; иначе есть оценки с меньшей дисперсией (WLS). Главное — стандартные ошибки $\text{Var}(w) = \sigma^2 (X^T X)^{-1}$ становятся неверными $\rightarrow$ доверительные интервалы и p -value некорректны. Лечение: робастные ошибки (White/Huber).

Раздел 2. Регуляризация и теория оптимизации

Билет 11. Число обусловленности и устойчивость решения

Определение: Число обусловленности

$$\text{cond}(A) = \|A\| \cdot \|A^{-1}\| = \frac{\sigma_{\max}}{\sigma_{\min}}, \quad \frac{\|\Delta x\|}{\|x\|} \leq \text{cond}(A) \frac{\|\Delta b\|}{\|b\|}.$$

cond — коэффициент усиления относительной ошибки входа в решении $Ax = b$ (у нас $A = X^T X$).

Геометрия «почти параллельных прямых»

Решение системы = пересечение прямых. Под прямым углом — точка чёткая. Почти параллельны — малейшее дрожание уносит пересечение далеко. Малый угол между строками $A \Rightarrow$ почти линейная зависимость строк $\Rightarrow$ вырождается ПОСЛЕДНЕЕ независимое направление $\Rightarrow \sigma_{\min} \rightarrow 0$ (не $\sigma_{\max}$: она определяется длиной строк). Для матрицы из единичных строк под углом θ : $\text{cond} \approx 2/\theta$ при малых θ .

Фишка на собесе

Одна цепочка эквивалентностей: мультиколлинеарность $\Rightarrow \sigma_{\min} \rightarrow 0 \Rightarrow \text{cond}$ огромен $\Rightarrow$ коэффициент $1/\sigma_{\min}$ в решении взрывается $\Rightarrow$ веса неустойчивы к шуму. Высокий $\text{cond} \Leftrightarrow$ мультиколлинеарность $\Leftrightarrow$ взрыв весов — одно явление, три описания. Лечится Ridge (τE сдвигает $\lambda_{\min} \rightarrow \lambda_{\min} + \tau$) и масштабированием.

Билет 12. Переобучение и недообучение

Определение: Определения через симптомы

Переобучение (overfitting): подстройка под шум train; ошибка на train мала (иногда ≈ 0), на test велика; симптом — огромные неустойчивые веса (high variance).

Недообучение (underfitting): модель слишком проста; ошибка велика и на train, и на test (high bias).

Train / Validation / Test

Train — считаются веса. Validation — подбираются гиперпараметры (τ , K , глубина). Test — используется ОДИН раз в конце для честной оценки. Подбор гиперпараметров по test превращает его во вторую validation $\rightarrow$ оптимистичное смещение (утечка, билет 23).

Фишка на собесе

Early stopping = implicit регуляризация без штрафного члена в loss. Механизм: норма весов $\|w\|$ монотонно РАСТЁТ по мере итераций GD (старт с $w \approx 0$). Обрыв обучения не даёт $\|w\|$ дорасти до величины несжатой МНК-оценки — функционально имитирует ограничение на $\|w\|$. Для линейной регрессии: раннее остановленный GD $\approx$ Ridge с $\tau \propto 1/(\# \text{ итераций})$. Для бустинга: меньше деревьев = меньше эффективная сложность.

Билет 13. Ridge-регрессия (L2-регуляризация)**Определение: Ridge**

$$L = \frac{1}{n} \|Xw - y\|^2 + \tau \|w\|_2^2, \quad w = (X^\top X + \tau E)^{-1} X^\top y.$$

Механизм добавки τE

Собственные числа λ_i матрицы $X^\top X$ (все ≥ 0) переходят в $\lambda_i + \tau > 0$ у $(X^\top X + \tau E)$. Матрица становится строго положительно определённой $\Rightarrow$ обратима всегда. $\text{cond} = (\lambda_{\max} + \tau)/(\lambda_{\min} + \tau)$ падает — лечится и обусловленность. **Ridge НЕ убивает корреляцию признаков** (данные не трогает), только сдвигает собственные числа — не путать с декорреляцией через PCA.

Свойства

w_0 (bias) обычно не регуляризуют (это сдвиг, не сложность). Ridge сжимает веса к нулю, но НЕ зануляет точно (обращение матрицы не даёт точный ноль при $X^\top y \neq 0$). Влияние τ : рост $\rightarrow \text{bias} \uparrow, \text{variance} \downarrow$.

Фишка на собесе

Чтобы по весам Ridge понять важность признаков — сначала СТАНДАРТИЗИРОВАТЬ X (иначе малый вес может значить «признак большого масштаба», а не «неважный»). Ridge даёт непрерывное ранжирование, но не автоматический отбор — для отбора нужен Lasso.

Билет 14. Lasso-регрессия (L1-регуляризация)**Определение: Lasso**

$$L = \frac{1}{n} \|Xw - y\|^2 + \lambda \|w\|_1, \quad \|w\|_1 = \sum_j |w_j|.$$

Главное свойство: ЗАНУЛЯЕТ веса неинформативных признаков $\rightarrow$ автоматический отбор признаков (sparsity), интерпретируемость.

Нет аналитики

$|w_j|$ не дифференцируема в 0 (излом: слева -1 , справа $+1$). Нужен субградиент (в

точке излома — весь отрезок $[-1, 1]$). Решают координатным спуском.

Soft-thresholding — механизм зануления

$$w_j^* = S_\lambda(\rho_j) = \text{sign}(\rho_j) \cdot \max(|\rho_j| - \lambda, 0),$$

ρ_j — «сырой» МНК-вклад признака j . Из $|\rho_j|$ вычитаем λ ; если результат отрицателен — обрезаем в ноль. Сравни с Ridge: там УМНОЖЕНИЕ на коэффициент < 1 (ноль недостижим), здесь ВЫЧИТАНИЕ-с-обрезкой $\rightarrow$ точный ноль при $|\rho_j| \leq \lambda$.

Пример: Soft-threshold

$\rho_j = 0.3$, $\lambda = 0.5$: $\max(0.3 - 0.5, 0) = \max(-0.2, 0) = 0$. Сигнал слабее порога — зануляется.

Фишка на собесе

Нестабильность Lasso при коллинеарной группе — НЕ из-за порядка обхода координат (координатный спуск сходится к глобальному оптимуму независимо от порядка). Причина: при почти идентичных признаках задача имеет ВЫРОЖДЕННОЕ решение — «весь вес на А» и «весь вес на В» дают почти одинаковый loss. Геометрически (билет 15): эллипсы RSS касаются ромба вдоль целого ребра, и в какой угол упрётся решение — решает шум. У Ridge решение гладко и единственно $\Rightarrow$ вес делится между коррелирующими признаками стабильно.

Билет 15. Геометрия регуляризации: L1 vs L2

Эквивалентная условная задача

$\min[\text{RSS}(w) + \lambda R(w)]$ (штрафная форма) $\Leftrightarrow \min \text{RSS}(w)$ при $R(w) \leq \beta$ (условная форма). Больше λ — меньше β .

Геометрическая картина

Линии уровня RSS — эллипсы вокруг w_{OLS} . Область ограничения: L2 — круг ($\|w\|_2 \leq \beta$), L1 — ромб ($\|w\|_1 \leq \beta$, вершины на осях). Решение — точка касания наименьшего эллипса с границей области.

Почему L1 разрезает, а L2 нет

L1 (ромб): острые углы НА ОСЯХ (точки $(\beta, 0)$, $(0, \beta)$, где один вес = 0). Углы «ловят» эллипс широким диапазоном направлений подхода $\Rightarrow$ решение часто в углу $\Rightarrow$ зануление. **L2 (круг)**: гладкая граница, касание в точке, которая с вероятностью 1 не на оси $\Rightarrow$ оба веса ненулевые, просто сжаты. То же явление, что soft-threshold vs умножение (билет 14) — геометрически.

Фишка на собесе

Ridge — когда все признаки полезны и есть коллинеарность; Lasso — когда нужен отбор из многих мусорных. Геометрически при коллинеарных ОБОИХ полезных признаках: круг не имеет привилегированных направлений $\rightarrow$ делит вес пропор-

ционально, устойчиво к шуму; ромб навязывает дискретный выбор «один признак = 0, другой = всё», причём выбор решает шум. L1 насильно вводит асимметрию туда, где данные симметричны.

Билет 16. Elastic Net и функция потерь Хубера

Определение: Elastic Net

$$L = \frac{1}{n} \|Xw - y\|^2 + \lambda_1 \|w\|_1 + \lambda_2 \|w\|_2^2.$$

L1 даёт зануление, L2 — устойчивость при коллинеарности. **Grouping effect:** $|w_i - w_j| \leq \frac{\text{const}}{\lambda_2} \sqrt{2(1 - \rho_{ij})}$ — сильно коррелирующие признаки ($\rho_{ij} \rightarrow 1$) получают близкие веса, L2 «склеивает» группу, L1 зануляет её целиком. «Lasso берёт один случайный из группы, Elastic Net — всю группу».

Определение: Функция потерь Хубера

$$L_\delta(r) = \begin{cases} \frac{1}{2}r^2, & |r| \leq \delta \\ \delta(|r| - \delta/2), & |r| > \delta \end{cases}, \quad r = y - \hat{y}.$$

Малые остатки — как MSE (гладко, хороший градиент), большие — как MAE (выброс не доминирует). Непрерывна и дифференцируема в стыке $|r| = \delta$ (в отличие от чистой MAE).

Предельные случаи Хубера

$\delta \rightarrow 0$: почти вся область — линейная ветка $\Rightarrow$ пропорциональна MAE. $\delta \rightarrow \infty$: условие $|r| \leq \delta$ для всех $r \Rightarrow$ только $\frac{1}{2}r^2 = \text{MSE}$. Чувствительность к выбросам: $\text{MSE} \gg \text{Huber} > \text{MAE}$.

Фишка на собеседе

Почему не всегда Elastic Net / Huber: они добавляют гиперпараметры ($\lambda_1, \lambda_2 / \delta$) — дороже подбор. MSE остаётся дефолтом: MLE при гауссовом шуме (ЦПТ), гладкость, простота. Elastic Net нужен при известной структуре коррелирующих групп; Huber — при известных тяжёлых выбросах.

Билет 17. Выпуклость, L-гладкость и сильная выпуклость

Определение: Три свойства

- **Выпуклость:** $f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$. Следствие: любой локальный минимум глобален.
- **L-гладкость:** $\|\nabla f(x) - \nabla f(y)\| \leq L \|x - y\|$ (липшицев градиент). Для дважды диф.: $L = \lambda_{\max}(\nabla^2 f)$. Даёт безопасный шаг $h \leq 1/L$.
- **μ -сильная выпуклость:** $f(x) - \frac{\mu}{2} \|x\|^2$ выпукла. Функция крутая везде, нет плато, минимум единственный.

Замечание: L-гладкость $\neq$ выпуклость

L-гладкость — ТОЛЬКО про скорость изменения градиента, НЕ гарантирует глобальность минимума. Функция потерь нейросети L-гладкая, но невыпуклая (много локальных минимумов). Гарантию «локальный = глобальный» дают только выпуклость и сильная выпуклость.

МНК как пример

МНК: выпукл, L-гладок с $L = \lambda_{\max}(X^T X)$, но не обязательно сильно выпукл ($\mu = \lambda_{\min} \approx 0$ при плохой обусловленности). МНК+L2 (Ridge): μ -сильно выпукл с $\mu = \tau$ (гессиан $2(X^T X + \tau E)$, мин. собств. число $\geq 2\tau$).

Фишка на собеседе

Зачем регуляризация, если она «уводит от истинного w »? МНК-оценка несмещена лишь В СРЕДНЕМ по многим выборкам, но у одной реальной выборки при мультиколлинеарности разброс (variance) огромен. Ridge жертвует малым bias ради резкого падения variance: аналогия — стрелок В (систематически чуть смещён, но кучно) на одном выстреле ближе к цели, чем стрелок А (в среднем точен, но разброс огромный). Ошибка = $\text{Bias}^2 + \text{Variance}$; окупается, когда variance доминирует.

Билет 18. Скорость сходимости градиентного спуска**Теорема: Геометрическая сходимость**

Для L-гладких μ -сильно выпуклых функций GD (шаг $h \leq 1/L$) сходится геометрически:

$$\|w^{(k+1)} - w^*\|^2 \leq q^k \|w^{(0)} - w^*\|^2, \quad q < 1, \quad K \approx O\left(\frac{L}{\mu} \ln \frac{1}{\varepsilon}\right).$$

Разбор формулы

$\ln(1/\varepsilon)$ — логарифмическая зависимость от точности: улучшить в 10 раз $\rightarrow$ не в 10 раз больше итераций, а константная добавка. L/μ — число обусловленности задачи; для МНК $L/\mu = \lambda_{\max}/\lambda_{\min} = \text{cond}(X^T X)$. Большое L/μ — вытянутая чаша (билет 5) — зигзаг, много итераций. $L/\mu \approx 1$ — сфера, быстро.

Почему не за один шаг

GD использует только градиент (1-й порядок) — «знает лишь наклон под ногами». Метод Ньютона (2-й порядок, гессиан) для квадратичной функции доходит за один шаг.

Фишка на собеседе

Рост τ в Ridge: $L/\mu = (\lambda_{\max} + \tau)/\tau = \lambda_{\max}/\tau + 1$ строго УБЫВАЕТ ($d/d\tau < 0$). При $\tau \rightarrow \infty$: $L/\mu \rightarrow 1$ (идеальная обусловленность, быстрая сходимость). Но GD

сходится к ДРУГОЙ, более смещённой точке (не w_{OLS} , а сжатое Ridge-решение). Скорость оптимизации и качество решения — разные оси: регуляризация упрощает саму оптимизацию И меняет то, что ищем.

Билет 19. Стохастический градиентный спуск (SGD) и mini-batch

Определение: SGD

Градиент по одному объекту / мини-батчу вместо всей выборки: $\nabla L_i(w) = 2x_i(x_i^T w - y_i)$. Итерация дешёвая, но оценка градиента шумная.

Несмещённость и дисперсия

При случайном равновероятном выборе i : $\mathbb{E}[\nabla L_i(w)] = \nabla L(w)$ (несмещена), но большая дисперсия — конкретный ∇L_i может сильно отличаться от истинного направления. Траектория SGD дрожит вокруг направления полного GD.

Теорема: Условия Роббинса–Монро

Для сходимости несмотря на шум расписание шага α_k должно удовлетворять

$$\sum_k \alpha_k = \infty \quad (\text{дотянуться до минимума}), \quad \sum_k \alpha_k^2 < \infty \quad (\text{успокоиться, не дрожать вечно}).$$

Пример: $\alpha_k = 1/k$ (гармонический ряд расходится, $\sum 1/k^2$ сходится). Только $\alpha_k = \text{const}$: вечное дрожание. Только $\alpha_k = 1/k^2$: сумма шагов конечна, до далёкого минимума не дойти.

Размер батча

Малый: шумно, дешёво, шум помогает выпрыгивать и регуляризует. Большой: стабильно, дорого. Mini-batch (32–512): компромисс + параллелизм GPU.

Фишка на собеседе

Два РАЗНЫХ эффекта одного шума, работают одновременно (не последовательно): (1) **выпрыгивание из плохой ямы** — масштаб навигации по невыпуклому ландшафту (в какой долине окажемся); (2) **implicit regularization** — шум не даёт дойти до острого/переобученного дна ВНУТРИ хорошей ямы, склоняет к широким flat minima (лучше обобщают). Первое — «в какой долине», второе — «насколько остро вниз в этой долине сядем».

Билет 20. Ускоренные и адаптивные методы: Momentum, Adam

Определение: Momentum («тяжёлый шарик»)

$$v = \gamma v + \eta g, \quad w = w - v, \quad g = \nabla f(w), \quad \gamma \approx 0.9.$$

v — накопленная скорость (память о прошлых шагах). Вдоль пологого направления (стабильный g) скорость накапливается — разгон; вдоль крутого (знакопеременный g) вклады $+\eta g$ и $-\eta g$ гасят друг друга — демпфирование зигзага. **NAG**: градиент в упреждающей точке $w - \gamma v$.

Определение: Адаптивные методы (свой шаг каждому весу)

AdaGrad: $S = S + g^2$, $w = w - \eta g / (\sqrt{S} + \varepsilon)$ — шаг падает у весов с историей больших g ; минус: S растёт вечно, шаг затухает до нуля. **RMSProp**: $S = \beta S + (1 - \beta)g^2$ — ЕМА с забыванием, шаг не затухает навсегда.

Определение: Adam = Momentum + RMSProp

$$m = \beta_1 m + (1 - \beta_1)g \quad (\text{направление}), \quad v = \beta_2 v + (1 - \beta_2)g^2 \quad (\text{масштаб}),$$

$$\hat{m} = \frac{m}{1 - \beta_1^t}, \quad \hat{v} = \frac{v}{1 - \beta_2^t}, \quad w = w - \eta \frac{\hat{m}}{\sqrt{\hat{v}} + \varepsilon}.$$

$\beta_1 \approx 0.9$, $\beta_2 \approx 0.999$, t — номер итерации.

Зачем коррекция смещения

$m_0 = 0 \Rightarrow m_1 = \beta_1 \cdot 0 + (1 - \beta_1)g_1 = (1 - \beta_1)g_1$. При $\beta_1 = 0.9$: $m_1 = 0.1g_1$ — всего 10% истинного градиента (сильно занижено). Коррекция: $\hat{m}_1 = m_1 / (1 - \beta_1^1) = (1 - \beta_1)g_1 / (1 - \beta_1) = g_1$ — точно восстанавливает. При росте t множитель $(1 - \beta_1^t) \rightarrow 1$, коррекция автоматически выключается.

AdamW

В обычном Adam L2-штраф $2\tau w$ тоже делится на $\sqrt{\hat{v}} \rightarrow$ у весов с большим градиентом регуляризация ослабляется непредсказуемо. AdamW применяет weight decay $w \leftarrow w(1 - \lambda)$ ОТДЕЛЬНО от адаптивной нормировки — корректная L2.

Фишка на собесе

Adam/AdamW — дефолт (быстро, мало настройки, устойчив к разномасштабным градиентам — NLP, трансформеры). SGD+Momentum часто даёт ЛУЧШЕЕ финальное обобщение (CV) — Adam иногда садится в острый минимум, а шум SGD ведёт к flat minima. State-of-the-art в CV нередко всё ещё SGD+momentum.

Билет 21. Разложение на смещение, дисперсию и шум (bias-variance)

Теорема: Bias–variance разложение

Для $y = f(x) + \varepsilon$, $\mathbb{E}\varepsilon = 0$, $\text{Var } \varepsilon = \sigma^2$, $\bar{f}(x) = \mathbb{E}_D[\hat{f}(x)]$:

$$\text{EPE}(x) = \underbrace{(f(x) - \bar{f}(x))^2}_{\text{Bias}^2} + \underbrace{\mathbb{E}_D[(\bar{f}(x) - \hat{f}(x))^2]}_{\text{Variance}} + \underbrace{\sigma^2}_{\text{Noise}}.$$

Обнуление перекрёстных членов

Раскрываем $\mathbb{E}[(f - \bar{f}) + (\bar{f} - \hat{f}) + \varepsilon]^2$. Перекрёстные члены зануляются: $(f - \bar{f})$ — константа; $\mathbb{E}[\bar{f} - \hat{f}] = 0$ по определению $\bar{f} = \mathbb{E}_D[\hat{f}]$; $\mathbb{E}\varepsilon = 0$ и ε независим от $\hat{f}$. Остаётся сумма трёх квадратов.

Смысл слагаемых

Bias^2 — систематическая неспособность модели выразить f (недообучение). Variance — чувствительность к конкретной выборке (переобучение; связь с билетом 11 — неустойчивость = высокая variance). Noise — неустранимый предел (σ^2).

Как зависят от сложности и n

Рост сложности: $\text{Bias} \downarrow$, $\text{Variance} \uparrow$. Регуляризация ($\tau \uparrow$): $\text{Bias} \uparrow$, $\text{Variance} \downarrow$. **Bias** — вопрос К МОДЕЛИ (форма/сложность), НЕ лечится ростом n . **Variance** — вопрос К ВЫБОРКЕ, ПАДАЕТ с ростом n (больше данных $\rightarrow$ выборки представительнее $\rightarrow \hat{f}$ меньше прыгает, ЗБЧ).

Фишка на собеседе

Learning curves: train-ошибка РАСТЁТ с n (сложнее подогнать больше точек, $\rightarrow \text{Bias}^2 + \text{Noise}$ сверху), val-ошибка ПАДАЕТ ($\text{Variance} \downarrow$, $\rightarrow$ тот же предел снизу), кривые сходятся к $\text{Bias}^2 + \text{Noise}$. Разрыв между ними = мера Variance . Частая ошибка: сказать «variance растёт с n » — наоборот, падает. Bias лечат сложнее моделью/признаками, Variance — данными/регуляризацией/бэггингом. Бэггинг и рост n снижают Variance почти бесплатно (не трогая Bias).

Билет 22. Энтропия, кросс-энтропия и KL-дивергенция**Определение: Три величины**

$$H(p) = - \sum_i p_i \log p_i, \quad H(p, q) = - \sum_i p_i \log q_i, \quad KL(p||q) = \sum_i p_i \log \frac{p_i}{q_i} = H(p, q) - H(p).$$

Информационный смысл

$H(p)$ — среднее число бит для оптимального кодирования $x \sim p$ (выводится однозначно из аксиом непрерывности, монотонности, аддитивности — теорема Шеннона). Максимум у равномерного (полная неопределённость). Честная монета: $H = 1$ бит. $H(p, q)$ — реальное число бит, если кодируем оптимально под q (модель), а данные приходят из p (истина); $H(p, q) \geq H(p)$, равенство $\Leftrightarrow q = p$. KL — лишние биты из-за $q \neq p$; $KL \geq 0$,

$= 0 \Leftrightarrow p = q$, НЕсимметрична (не метрика).

Связи с ML

Максимизация правдоподобия $\Leftrightarrow$ минимизация $KL(p_{\text{data}} \| p_{\text{model}})$. Кросс-энтропия = log-loss логрег/softmax. Энтропия = критерий ветвления деревьев (information gain).

Пример: Асимметрия KL на 3 точках

Истина $p = (0.5, 0, 0.5)$ (моды A, C; B невозможна). Кандидаты: $q_{\text{cover}} = (0.4, 0.2, 0.4)$ (покрывает обе моды, чуть «мусорит» в B), $q_{\text{single}} = (0, 0, 1)$ (игнорирует моду A). $KL(p \| q_{\text{single}})$: точка A даёт $0.5 \log(0.5/0) = \infty$. $KL(p \| q_{\text{cover}}) \approx 0.22$ (в B: $0 \cdot \log(0/0.2) = 0$, штрафа нет). **Forward KL** наказывает игнор моды, не наказывает лишнюю массу. $KL(q_{\text{single}} \| p) \approx 0.69$ (в A: $0 \cdot \log = 0$, штрафа за игнор нет). $KL(q_{\text{cover}} \| p)$: в B $0.2 \log(0.2/0) = \infty$. **Reverse KL** наказывает массу там, где истины нет.

Фишка на собеседе

Ключ к асимметрии — ВЕС перед логарифмом. $KL(p \| q) = \sum p_i \log(p_i/q_i)$ взвешен по p : штраф ∞ если $q \rightarrow 0$ там где $p > 0$; но 0 если $p = 0$ (лишняя масса q бесплатна) $\Rightarrow$ **mean-seeking**, накрывает все моды. $KL(q \| p)$ взвешен по q : штраф ∞ если $p \rightarrow 0$ там где $q > 0$; но 0 если $q = 0$ (игнор моды p бесплатен) $\Rightarrow$ **mode-seeking**, садится на одну моду.

Билет 23. Кросс-валидация и утечки данных

Определение: K-fold CV

Разбить на k фолдов; k раз обучать на $k-1$, валидировать на оставшемся; усреднить. Каждый объект ровно раз в роли validation. Надёжнее одного split (усредняет по разбиениям).

Разновидности

Stratified: сохраняет доли классов (критично при дисбалансе). **LOO** ($k = n$): почти несмещённая оценка, но дорого (n обучений) и высокая дисперсия (каждый фолд = один объект). **Time series split**: только прошлое $\rightarrow$ будущее.

Nested CV

Внешний цикл — честная оценка, внутренний — подбор гиперпараметров. Иначе (подбор на тех же фолдах, где меряем качество) — оптимистичное смещение.

Определение: Виды утечки данных (data leakage)

1. **Target leakage** — признак есть следствие таргета («дата выписки» при предсказании выписки).
2. **Препроцессинг** — статистики (μ, σ , target encoding, импутация) считать ТОЛЬКО на train внутри фолда.

3. **Временная** — будущее $\rightarrow$ прошлое.

4. **Дубликаты** train/test.

Симптом — подозрительно высокое качество, не подтверждающееся в проде.

Фишка на собеседе

Тонкая утечка через препроцессинг в CV: если μ, σ посчитаны по ВСЕЙ выборке до разбиения, то стандартизируя train-часть фолда, мы используем μ, σ , в которые внесли вклад объекты validation ЭТОГО фолда. Train-признаки статистически коррелируют со значениями validation $\Rightarrow$ модель косвенно «подглядывает». Правильно: пересчитывать μ, σ заново для train-части КАЖДОГО фолда (не один раз глобально).

Раздел 3. Оптимизация второго порядка

Раздел для полноты; на собеседах по classic ML спрашивают редко (кроме интуиции GD vs Ньютон vs BFGS). Изложено компактно.

Билет 24. Метод Ньютона

$$x_{k+1} = x_k - [\nabla^2 L(x_k)]^{-1} \nabla L(x_k).$$

Квадратичная аппроксимация по Тейлору (учитывает кривизну $\nabla^2 L$ = гессиан). Для квадратичной функции (МНК) — точный минимум за 1 шаг: «видит форму горы целиком».

Билет 25. Проблемы Ньютона и Левенберг–Марквардт

Минусы Ньютона: гессиан дорог ($O(m^3)$ на обращение), может быть необратим/плохо обусловлен, вдали от минимума расходится. **Левенберг–Марквардт** (нелинейный МНК): $(J^T J + \lambda I)p = -J^T f$. λI как Ridge гарантирует обратимость: большой $\lambda \rightarrow$ GD (надёжно, медленно), малый $\rightarrow$ Гаусс–Ньютон (быстро). λ адаптируется по успеху шага.

Билет 26. Демпфированный Ньютон и линейный поиск

$x_{k+1} = x_k + \gamma_k H^{-1} \nabla f$ — размер шага γ_k и приближённый (замороженный) H . Line search: при известном направлении p_k задача сводится к одномерной $\gamma_k^* = \arg \min_{\gamma} f(x_k + \gamma p_k)$; неточный поиск — условия Армихо/Вульфа (достаточное убывание).

Билет 27. Квазиньютоновские методы: секущее уравнение

Строим приближение $B_k \approx [\nabla^2 f]^{-1}$ по истории градиентов (только 1-е производные). $s_k = x_{k+1} - x_k$, $y_k = \nabla f(x_{k+1}) - \nabla f(x_k)$: секущее уравнение $s_k = B_{k+1} y_k$ (недоопределено $\rightarrow$ доп. требования: симметричность, $\succ 0$, близость к B_k).

Билет 28. Метод SR-1 (Symmetric Rank-1)

Добавка ранга 1: $B_{k+1} = B_k + \frac{(s_k - B_k y_k)(s_k - B_k y_k)^T}{(s_k - B_k y_k)^T y_k}$. При $k \rightarrow \infty$ сходится к обратному гессиану. Минус: может терять положительную определённость $\rightarrow$ направление не убывания.

Билет 29. Алгоритм BFGS и L-BFGS

Добавка ранга 2. Гарантия: если $B_0 \succ 0$ и $y_k^T s_k > 0$ (обеспечивает line search) — все $B_k \succ 0$, направление всегда убывающее. **L-BFGS**: хранит не всю матрицу, а последние

$\sim 10\text{--}20$ пар (s_k, y_k) — для больших размерностей.

Фишка на собеседе

Иерархия $\text{GD} \rightarrow \text{BFGS} \rightarrow \text{Ньютон}$ = сколько информации о кривизне (0/1/2-й порядок): GD — только наклон (дёшево, много шагов), Ньютон — точная кривизна (дорого, мало шагов), BFGS — приближает кривизну по истории градиентов (средне). Почему не всегда BFGS: (1) $O(m^2)$ память — невозможно для нейросетей с млрд параметров; (2) плохо совместим с mini-batch — шумная история градиентов ломает оценку кривизны. Поэтому в deep learning — SGD/Adam, а BFGS/L-BFGS — в классическом ML (логрег, CRF) с full-batch.

Раздел 4. Снижение размерности

Билет 30. Теорема о наилучшем низкоранговом приближении (Эккарта–Янга)

Теорема: Эккерт–Янг

$$\min_{B: \text{rank}(B)=k} \|X - B\| \implies B = \sum_{j=1}^k u_j \sigma_j v_j^T, \quad \|X - B\| = \sigma_{k+1}.$$

Наилучшее приближение ранга k (по норме Фробениуса/спектральной) = усечённое SVD (top- k троек). Ошибка = первое отброшенное сингулярное число.

Зачем снижать размерность

Борьба с шумом (малые σ = шумовые направления); визуализация; скорость; борьба с мультиколлинеарностью; проклятие размерности (kNN деградирует).

Фишка на собеседе

Оптимальность ГЛОБАЛЬНАЯ, не поточечная. $\|X - B\|_F^2 = \sum_i \|x_i - b_i\|^2$ — минимизируется СУММА по объектам, не каждое слагаемое. Нетипичный объект (вариация в отброшенных направлениях с малым σ) реконструируется плохо, даже если B оптимальна в среднем. Пример: PCA на лицах ловит общие вариации (освещение, поворот), но редкая особенность (шрам) уходит в отброшенные компоненты. Связь с выбросами (билет 94): низкоранговое приближение «стирает» редкие сигналы.

Билет 31. PCA через максимизацию дисперсии

Определение: Задача PCA

Найти ортогональное направление Rot ($\|\text{Rot}\| = 1$) с максимальной дисперсией проекций: $\max_{\text{Rot}} \|X \cdot \text{Rot}\|^2$ при $\|\text{Rot}\| = 1$.

Вывод через Лагранжиан

$\mathcal{L} = \text{Rot}^T (X^T X) \text{Rot} - \lambda (\text{Rot}^T \text{Rot} - 1)$. Градиент:

$$\nabla \mathcal{L} = 2(X^T X) \text{Rot} - 2\lambda \text{Rot} = 0 \implies (X^T X) \text{Rot} = \lambda \text{Rot}.$$

Направления максимальной дисперсии = собственные векторы $X^T X$ = столбцы V (SVD), $\lambda = \sigma^2$ = дисперсии проекций.

Эквивалентность двух взглядов

«Максимум дисперсии вдоль Rot » $\Leftrightarrow$ «минимум ошибки реконструкции $\perp \text{Rot}$ » (билет

30). Полная энергия $\sum \|x_i\|^2 = \text{const}$ раскладывается по теореме Пифагора на объяснённую дисперсию + ошибку реконструкции; максимизация первого минимизирует второе.

Фишка на собеседе

РСА (unsupervised, максимум дисперсии) vs LDA (supervised, максимум разделённости классов). Направление максимальной дисперсии может быть ПЕРПЕНДИКУЛЯРНО направлению разделения классов: два длинных узких облака классов, вытянутых вдоль одной оси, но сдвинутых перпендикулярно. РСА выберет ось вытянутости (максимум дисперсии), спроецирует на неё — классы схлопнутся и перемешаются. LDA нашёл бы ось разделения. Мораль: РСА-препроцессинг перед классификацией может УНИЧТОЖИТЬ разделимость.

Билет 32. РСА: геометрия, выбор числа компонент, центрирование

Переход к главным компонентам

$X \cdot \text{Rot} = K$, где Rot — первые d правых сингулярных векторов V (билет 31). Компоненты K взаимно ОРТОГОНАЛЬНЫ (не коррелируют) — следствие ортонормированности столбцов V . Это и есть декорреляция данных.

Определение: Информативность компонент

$\sigma_1 \geq \dots \geq \sigma_r$. Сохранённая доля: $S_d/\tilde{S}$, $S_d = \sum_{i=1}^d \sigma_i$, $\tilde{S} = \sum_{j=1}^r \sigma_j$. На практике чаще через дисперсию (explained variance ratio): доля = $\sum_{i=1}^d \sigma_i^2 / \sum_j \sigma_j^2$ (т.к. $\lambda = \sigma^2$ — дисперсия проекции, билет 31).

Scree plot и метод локтя

График σ_i по номеру компоненты. **Метод локтя**: ищем точку излома, где резкое падение сменяется плато — субъективно, хорош при чёткой границе сигнал/шум, плохо работает при плавном убывании (нет однозначного излома). **Порог % дисперсии** (напр. 95%): объективен, воспроизводим для автоматизации, но выбор порога произволен и не различает «резкий сигнал+шум» от «плавно убывающей значимости».

КРИТИЧНО: центрирование

Без вычитания среднего РСА максимизирует $\|X \cdot \text{Rot}\|^2$ — это ВТОРОЙ МОМЕНТ, не дисперсия. Матрица, которую диагонализировать: $X^T X = n \cdot (\text{ковариация}) + n\mu\mu^T$. Если μ велико относительно разброса, слагаемое $n\mu\mu^T$ доминирует — первая «компонента» указывает в сторону среднего (куда смещено облако), а не в сторону реальной вариации данных вокруг центра. Обязательно центрировать (и обычно стандартизировать) перед РСА.

Фишка на собеседе

Различай масштаб как АРТЕФАКТ единиц измерения (рубли vs годы — стандартизируй ОБЯЗАТЕЛЬНО, иначе смена единиц меняет главную компоненту)

от масштаба как СОДЕРЖАТЕЛЬНОЙ информации (10 признаков, 9 — сигнал с большим разбросом, 1 — шум с крошечным естественным разбросом). Во втором случае стандартизация РАЗДУВАЕТ дисперсию шумового признака до 1 (как у всех), он формирует собственное отдельное направление с $\lambda \approx 1$, искусственно неотличимое в scree plot от сигнальных компонент — прячет реальную границу сигнал/шум, которая без стандартизации была видна по естественной разнице масштабов. Правило: одинаковые единицы + разный контентный разброс — стандартизация может ВРЕДИТЬ, пробуй оба варианта.

Билет 33. Степенной метод (Power Iteration) и deflation

Определение: Power Iteration

Найти главный собственный вектор $A = X^T X$ без полного SVD:

$$x^{(k+1)} = \frac{Ax^{(k)}}{\|Ax^{(k)}\|}.$$

Сходится к собственному вектору, соответствующему МАКСИМАЛЬНОМУ собственному числу λ_1 .

Почему сходится к v_1

Разложим $x^{(0)} = c_1 v_1 + c_2 v_2 + \dots + c_r v_r$ по базису собственных векторов ($\lambda_1 > \lambda_2 \geq \dots$). Тогда

$$A^k x^{(0)} = c_1 \lambda_1^k v_1 + c_2 \lambda_2^k v_2 + \dots = \lambda_1^k \left(c_1 v_1 + c_2 \left(\frac{\lambda_2}{\lambda_1} \right)^k v_2 + \dots \right).$$

Т.к. $(\lambda_2/\lambda_1)^k \rightarrow 0$ (строго убывает при $\lambda_1 > \lambda_2$), после нормировки все слагаемые кроме v_1 «вымирают». Скорость сходимости зависит от $|\lambda_2/\lambda_1|$ — чем меньше, тем быстрее (та же логика, что скорость GD, билет 18).

Замечание: Случай $\lambda_1 = \lambda_2$

Метод НЕ «плохо сходится» — он сходится к вектору внутри ДВУМЕРНОГО собственного подпространства $\text{span}(v_1, v_2)$ (оба слагаемых домножаются на один и тот же λ_1^k , не затухают друг относительно друга). Какая именно комбинация $c_1 v_1 + c_2 v_2$ получится — зависит от случайного старта $x^{(0)}$: результат не единственен, потому что единственного «главного» направления в этом случае просто не существует.

Определение: Deflation (исчерпывание)

Для следующей компоненты вычитаем вклад найденной:

$$A_{\text{new}} = A - \lambda_1 v_1 v_1^T.$$

Повторяем power iteration на A_{new} .

Почему максимум A_{new} = второе по величине λ исходной A

Действие на v_1 : $A_{\text{new}}v_1 = Av_1 - \lambda_1v_1(v_1^T v_1) = \lambda_1v_1 - \lambda_1v_1 = 0$ — направление v_1 обнулено.

Действие на v_2 (или любой v_j , $j \neq 1$): $A_{\text{new}}v_2 = Av_2 - \lambda_1v_1(v_1^T v_2) = \lambda_2v_2 - \lambda_1v_1 \cdot 0 = \lambda_2v_2$ (т.к. собственные векторы симметричной матрицы ОРТОГОНАЛЬНЫ, $v_1^T v_2 = 0$) — v_2 остаётся собственным вектором с ТЕМ ЖЕ λ_2 , не тронут. Итог: собственные числа $A_{\text{new}} = \{0, \lambda_2, \lambda_3, \dots\}$ — максимум теперь λ_2 . Ортогональность собственных векторов — ключевой факт, делающий deflation «хирургически точным».

Когда выгодно

Нужно лишь несколько top- k компонент из БОЛЬШОЙ матрицы — полное SVD $O(\min(n, m)^3)$ избыточно дорого; power iteration + deflation даёт k компонент за $O(k)$ проходов умножения матрицы на вектор.

Билет 34. Kernel PCA и ядра**Проблема и идея**

Линейный PCA ищет направления как линейные комбинации исходных признаков — не ловит нелинейную структуру (кольца, спирали). Идея: отобразить $x \rightarrow \varphi(x)$ в пространство БОЛЬШЕЙ размерности, где структура линеаризуется, и применить PCA там.

Пример: Кольца

Красные точки в центре, синие вокруг кольцом — в 2D неразделимо линией. При $z = x^2 + y^2$ («выдавить» центр вверх) красные (маленький радиус, маленький z) окажутся внизу, синие (большой радиус, большой z) — наверху; в 3D разделяются плоскостью. Заметь: $z = x^2 + y^2 = \langle (x, y), (x, y) \rangle$ — это КВАДРАТ РАДИУСА (в полярных: $r^2 \cos^2 \theta + r^2 \sin^2 \theta = r^2$), т.е. ровно та характеристика, которая и различает классы (радиус), угол θ — шумовая координата.

Определение: Kernel trick

Если алгоритм использует данные только через скалярные произведения $\langle \varphi(x_i), \varphi(x_j) \rangle$ (PCA можно переформулировать через матрицу Грама в новом пространстве), заменяем это на функцию ЯДРА:

$$K(x_i, x_j) = \langle \varphi(x_i), \varphi(x_j) \rangle,$$

вычисляемую НАПРЯМУЮ по исходным x , без явного построения $\varphi(x)$.

Популярные ядра

Полиномиальное: $K(x, y) = (c + \langle x, y \rangle)^d$ (взаимодействия признаков). RBF: $K(x, y) = \exp(-\gamma \|x - y\|^2)$ — соответствует БЕСКОНЕЧНОМЕРНОМУ пространству признаков (теорема Мерсера ниже).

Теорема: Условие Мерсера

K годится как ядро $\Leftrightarrow K$ симметрична и ПОЛОЖИТЕЛЬНО ПОЛУОПРЕДЕЛЕНА (матрица $K(x_i, x_j)$ для любого набора точек — PSD). Это ровно аксиома 3 скалярного произведения из функана ($\langle x, x \rangle \geq 0$): отрицательное собственное число матрицы Грама означало бы $\|\varphi(x)\|^2 < 0$ для какого-то вектора — невозможно для настоящего скалярного произведения. Без PSD не существует φ , для которого K было бы честным $\langle \varphi(x), \varphi(y) \rangle$ — вся геометрическая схема (существование RKHS, гарантии выпуклости SVM) ломается.

Теорема Мерсера (явная формула, связь с функаном)

Для непрерывного симметричного PSD-ядра существует ортонормированный базис собственных функций $\{\psi_i\}$ интегрального оператора $(T_K f)(x) = \int K(x, y) f(y) dy$ с собственными числами $\lambda_i \geq 0$:

$$K(x, y) = \sum_i \lambda_i \psi_i(x) \psi_i(y).$$

Это спектральное разложение ОПЕРАТОРА (аналог $X = USV^T$ для матрицы, билет 6, только в бесконечномерном функциональном пространстве). Отсюда явный feature map $\varphi(x) = (\sqrt{\lambda_1} \psi_1(x), \sqrt{\lambda_2} \psi_2(x), \dots)$ — для RBF сумма бесконечна, вот откуда «RBF = бесконечномерное пространство признаков».

RKHS (Reproducing Kernel Hilbert Space)

Гильбертово пространство H_K , канонически связанное с K , со свойством воспроизведения $f(x) = \langle f, K(x, \cdot) \rangle_{H_K}$. Строится (теорема Мура–Аронжайна) как пополнение линейных комбинаций $\sum_i c_i K(x_i, \cdot)$ со скалярным произведением $\langle K(x, \cdot), K(y, \cdot) \rangle := K(x, y)$ — та же операция пополнения по Коши, что при построении L^2 в функане. Биекция между PSD-ядрами и RKHS: выбор ядра K полностью определяет пространство H_K , в котором работает алгоритм.

Фишка на собесе

‘[Николенко]’ Ядро — функция похожести = скалярное произведение в (возможно неявном) пространстве признаков (RKHS). Та же идея «ядризации» применима к любому алгоритму, зависящему от данных только через $\langle x_i, x_j \rangle$ — в частности к SVM (билет 43): подставляем K вместо $\langle x_i, x_j \rangle$ и никогда не вычисляем $\varphi(x)$ явно, даже если оно бесконечномерно.

Билет 35. Нелинейное снижение размерности: t-SNE и UMAP**Отличие от PCA**

PCA/Kernel PCA сохраняют ГЛОБАЛЬНУЮ структуру (расстояния, дисперсию). t-SNE/UMAP сохраняют ЛОКАЛЬНУЮ структуру (кто с кем сосед), жертвуя точностью глобальных расстояний — инструменты для визуализации, не общий препроцессинг.

Определение: t-SNE: сходства в исходном пространстве

$$p_{j|i} = \frac{\exp(-\|x_i - x_j\|^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|x_i - x_k\|^2 / 2\sigma_i^2)}, \quad p_{ij} = \frac{p_{j|i} + p_{i|j}}{2n}.$$

σ_i СВОЯ для каждой точки, подбирается так, чтобы энтропия $H(P_i)$ (билет 22) соответствовала заданной **perplexity** $= 2^{H(P_i)}$ (эффективное число соседей, обычно 5–50).

Определение: t-SNE: сходства в 2D и loss

$$q_{ij} = \frac{(1 + \|y_i - y_j\|^2)^{-1}}{\sum_{k \neq l} (1 + \|y_k - y_l\|^2)^{-1}}, \quad \text{Loss} = KL(P \| Q) = \sum_{ij} p_{ij} \log \frac{p_{ij}}{q_{ij}}.$$

P фиксирован, Q зависит от оптимизируемых координат $\{y_i\}$ (GD, билет 5). t-распределение (1 степень свободы) вместо гауссианы — ключевое решение.

Crowding problem и почему именно тяжёлые хвосты

В высокой размерности вокруг точки помещается много «умеренно далёких» соседей; в 2D/3D физически не хватает места разместить их на том же ОТНОСИТЕЛЬНОМ расстоянии (объём растёт с размерностью). Простое увеличение σ у гауссианы НЕ решает проблему: хвост всё равно убывает ЭКСПОНЕНЦИАЛЬНО ($\exp(-x^2)$), вероятностная масса жмётся в узкий пик — скученность в центре. t-распределение убывает СТЕПЕННО ($\propto 1/d^2$ при больших d) — гораздо медленнее, даёт умеренно удалённым точкам достаточно «вероятностной массы», чтобы расселиться на больших дистанциях в 2D без катастрофического штрафа KL.

Почему forward $KL(P \| Q)$, а не reverse

P — истина (высокая размерность), Q — модель (2D-расположение). Forward KL сильно наказывает, если q_{ij} мало там, где p_{ij} велико (билет 22) — реальные соседи, оказавшиеся далеко в 2D, штрафуются жёстко. Это обеспечивает главное свойство t-SNE: сохранение локальных соседств любой ценой, даже за счёт искажения глобальной геометрии.

Определение: UMAP: fuzzy simplicial set

Граф k ближайших соседей, вес ребра

$$w_{ij} = \exp\left(-\frac{d(x_i, x_j) - \rho_i}{\sigma_i}\right),$$

ρ_i — расстояние до ближайшего соседа (гарантирует связность весом 1). Симметризация через fuzzy union: $W_{ij} = w_{ij} + w_{ji} - w_{ij}w_{ji}$. В 2D: $v_{ij} = (1 + a \|y_i - y_j\|^{2b})^{-1}$.

UMAP loss — cross-entropy, не KL

$$\text{Loss} = \sum_{ij} \left[W_{ij} \log \frac{W_{ij}}{v_{ij}} + (1 - W_{ij}) \log \frac{1 - W_{ij}}{1 - v_{ij}} \right].$$

Первое слагаемое — притяжение похожих точек (как t-SNE). Второе — ЯВНОЕ отталкивание непохожих, встроенное прямо в loss (у t-SNE отталкивание — лишь

побочный эффект нормировки знаменателя Q). Отсюда лучшая сохранность глобальной структуры у UMAP — кластеры не «слипаются» бесконтрольно.

Почему UMAP быстрее

Приближённый поиск соседей (не точный k -NN); negative sampling (случайная выборка «негативных» пар вместо всех $O(n^2)$, как в word2vec); более информативный градиент (явные притяжение+отталкивание).

Фишка на собесе

Отсутствие out-of-sample у t-SNE — НЕ просто «дорого пересчитывать, как в kNN». У PCA есть явная параметрическая формула ($x_{\text{new}} \cdot \text{Rot}$), применимая к любой новой точке независимо. У t-SNE координат $\{y_i\}$ — это результат СОВМЕСТНОЙ глобальной оптимизации по всем n точкам сразу (единая система, не независимое отображение точка-за-точкой). Новую точку нельзя вставить в формулу — либо переоптимизировать всё целиком (старые y могут сдвинуться, в отличие от PCA), либо грубо приблизить, зафиксировав старые y .

Автокодировщики и когда что выбирать

Автокодировщик (нейросеть с bottleneck) — обучаемое НЕЛИНЕЙНОЕ обобщение PCA (PCA = автокодировщик с линейными активациями). **PCA**: линейно/быстро/интерпретируемо, глобальная структура, общий препроцессинг. **t-SNE/UMAP**: визуализация кластеров при нелинейной структуре. **UMAP** предпочтительнее t-SNE на практике (быстрее, стабильнее, годится как препроцессинг перед кластеризацией, напр. HDBSCAN, билет 64).

Раздел 5. Классификация: линейные методы

Билет 36. Задача классификации и отступ (margin)

Определение: Отступ

Дискриминантная функция $c(x, w)$ — уверенность модели; ответ $a(x) = \text{sign}(c(x, w))$.

$$M(x, y) = c(x, w) \cdot y.$$

$M > 0$ — верная классификация; $M < 0$ — ошибка; $M \approx 0$ — пограничный объект (близко к границе решения, неустойчив к малым изменениям).

Типизация по отступу

$M \gg 0$ надёжный; $M \approx 0$ сомнительный; $M \ll 0$ грубая ошибка/выброс. Величина отступа — основа ВСЕХ функций потерь классификации (билет 37).

Фишка на собесе

$c(x, w)$ не ограничена по масштабу (домножение w на 100 домножает все $|M|$ на 100). Два реальных решения: (1) геометрическая нормировка $M/\|w\|$ (SVM, билет 40, фиксируют $\min_i M_i = 1$, ширина полосы $= 2/\|w\|$ уже не зависит от масштаба w); (2) калибровка через сигмоиду $\sigma(c(x, w)) \in (0, 1)$ (логрег, билет 38) — превращает score в вероятность.

Билет 37. Пороговая функция потерь и её гладкие оценки

Проблема ступеньки

Идеальный функционал $Q_0 = \frac{1}{n} \sum_i [M_i < 0]$ — ступенька, производная = 0 почти всюду $\Rightarrow$ градиентные методы не видят, куда двигаться.

Определение: Гладкие верхние оценки $\varphi(M)$

- Логистическая: $\log_2(1 + e^{-M})$ — логрег. Никогда не = 0 даже при $M \gg 0$.
- Hinge: $\max(0, 1 - M)$ — SVM. = 0 при $M \geq 1$ (не просто $M > 0$!) — зона безопасности $\rightarrow$ разреженность опорных векторов.
- Экспоненциальная: e^{-M} — AdaBoost. Растёт быстрее всех при $M \rightarrow -\infty$ — чувствительна к выбросам (см. билет 56).
- Квадратичная: $(1 - M)^2$.

Фишка на собеседе

$\log_2$ vs $\ln$ — чистая конвенция масштаба ($\log_2 x = \ln x / \ln 2$), argmin по w не меняется. $\log_2$ здесь — дань информационной рамке (биты, билет 22); индустриальный стандарт (sklearn, PyTorch) — $\ln$ через прямой вывод MLE (билет 10), без лишней константы.

Билет 38. Логистическая регрессия**Определение: Odds и log-odds**

Odds = $p/(1-p)$ (не вероятность!). $p = 0.75 \Rightarrow \text{odds} = 3$ («3 к 1»). Log-odds = $\log(p/(1-p)) \in (-\infty, +\infty)$ — НЕограничены, поэтому линейная модель $w^\top x$ годится именно для log-odds, не для p напрямую.

Вывод модели

$$\log \frac{P(C_1|x)}{P(C_0|x)} = w^\top x \Rightarrow P(C_1|x) = \sigma(w^\top x) = \frac{1}{1+e^{-w^\top x}}.$$

Функция потерь (кросс-энтропия)

Бернулли: $L(w) = \prod_i \sigma(w^\top x_i)^{y_i} (1 - \sigma(w^\top x_i))^{1-y_i}$.

$$\nabla L = \sum_i (\sigma(w^\top x_i) - y_i) x_i.$$

Структура градиента ИДЕНТИЧНА МНК ($\nabla = 2X^\top(Xw - y)$, билет 5) — невязка (предсказание—истина), умноженная на x_i . Разница: невязка $(\sigma(w^\top x) - y)$ НЕЛИНЕЙНА по w (из-за σ) $\Rightarrow \nabla L = 0$ — трансцендентное уравнение, нет аналитики (в отличие от линрег, где невязка линейна по w). Обучение: GD или IRLS (=Ньютон, билет 24).

Стандартная запись (как на собеседе)

$y \in \{0, 1\}$, $L = -\frac{1}{n} \sum_i [y_i \log p_i + (1 - y_i) \log(1 - p_i)]$, $p_i = \sigma(w^\top x_i)$ — binary cross-entropy, $\ln$. Эквивалентна margin-форме $\frac{1}{n} \sum \log(1 + e^{-M_i})$ при перекодировке $y \in \{-1, +1\}$.

Фишка на собеседе

Odds ratio e^{w_j} : увеличение x_j на 1 меняет ШАНСЫ в e^{w_j} раз (не вероятность!) при ПРОЧИХ РАВНЫХ. При мультиколлинеарности (билет 4) остальные признаки не могут оставаться «равными» (двигаются вместе с x_j) — интерпретация конкретного w_j становится ненадёжной, веса неустойчивы (билет 11). Калибровка «из коробки»: логрег прямо оптимизирует log-loss $\Rightarrow p = \sigma(w^\top x)$ ведёт себя как настоящая частота. SVM/деревья не оптимизируют это напрямую $\Rightarrow$ требуют калибровки постфактум (билет 51). Порог 0.5 — ДЕФОЛТ, не требование: сдвигают в зависимости от цены FP vs FN (билет 47–49), это отдельный шаг ПОСЛЕ обучения модели, сама модель не меняется.

Билет 39. LDA, QDA и линейный дискриминант Фишера

Замечание: Не путать с Latent Dirichlet Allocation

LDA (Linear Discriminant Analysis, наш билет) — классификация, supervised, гауссианы классов. LDA (Latent Dirichlet Allocation) — тематическое моделирование текстов, unsupervised, распределение Дирихле на пропорции тем. Омонимия названий, не версии одного метода.

Определение: Порождающий подход

$P(C_k|x) \propto p(x|C_k)P(C_k)$, $p(x|C_k) = N(\mu_k, \Sigma_k)$ — предположение: данные внутри класса k гауссовски распределены вокруг μ_k . Контраст с логрег (дискриминативный): LDA строит полную модель «как появился x », логрег сразу решает $P(y|x)$, не моделируя x .

QDA vs LDA

QDA: своя Σ_k у каждого класса $\Rightarrow$ квадратичные члены $x^T \Sigma_k^{-1} x$ не сокращаются в log-отношении плотностей $\Rightarrow$ КВАДРАТИЧНАЯ граница. **LDA**: общая Σ у всех классов $\Rightarrow$ квадратичные члены сокращаются $\Rightarrow$ ЛИНЕЙНАЯ граница. При верных гауссовых предположениях — байесовски оптимальный классификатор.

Критерий Фишера

$$J(w) = \frac{w^T S_B w}{w^T S_W w}, \quad w \propto S_W^{-1}(\mu_2 - \mu_1).$$

S_B — межклассовый разброс (числитель, далёкость центров), S_W — внутриклассовый (знаменатель, компактность каждого класса). БЕЗ знаменателя максимизация S_B просто «растаскила бы» классы, не заботясь об их внутренней кучности — отношение гарантирует разделимость ОТНОСИТЕЛЬНО разброса. Для K классов: обобщённая задача $S_B v = \lambda S_W v$, максимум $K - 1$ ненулевых направлений (ранг $S_B \leq K - 1$, т.к. K векторов отклонений μ_k от общего среднего линейно зависимы).

Фишка на собеседе

LDA $\neq$ PCA: PCA отвечает «где данные больше всего меняются» (unsupervised), LDA/Фишер — «где классы больше всего отличаются» (supervised). Два вытянутых параллельных облака классов, сдвинутых ПЕРПЕНДИКУЛЯРНО направлению вытянутости — PCA выберет ось вытянутости (max дисперсия) и классы схлопнутся при проекции; LDA найдёт ось разделения. LDA имеет ДВЕ роли: (1) классификатор (основное назначение, Фишер 1936); (2) снижение размерности (проекция на найденные направления, до $K - 1$ измерений) — побочный продукт той же математики, не два разных метода. LDA vs логрег при нарушении гауссовости: логрег не оценивает μ, Σ вообще (устойчивее к выбросам/скошенности); LDA оценивает их через выборочные среднее/ковариацию — НЕ робастные статистики (как MSE, билет 8), выброс искажает оценку $\Rightarrow$ систематически смещённая (не «взрывающаяся») граница.

Билет 40. SVM: принцип оптимальной разделяющей гиперплоскости

Определение: Модель и ширина полосы

$a(x) = \text{sign}(\langle w, x \rangle - w_0)$. Нормировка (всегда возможна масштабированием w, w_0): $\min_i M_i = 1$. Ширина полосы = $2 / \|w\|$.

Вывод ширины

x_+ на границе: $\langle w, x_+ \rangle - w_0 = 1$; x_- : $\langle w, x_- \rangle - w_0 = -1$. Разность: $\langle w, x_+ - x_- \rangle = 2$. Ширина = проекция на нормированное направление: $\langle w / \|w\|, x_+ - x_- \rangle = 2 / \|w\|$.

Теорема: Принцип максимального зазора

$$\frac{1}{2} \|w\|^2 \rightarrow \min \text{ при } M_i \geq 1 \ \forall i.$$

Выпуклая QP-задача (билет 17), единственный глобальный минимум.

Пример: «1» — нормировка, не реальное расстояние

Сырые w', w'_0 , минимальный отступ $M' = 0.05$ (классы близко). Делим: $w = w' / 0.05$, $w_0 = w'_0 / 0.05$ — гиперплоскость та же, но теперь $\min M = 1$. Реальная ширина $2 / \|w\|$ — если исходное расстояние было 0.1, получим ИМЕННО $2 / \|w\| = 0.1$. Число «1» — инструмент параметризации, вся геометрия закодирована в $\|w\|$.

Фишка на собесе

Опорные векторы — объекты на границе полосы ($M_i = 1$), задача решается по строгой выпуклости $\frac{1}{2} \|w\|^2$ (гессиан = $I \succ 0$) $\Rightarrow$ решение w ЕДИНСТВЕННО, даже если между кластерами широкий пустой промежуток (кажется, что много просто разделяющих линий, но конкретно МАКСИМАЛЬНО широкая полоса — одна).

Билет 41. SVM: мягкий зазор и hinge loss

Определение: Slack-переменные

$$M_i \geq 1 - \xi_i, \ \xi_i \geq 0. \quad \frac{1}{2} \|w\|^2 + C \sum_i \xi_i \rightarrow \min.$$

Вывод безусловной формы

Для фикс. w оптимально $\xi_i^* = \max(0, 1 - M_i) = (1 - M_i)_+$ (минимально допустимое). Подставляем и делим на C (не меняет argmin):

$$\frac{1}{2} \|w\|^2 + C \sum_i (1 - M_i)_+ \rightarrow \underbrace{\sum_i (1 - M_i)_+}_{\text{hinge loss}} + \underbrace{\frac{1}{2C} \|w\|^2}_{\text{L2-регуляризатор}}.$$

Теорема: Универсальный шаблон Loss+Regularizer

МНК: $(y - w^\top x)^2$ + ничего. Ridge: $(y - w^\top x)^2 + \tau \|w\|^2$. Логрег: кросс-энтропия + $\tau \|w\|^2$ (опц).
SVM: hinge + $\frac{1}{2C} \|w\|^2$. Меняется ТОЛЬКО loss (что штрафует), регуляризатор $\|w\|^2$ работает одинаково везде (билеты 4/11/13).

Фишка на собеседе

Направление C (частая путаница!): C большой $\Rightarrow 1/(2C) \rightarrow 0 \Rightarrow$ регуляризация СЛАБАЯ $\Rightarrow$ модель гонится за точной подгонкой (как жёсткий зазор) $\Rightarrow$ ПЕРЕОБУЧЕНИЕ (bias $\downarrow$, variance $\uparrow$). C маленький $\Rightarrow 1/(2C)$ большой $\Rightarrow$ регуляризация СИЛЬНАЯ $\Rightarrow$ НЕДООБУЧЕНИЕ (bias $\uparrow$, variance $\downarrow$). Правило: смотри на коэффициент при РЕГУЛЯРИЗАТОРЕ ($1/(2C)$), а не при C напрямую — C в исходной форме стоит при loss, не при штрафе за сложность. Предел $C \rightarrow \infty$: $1/(2C) \rightarrow 0 \Rightarrow \sum (1 - M_i)_+ \rightarrow \min$ (регуляризатор выключен) $\Rightarrow$ для разделимых данных это условие $M_i \geq 1 \forall i$ — в точности жёсткий зазор (билет 40).

Билет 42. SVM: двойственная задача и опорные векторы

Определение: Ключевой результат (из Лагранжиана, детали опущены)

$$w = \sum_i \alpha_i y_i x_i, \quad 0 \leq \alpha_i \leq C, \quad \sum_i \alpha_i y_i = 0.$$

Опорный вектор = объект с $\alpha_i \neq 0$. Финальный классификатор:

$$a(x) = \text{sign} \left(\sum_i \alpha_i y_i \langle x, x_i \rangle - w_0 \right).$$

Primal vs dual

Primal (билеты 40–41): минимизация по w (m переменных). Dual: та же задача, переформулированная по α (n переменных), через Лагранжиан. Одинаковый финальный ответ, но dual вскрывает: x входит ТОЛЬКО через $\langle x_i, x_j \rangle$ — точка входа для kernel trick (билет 43).

ККТ-типизация (кратко)

$\alpha_i = 0$: периферийный ($M_i > 1$, не влияет). $0 < \alpha_i < C$: опорный-граничный ($M_i = 1$). $\alpha_i = C$: опорный-нарушитель ($M_i < 1$). При $C \rightarrow \infty$ верхняя граница $\alpha_i \leq C$ исчезает — нет «нарушителей» по построению (жёсткий зазор не допускает нарушений вообще).

Фишка на собеседе

Мало опорных векторов (напр. 200 из 10^6) — чистое разделение, быстрый инференс (сумма по ~ 200 слагаемым). МНОГО опорных (напр. 900k из 10^6) — классы сильно перекрываются/данные зашумлены, И инференс становится медленным (сумма по 900k термов) — SVM теряет главное практическое преимущество; на таких данных чаще выбирают бустинг (билет 57–58).

Билет 43. Ядра в SVM и спрямляющие пространства

Прямое применение билета 34

$$a(x) = \text{sign} \left(\sum_i \alpha_i y_i K(x, x_i) - w_0 \right).$$

Линейное $K = \langle x, y \rangle$; полиномиальное $(\langle x, y \rangle + 1)^d$; RBF $\exp(-\|x - y\|^2 / 2\sigma^2)$ (бесконечномерное пространство, теорема Мерсера, билет 34).

Фишка на собесе

SVM+RBF $\approx$ двухслойная RBF-сеть: «нейроны» первого слоя центрированы в опорных векторах x_i (число нейронов = число опорных векторов, определяется ДАННЫМИ при обучении, а не архитектурой заранее, в отличие от обычной нейросети); второй слой — линейная комбинация с весами $\alpha_i y_i$. Малое σ (большое $\gamma = 1/2\sigma^2$): $K(x, x_i) \rightarrow 0$ для почти всех пар (не схлопывание — ИЗОЛЯЦИЯ каждой точки). (а) число опорных векторов РАСТЁТ (почти каждая точка нужна отдельно, нет обобщения между ними); (б) жёсткое ПЕРЕОБУЧЕНИЕ (похоже на 1-NN, границы-«пузыри» вокруг каждой точки). Прямая параллель с σ_i в t-SNE (билет 35) — тот же тип параметра «bandwidth»: малое σ — гипер-локальность/переобучение в обоих алгоритмах, большое — сглаживание/недообучение.

Билет 44. Метод k ближайших соседей (kNN)

Определение: Непараметрический, ленивый метод

Нет фазы обучения («обучение» = запомнить train). Классификация: голосование k ближайших соседей (нечётное k , веса $\propto 1/d$). Регрессия: усреднение. Метрики: евклидова, косинусная, Хэмминга.

Критично масштабирование

Без него признак большого диапазона доминирует в евклидовом расстоянии (билет 9).

Проклятие размерности

В высокой размерности $\min(\text{расст.}) / \max(\text{расст.}) \rightarrow 1$ — «ближайший» и «дальний» сосед становятся неразличимы, понятие близости теряет смысл. Ускорение: k-d деревья ($O(\log n)$ вместо $O(n \cdot d)$ в среднем, тоже деградируют при очень высокой d).

Фишка на собесе

РСА перед kNN vs UMAP перед kNN — реальный компромисс, не односторонняя победа. RSA: сохраняет ГЛОБАЛЬНУЮ дисперсию, не гарантирует сохранение ЛОКАЛЬНЫХ соседств (может «сломать» именно то, что нужно kNN), но даёт дешёвую точную проекцию новых запросов ($x_{\text{new}} \cdot \text{Rot}$). UMAP: специально со-

хранит локальную структуру (то, что нужно kNN), но out-of-sample для новых точек дороже/приближённое (билет 35) — а kNN ПОСТОЯННО получает новые запросы. Нет универсального победителя, сравнивать на валидации.

Билет 45. Наивный байесовский классификатор

Определение: Наивное предположение

$$p(y, x) = p(y) \prod_i p(x_i|y)$$

— условная независимость признаков при заданном классе. Радикально упрощает: вместо полной $p(x|y)$ (билет 39, LDA) — m одномерных $p(x_i|y)$, требует намного меньше данных.

Сглаживание Лапласа = MAP-оценка (закрывает билет 9)

MLE: $\hat{\theta} = \text{count} / \text{count}_{\text{tot}}$ — проблема: один нулевой множитель в $\prod_i p(x_i|y)$ обнуляет ВСЮ вероятность класса. Лаплас: $\hat{\theta} = \frac{\text{count} + 1}{\text{count}_{\text{tot}} + M}$ — это MAP с равномерным (Dirichlet($\alpha, \dots, \alpha$), $\alpha = 1$) априорным:

$$\hat{\theta}_{\text{MAP}} = \frac{\text{count} + \alpha}{\text{count}_{\text{tot}} + M\alpha}.$$

α — «псевдо-счётчик», будто видели α наблюдений каждого значения ДО данных. $\alpha \rightarrow 0$: чистая MLE. $\alpha \rightarrow \infty$: оценка $\rightarrow 1/M$ (равномерное, данные полностью игнорируются). **Target encoding (билет 9)** — та же конструкция: $\text{encoded} = \frac{n_{\text{cat}} \cdot \text{mean}_{\text{cat}} + \alpha \cdot \text{global_mean}}{n_{\text{cat}} + \alpha}$. При $n_{\text{cat}} \rightarrow \infty$ — чистое mean_{cat} ; при $n_{\text{cat}} \rightarrow 0$ — global_mean (не доверяем шумной оценке по паре наблюдений).

Фишка на собеседе

Naive Bayes vs логрег — та же дихотомия generative/discriminative, что LDA vs логрег (билет 39). NB: ВЫСОКИЙ bias (неверное предположение независимости, не убывает с n), НИЗКИЙ variance (мало параметров, стабильные оценки даже на малых выборках). Логрег: НИЗКИЙ bias, ВЫСОКИЙ variance при малых n . С ростом n variance логрег ПАДАЕТ (билет 21, ЗБЧ) и в какой-то момент становится меньше фиксированного bias NB — логрег обгоняет. На МАЛЫХ данных NB часто лучше именно из-за низкого variance, компенсирующего bias.

Билет 46. Многоклассовая классификация: OvA, OvO, softmax

Определение: Три подхода

OvA: K классификаторов (класс k vs остальные). Минус: неоднозначные зоны, дисбаланс 1 vs $K-1$. **OvO**: $K(K-1)/2$ классификаторов (все пары), голосова-

ние. Минус: квадратичный рост числа моделей. **Softmax**: единая модель, $P_j = \frac{\exp(c_j(x))}{\sum_y \exp(c_y(x))}$ — нормирует в НАСТОЯЩЕЕ распределение ($\sum P_j = 1$, все ≥ 0) $\Rightarrow$ ровно один класс с максимумом, нет неоднозначных зон в принципе. Прямое обобщение логрег ($K = 2 \Rightarrow$ сигмоида). Обучение — кросс-энтропия (билет 22).

Micro vs macro усреднение (метрики, разбор в разделе 6)

Micro: суммируем TP/FP/FN по всем классам, одна общая метрика — крупные классы доминируют. Macro: считаем метрику отдельно по классу, среднее — каждый класс равный вес, важно при дисбалансе (билет 50).

Раздел 6. Метрики классификации

Билет 47. Матрица ошибок: Accuracy, Precision, Recall

Определение: Confusion matrix

TP/FP/FN/TN — четыре числа, из которых строятся все метрики раздела. FP — ошибка I рода (ложная тревога), FN — ошибка II рода (пропуск цели); та же терминология, что в статтестах (билет 87).

$$\text{Accuracy} = \frac{TP + TN}{TP + FP + FN + TN}, \quad \text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}.$$

Замечание: Precision $\neq$ Recall — частая путаница в формулах

Precision — про ПРЕДСКАЗАНИЯ (знаменатель $TP + FP$ = всё, что модель НАЗВАЛА positive). Recall — про РЕАЛЬНОСТЬ (знаменатель $TP + FN$ = всё, что РЕАЛЬНО positive). Не путать местами.

Пример: Accuracy-ловушка при дисбалансе

Детектор мошенничества, 1% Positive из 10000. Модель, всегда говорящая «не мошенничество»: TP=0, FN=100, TN=9900. Accuracy=9900/10000=99%, но модель бесполезна — поймала 0 мошенников.

Аналогия — металлоискатель

Precision — не пишит на мусор (мало FP). Recall — прочесал весь пляж (не пропустил ни одной монеты). Независимые оси: можно быть точным, но неполным, и наоборот.

Когда что важнее

Антиспам — Precision (пропустить спам не страшно, пометить важное письмо как спам дорого). Скрининг рака — Recall (пропуск больного смертелен, ложная тревога — просто лишнее обследование).

Фишка на собеседе

Micro vs macro (с числами): 3 класса, A(900 объектов, $P=0.983$), B(50, $P=0.25$), C(50, $P=0.242$). Macro-P = $(0.983 + 0.25 + 0.242)/3 \approx 0.492$ (штрафует за плохие редкие классы поровну). Micro-P = $(880+10+8)/(898+70) \approx 0.928$ (частый класс A доминирует в сумме, прячет провал на B,C). Разница почти вдвое — одна модель, разное число. **Weighted average** (третий способ, билет 50): вес каждого класса = n_k/N (не $1/K$ как macro). Weighted-P = $0.9 \cdot 0.983 + 0.05 \cdot 0.25 + 0.05 \cdot 0.242 \approx 0.909$ — ближе к micro, тоже смещён к частому классу, sklearn выдаёт это по умолчанию в classification_report. **Совпадения метрик**: Precision=Recall $\Leftrightarrow FP = FN$ (равные знаменатели). Accuracy=Recall $\Leftrightarrow$ нет Negative-класса ($FP=TN=0$). Precision=Accuracy, если модель предсказывает всех Positive (оба = $P/(P+N)$, базовая доля класса).

Билет 48. F-мера и баланс точности/полноты**Определение: F1** — гармоническое, не арифметическое среднее

$$F_1 = \frac{2PR}{P+R}.$$

Пример: Почему гармоническое

$P=1, R=0$: арифметическое $(1+0)/2 = 0.5$ (обманчиво «средне»). Гармоническое $2 \cdot 1 \cdot 0 / (1+0) = 0$ (честно — модель бесполезна, ничего не находит). Гармоническое $\leq$ арифметическому всегда, разрыв растёт с перекосом P и R .

Определение: Обобщённая F_β

$$F_\beta = \frac{(1 + \beta^2)PR}{\beta^2 P + R}.$$

$\beta=1$: равный вес. $\beta>1$ (напр. $\beta=2$): Recall важнее, при $\beta \rightarrow \infty: F_\beta \rightarrow R$. $\beta<1$ (напр. 0.5): Precision важнее, при $\beta \rightarrow 0: F_\beta \rightarrow P$.

Фишка на собесе

Переход от F1-оптимального порога к F2-оптимальному: порог СНИЖАЕТСЯ (Recall растёт при снижении порога, билет 47/mid) — т.к. F2 весит Recall сильнее, оптимум сдвигается туда, где Recall выше, жертвуя Precision. Cost-sensitive порог: $t^* = \text{Cost}(FP) / (\text{Cost}(FP) + \text{Cost}(FN))$ — если FN в 4 раза дороже FP, $t^* = 1/5 = 0.2$ (низкий, модель «подозрительна»).

Билет 49. ROC-кривая, AUC и PR-кривая**Определение: Оси ROC**

$$\text{TPR} = \text{Recall} = \frac{TP}{TP + FN}, \quad \text{FPR} = \frac{FP}{FP + TN} = \frac{FP}{N}.$$

Каждая точка кривой — результат ОДНОГО конкретного порога (порог — скрытый параметр, не ось графика).

Пример: Построение по шагам (5 объектов)

A(0.9,Pos), B(0.7,Neg), C(0.6,Pos), D(0.4,Neg), E(0.2,Neg). Порог 1.0 $\rightarrow$ (0,0). Порог 0.8 (только A) $\rightarrow$ TPR=0.5, FPR=0 $\rightarrow$ (0,0.5). Порог 0.65 (A,B) $\rightarrow$ (0.33,0.5). Порог 0.5 (A,B,C) $\rightarrow$ (0.33,1.0). Порог 0 $\rightarrow$ (1,1). Кривая идёт ВВЕРХ при захвате Positive, ВПРАВО при захвате Negative.

Теорема: AUC-ROC — вероятностная интерпретация

AUC = вероятность, что случайный Positive получит БОЛЬШИЙ score, чем случайный Negative = доля пар (Positive, Negative), где Positive выиграл (статистика

Манна–Уитни). На примере выше: $2 \text{ Positive} \times 3 \text{ Negative} = 6$ пар, 5 из 6 — Positive выиграл $\Rightarrow \text{AUC} = 5/6 \approx 0.833$ — совпадает с геометрической площадью. Инвариантна к дисбалансу базовых долей (TPR считается только среди Positive, FPR только среди Negative).

Зачем AUC, если «не всегда надо»

Сравнение моделей ДО выбора порога (фундаментальная способность ранжировать); порог не известен заранее или меняется по контексту; ранняя стадия разработки без зафиксированных бизнес-требований.

Фишка на собеседе

PR-кривая при сильном дисбалансе: 100 Positive, 10000 Negative, 90 TP/200 FP. $\text{FPR} = 200/10000 = 0.02$ (крошечная доля от ОГРОМНОГО N) — ROC выглядит отлично. $\text{Precision} = 90/290 \approx 0.31$ (те же 200 FP — ОГРОМНАЯ доля от маленького пула предсказанных positive 290). Одинаковые 200 ошибок тонут в одном знаменателе ($N=10000$) и доминируют в другом ($\text{TP}+\text{FP}=290$) — источник расхождения ROC-AUC (оптимистичный) и Precision (реалистичный) при дисбалансе.

Билет 50. Дисбаланс классов: методы борьбы

Определение: Методы на уровне данных

Undersampling — прореживаем мажоритарный класс (теряем информацию). **Oversampling** — дублируем миноритарный (риск переобучения на копиях). **SMOTE**: синтетические точки $x_{\text{new}} = x_i + \lambda(x_{\text{сосед}} - x_i)$, $\lambda \in (0, 1)$ — интерполяция между реальным объектом и его k ближайшим соседом ТОГО ЖЕ класса (kNN-механизм, билет 44). $\lambda=0 \rightarrow x_i$, $\lambda=1 \rightarrow$ сосед — отрезок между ними. Разнообразие вместо точных копий, снижает (не убирает) риск переобучения.

Определение: Методы на уровне алгоритма

Взвешивание классов в loss ($w_{\text{Positive}} \gg w_{\text{Negative}}$ при редком Positive, `class_weight='balanced'`); подбор порога (билет 48, без изменения данных вообще).

Метрики при дисбалансе

НЕ Ассигасу (ловушка, билет 47), НЕ ROC-AUC как единственная (билет 49, оптимистичный обман). ДА: PR-AUC, F_β , подбор порога под целевую метрику.

Почему LDA/QDA страдают меньше

LDA моделирует $P(C_k)$ ЯВНО, отдельным параметром (доля класса в выборке) — не искажает оценку формы $p(x|C_k)$ (μ_k, Σ_k). Дисбаланс сдвигает только порог решения через Байеса, не портит оценку параметров редкого класса САМОГО ПО СЕБЕ (если данных всё же достаточно для оценки μ, Σ). Дискриминативные модели (логрег, SVM) оптимизируют агрегированный по ВСЕМ объектам loss — редкий класс «задавлен» вкладом частого в сумму градиента.

Фишка на собесе

Метрики (PR-AUC, macro-F1) $\neq$ LDA — разные слои проблемы, не взаимозаменяемы. Метрика нужна ВСЕГДА, чтобы честно ИЗМЕРИТЬ проблему, независимо от алгоритма. LDA лишь МОЖЕТ смягчить обучение изнутри, но не спасает при катастрофической нехватке данных редкого класса (даже μ, Σ станут шумными при n в единицы объектов, билет 39). SMOTE вокруг ВЫБРОСОВ миноритарного класса: если выброс далеко от остальных миноритарных точек, его «ближайшие» соседи всё равно далеко — SMOTE генерирует синтетические точки ВДОЛЬ ДЛИННОГО отрезка, который может пройти ЧЕРЕЗ территорию мажоритарного класса, создавая ложные миноритарные объекты внутри чужой области — портит границу решения, а не просто «добавляет облако».

Билет 51. Калибровка классификаторов**Определение: Определение**

Среди объектов с $\hat{p}(x) = 0.2$ реальная доля Positive $\approx 20\%$: $P(y=1 \mid \hat{p}(x)=p) \approx p$. НЕ то же самое, что точность ранжирования (AUC) — модель может идеально ранжировать, но иметь искажённые абсолютные значения p .

Недо-/переуверенность

Overconfident: говорит $p=0.99$, реально верно 70% (порядок правильный, число — нет).
Underconfident: говорит $p=0.6$, реально 90%.

Определение: Оценка калибровки

Reliability diagram: бины по $\hat{p}$, для каждого — среднее предсказанное vs реальная доля Positive. Идеал — диагональ $y=x$. **Brier score** $= \frac{1}{n} \sum (p_i - y_i)^2$ (MSE вероятности против бинарной истины). **ECE** — взвешенная сумма |предсказано—реально| по бином, одно число.

Определение: Методы калибровки (постфактум, на отдельной validation, билет 23)

Platt scaling: $p_{\text{cal}} = \sigma(A \cdot \text{score} + B)$ — доп. логрег поверх сырого score. **Изотоническая регрессия:** гибкая монотонная ступенчатая функция, требует больше данных. **Temperature scaling** (нейросети): $p = \text{softmax}(z/T)$, один параметр T .

Пример: Идеальный AUC, катастрофическая калибровка

A($y=0$, score=0.90), B($y=1$, score=0.95), C($y=1$, score=0.99). AUC=1.0 (обе пары упорядочены верно: $0.95 > 0.90$, $0.99 > 0.90$). Но A — РЕАЛЬНО Negative, а модель даёт $p=0.90$ (90% уверенность в обратном) — калибровка провалена. AUC заботится ТОЛЬКО о порядке, игнорирует абсолютные значения: домножь все score на что угодно монотонное — AUC не изменится, а как вероятности числа станут нелепыми.

Фишка на собеседе

Логрег калибрована из коробки: log-loss НАПРЯМУЮ штрафует за плохую калибровку (MLE, билет 10, это и есть задача получить верные вероятности). SVM: hinge loss заботится только о знаке и зазоре M , score — геометрическая величина (расстояние до гиперплоскости), не создавалась как вероятность. Деревья/бустинг: вероятность в листе = доля класса среди попавших туда объектов — при малом листе шумная и часто крайняя (0 или 1). Random Forest: усреднение по деревьям обычно сжимает предсказания к 0.5 сильнее нужного — типичная недоуверенность.

Раздел 7. Деревья и ансамбли

Билет 52. Решающие деревья: ID3 и информативность

Определение: Энтропия и Information Gain

$$H(S) = - \sum_k p_k \log_2 p_k, \quad IG(S, j) = H(S) - \sum_v \frac{|S_v|}{|S|} H(S_v).$$

H — неопределённость по классам ($H=0$ чисто, $H=\log_2 K$ максимум). ID3 жадно выбирает признак/порог, максимизирующий IG на каждом шаге. Сложность $O(Bhn)$ (B признаков, h высота, n объектов).

Пример: Числовой пример

S : 10 объектов (6A,4B), $H(S) \approx 0.971$ бит. Разбили: S_{left} (5A,0B) $H=0$; S_{right} (1A,4B) $H \approx 0.722$. $IG = 0.971 - 0.5 \cdot 0.722 \approx 0.61$ бит — хорошее разбиение.

Фишка на собеседе

ID-признак и IG: если $|S_v|=1$ для каждого подмножества — $H(S_v)=0$ ВСЕГДА (одна точка = ноль неопределённости) $\Rightarrow IG = H(S) - 0 = H(S)$ — МАКСИМАЛЬНО возможное значение. ID3 жадно выберет такой признак, хотя он бесполезен (новый объект не имеет такого ID) — классическая ловушка переобучения через IG. **XOR-контрпример (жадность ID3):** $y = [\xi_1 \xi_2 > 0]$ (шахматный узор). Идеальное дерево существует (спросить знак ξ_1 , потом ξ_2), но разбиение по ОДНОМУ ξ_1 в корне даёт $IG = 0$ (классы поровну в каждой половине) — ID3 никогда не выберет этот путь, близорук к взаимодействующим признакам. **Look-ahead:** строить пробное поддерево глубины h для кандидата, выбирать по итоговой ошибке — решает XOR, но дорого.

Билет 53. Критерии ветвления и редукция деревьев

Определение: Индекс Джини (CART)

$$\text{Gini}(S) = \sum_k p_k(1 - p_k) = 1 - \sum_k p_k^2.$$

Не требует логарифма — быстрее энтропии. Смысл: вероятность неверно классифицировать объект при случайной метке по распределению p_k . Для регрессии — уменьшение дисперсии в листьях.

Pre-pruning vs Post-pruning

Pre-pruning: ранний останов, если $IG < I_0$ для всех кандидатов. МЕНЕЕ эффективна: жадное ветвление и так неоптимально (XOR-пример), pre-pruning углубляет ту же близорукость на уровне «когда остановиться». **Post-pruning:** стро-

им полное дерево, берём контрольную выборку X_k ($\approx 30\%$, стратифицированную), прогоняем через дерево. Для каждого узла v считаем 4 варианта ошибок на S_v : (1) $r(v)$ — оставить поддерево; (2) $r_L(v)$ — заменить левым поддеревом; (3) $r_R(v)$ — заменить правым; (4) $r_c(v)$ — заменить листом класса $c = \arg \min_c r_c(v)$. Выбираем минимум.

Фишка на собеседе

Зачем 4 варианта, не 2 (сохранить/лист): реальные деревья асимметричны — одна ветка L_v хорошо обобщает (валидирована контролем), другая R_v — шум (мало контрольных объектов, высокая ошибка). Схлопывание в ОДИН лист выбрасывает полезную структуру L_v . Замена НА L_v (выбросить только R_v) сохраняет полезную часть, отбрасывая только шумную.

Билет 54. Композиции алгоритмов и голосование

Определение: Общая формула композиции

$$a(x) = C(F(b_1(x), \dots, b_T(x))).$$

b_t — базовые алгоритмы, F — корректирующая операция, C — решающее правило. Взвешенное голосование: $a(x) = C(\sum_t \alpha_t b_t(x))$, выпукло при $\alpha_t \geq 0, \sum \alpha_t = 1$.

Теорема: Условие пользы композиции

(а) базовые ЛУЧШЕ случайного; (б) базовые РАЗНЫЕ — «нет смысла складывать одинаковые алгоритмы». Компенсация ошибок работает только если разные b_t ошибаются на РАЗНЫХ объектах.

Три стратегии различности

Перевзвешивание объектов (бустинг, последовательно); случайные подвыборки/подпространства (бэггинг/RSM, параллельно); случайные инициализации/стохастическая оптимизация (нейросети).

Обучение весов α_t и фильтрация плохих алгоритмов

Если T базовых уже построены, вектор $(b_1(x), \dots, b_T(x))$ можно взять как НОВОЕ признаковое описание объекта и обучить α_t любым линейным методом (Фишер, логрег, SVM) поверх него. SVM предпочтителен — максимизирует зазор (билет 40), даёт более надёжную классификацию. Желательно ограничение $\alpha_t \geq 0$: отрицательный α_t означает, что b_t настолько ненадёжен, что его ответы стоило бы инвертировать — такой алгоритм разумнее просто исключить ($\alpha_t=0$), а не использовать с обратным знаком.

Фишка на собеседе

Эмпирическое сравнение: бустинг лучше на БОЛЬШИХ выборках, сложные границы классов. Бэггинг/RSM лучше на КОРОТКИХ выборках. RSM безусловно лучше при признаков>объектов и/или много шумовых признаков. Бэггинг/RSM

параллелятся, бустинг — строго последовательно.

Билет 55. Бэггинг и случайный лес (Random Forest)

Определение: Bootstrap aggregating

T подвыборок длины ℓ с возвращением, базовые обучаются НЕЗАВИСИМО, простое голосование. Доля уникальных объектов: $(1 - 1/\ell)^\ell \rightarrow e^{-1} \approx 0.368$ не попадают $\Rightarrow \approx 63.2\%$ уникальных попадают.

Почему снижает именно VARIANCE

$$\text{Var}\left(\frac{1}{T} \sum b_t\right) = \rho\sigma^2 + \frac{(1-\rho)\sigma^2}{T}.$$

$\rho \rightarrow 0$ (независимые деревья): второе слагаемое доминирует, $\text{Var} \rightarrow 0$ с ростом T .
 $\rho \rightarrow 1$ (одинаковые деревья): $\text{Var} = \sigma^2$, T не помогает. Bias почти НЕ меняется: bias среднего = среднее bias — систематическое смещение усреднением не лечится. Отсюда: бэггинг эффективен ТОЛЬКО для моделей с низким bias/высоким variance (глубокие деревья).

ООВ и Random Forest

ООВ $\approx 36.8\%$ объектов не попали в подвыборку b_t — бесплатная контрольная выборка именно для него, встроенный аналог CV без явного split. RF = бэггинг ГЛУБОКИХ деревьев + случайные $\sqrt{n}$ признаков в КАЖДОЙ вершине — декорреляция (снижает ρ), т.к. без этого все деревья использовали бы один и тот же сильный признак в корне.

Фишка на собесе

Почему рандомизация признаков именно В КАЖДОЙ вершине, не раз на дереве: фиксация на старте — ОДНА попытка поймать значимый признак (может не повезти, дерево «мёртвое»). Рандомизация в каждой вершине — МНОГО независимых попыток внутри одного дерева, вероятность что значимый признак НИКОГДА не попадёт ни в один набор экспоненциально мала. Feature importance: gain (mean decrease impurity) — быстро, но смещена к высококардинальным признакам (та же проблема, что у IG в ID3). Permutation importance — дороже, но честная (портим один признак, смотрим падение качества).

Билет 56. Бустинг: AdaBoost

Определение: Композиция и веса

$$a(x) = \text{sign}\left(\sum_t \alpha_t b_t(x)\right), \quad w_i \leftarrow w_i \cdot \exp(-\alpha_t y_i b_t(x_i)).$$

Ошибся на $i \Rightarrow$ множитель $e^{\alpha_t} > 1$ (вес растёт). Угадал $\Rightarrow e^{-\alpha_t} < 1$ (вес падает).

Вывод α_T

Аппроксимация $[M < 0] \leq e^{-M}$. $Q_T = e^{-\alpha}P + e^{\alpha}N + (1-P-N)Q_{T-1}$ (P, N — взвешенные доли верных/ошибок). Дифференцируя по α :

$$\alpha_T = \frac{1}{2} \ln(P/N), \quad \text{без отказов: } \alpha_T = \frac{1}{2} \ln \frac{1-N}{N}.$$

Условие: существует b лучше случайного ($P > N$). Сходимость геометрическая: $Q_T = Q_{T-1}(1 - (\sqrt{P} - \sqrt{N})^2)$.

Фишка на собесе

Чувствительность к выбросам (закрывает билет 37/hard): настоящий выброс ошибочно классифицируется КАЖДЫЙ раунд $\Rightarrow$ вес умножается на e^{α_t} каждый раз $\Rightarrow$ растёт ЭКСПОНЕНЦИАЛЬНО по числу раундов, быстро доминируя над нормальными объектами. Причина — e^{-M} растёт быстрее всех $\varphi(M)$ при $M \rightarrow -\infty$ (билет 37). Лечение: фильтрация по весам после ~ 20 раундов; shrinkage; замена на hinge/LogitBoost (растут ЛИНЕЙНО, не экспоненциально, при отрицательном M — НЕ «аннулируются», просто мягче).

Билет 57. Градиентный бустинг

Определение: Обобщение (Фридман) — градиентный спуск В ПРОСТРАНСТВЕ ФУНКЦИЙ

$$-g_i = -\frac{\partial L(a_{T-1}(x_i), y_i)}{\partial a}, \quad b_T = \arg \min_b \sum_i (b(x_i) + g_i)^2, \quad \gamma_T = \arg \min_{\gamma} \sum_i L(a_{T-1}(x_i) + \gamma b_T(x_i),$$

b_T — НЕ предсказывает y , а приближает антиградиент (псевдоостаток) через МНК. Для MSE: $-g_i = y_i - a_{T-1}(x_i)$ — обычная невязка (билет 2).

Для классификации

$a(x)$ — непрерывный score (как log-odds логрег, билет 38), финальный класс через sign/ σ . При логистическом L : $-g_i = y_i - \sigma(a(x_i))$ — структурно как градиент логрега.

AdaBoost = частный случай (Фридман)

При $L = e^{-ya}$: антиградиент $\propto y_i w_i$ (веса AdaBoost); МНК-приближение b_T эквивалентно минимизации взвешенной ошибки классификации $N(b; W)$; оптимальный γ_T сводится к $\alpha_T = \frac{1}{2} \ln \frac{1-N}{N}$.

Фишка на собесе

Почему база — деревья, не линейные модели: сумма линейных функций остаётся линейной, нет прироста выразительности с раундами (нарушает условие «разные», билет 54). Почему GB обобщается на регрессию/ранжирование, а AdaBoost — нет: AdaBoost жёстко завязан на понятие «объект классифицирован неверно» (бинарно) — перевзвешивание не имеет смысла для непрерывной ошибки регрессии. GB

заменяет это на регрессионную подзадачу (предсказать число-антиградиент по МНК) — имеет смысл для ЛЮБОЙ дифференцируемой L , независимо от типа задачи.

Билет 58. XGBoost, LightGBM, CatBoost

	XGBoost	LightGBM	CatBoost
Рост дерева	level-wise	leaf-wise (best-first)	level-wise, ОДИН вопрос на весь уровень (oblivious)
Кривизна	Тейлор 2-го порядка (град.+гессиан)	градиент (1-й порядок)	градиент (1-й порядок)
Регуляризация	$\gamma \cdot \# \text{листьев} + \frac{1}{2} \lambda \sum w^2$ в целевой функции	ограничение num_leaves/depth	простота oblivious-структуры
Категории	ручной препроцессинг	нативно, оптимальное разбиение на 2 группы	ordered target statistics (без утечки)
Скорость	средняя	самая быстрая (GOSS+EFB)	медленнее (неск. моделей)

Пример: Ordered Target Statistic — числовой пример

Случайная перестановка: x_3 (Москва, $y=1$), x_1 (СПб, 0), x_5 (Москва, 0), x_2 (Москва, 1), x_6 (СПб, 1), x_4 (Москва, 0). Для x_5 : среди Москвы РАНЬШЕ него — только $x_3(1) \Rightarrow \text{TS}=1.0$. Для x_2 : раньше $x_3(1), x_5(0) \Rightarrow \text{TS}=0.5$. Для x_4 : раньше $x_3(1), x_5(0), x_2(1) \Rightarrow \text{TS}=0.667$. Одна категория «Москва» — РАЗНЫЕ числа у разных объектов (честно, без утечки, в отличие от наивного target encoding с одним числом на категорию, билет 9).

Зачем oblivious-деревья (не только скорость)

Обычное дерево глубины 3: до 7 РАЗНЫХ узлов-решений. Oblivious той же глубины: только 3 (один на уровень) при том же числе листьев (8) — намного меньше степеней свободы на одно дерево $\Rightarrow$ меньше риск переобучения рег-дерево, идеально сочетается с философией бустинга (слабые базовые алгоритмы, билет 54). Плюс векторизованный инференс (все объекты проверяют один вопрос сразу).

Фишка на собеседе

GBDT vs Random Forest: RF снижает VARIANCE (параллельно, усреднение независимых глубоких деревьев). GBDT снижает BIAS (последовательно, каждое дерево уменьшает остаток предыдущих) — НЕТ механизма усреднения независимых оценок (в отличие от бэггинга формулы $\text{Var} = \rho\sigma^2 + (1 - \rho)\sigma^2/T$), поэтому variance у бустинга НЕ гасится естественно, и без регуляризации (shrinkage/early stopping) растёт с числом раундов — требует ручного контроля, в отличие от RF. Контр-пример «качество на тесте растёт после нулевой train-ошибки»: margin theory

— бустинг продолжает УВЕЛИЧИВАТЬ отступ M уже верно классифицированных объектов даже после $\text{train-ошибки}=0$, что улучшает обобщение отдельно от bias/variance игры.

Билет 59. Стэкинг и блендинг

Определение: Обучаемая комбинация вместо фиксированного голосования

Идея: вместо константных весов α_t (билет 54) — обучаем МЕТА-модель M , которая сама решает, как комбинировать предсказания базовых $b_1, \dots, b_T$: $a(x) = M(b_1(x), \dots, b_T(x))$. Мета-модель обычно простая (логрег, линейная регрессия) — сложность уже «упакована» в базовые модели.

Алгоритм стэкинга по шагам (K-fold OOF)

1. Разбить train на K фолдов (билет 23).
2. Для каждой базовой модели b_t и каждого фолда k : обучить b_t на $K-1$ фолдах, предсказать $b_t(x)$ для объектов ИМЕННО фолда k (они не участвовали в обучении).
3. После прохода по всем K фолдам — у КАЖДОГО train-объекта есть OOF-предсказание каждой b_t (полученное моделью, которая его не видела).
4. Эти OOF-предсказания $(b_1(x), \dots, b_T(x))$ — новые признаки; обучаем мета-модель M на них против истинных y .
5. Для новых объектов: переобучить b_t на ВСЕХ train-данных, получить их предсказания, подать в уже обученную M .

Пример: Почему без OOF — утечка

Если b_t обучена на всём train и мы берём её предсказание на train-объекте x_i напрямую — модель уже «видела» y_i при обучении, предсказание искусственно точнее, чем будет на новых данных. Мета-модель M , обучаясь на таких предсказаниях, переоценивает точность базовых моделей — классическая утечка (билет 23), симметрична target encoding без out-of-fold (билет 9).

Стэкинг vs блендинг

Блендинг: делим train на train-часть (обучаем b_t) и holdout (получаем предсказания b_t , обучаем M) — ОДНО разбиение, проще, быстрее, но b_t видят меньше данных и часть train «сгорает» только на holdout (цена как у post-pruning, билет 53). Стэкинг: полный K -fold — b_t в сумме используют весь train, точнее, но дороже по вычислениям (K раз переобучить каждую b_t).

Смеси экспертов (mixture of experts)

$$F(b_1, \dots, b_T, g_1, \dots, g_T) = \sum_t g_t(x) b_t(x).$$

$g_t(x)$ — функции компетентности (gates), в отличие от констант α_t (билет 54) ЗАВИСЯТ от объекта x . Область компетентности $\Omega_t = \{x : g_t(x) \text{ наибольшая}\}$. Прин-

цип «разделяй и властвуй»: простые эксперты + простые gate-функции восстанавливают сложные зависимости. Обозначение $g_t(x)b_t(x)$ — «компонента смеси»; нормировка $\sum_t g_t(x) = 1$.

Определение: Иерархические смеси экспертов (НМЕ)

Строим РЕКУРСИВНО: сначала смесь из двух алгоритмов, анализируем качество каждого на своей области компетентности. Если качество эксперта недостаточно — заменяем его смесью ДВУХ новых, дробящих его область $g(x)$ на $g(x)g_1(x)$ и $g(x)g_2(x)$ (с $g_1+g_2=1$, нормировка сохраняется). Процесс продолжается, пока все эксперты не станут удовлетворительны — получается БИНАРНОЕ ДЕРЕВО алгоритмов (структурно похоже на решающее дерево, билет 52, но в узлах — не пороговые предикаты, а обучаемые gate-функции и полноценные алгоритмы-эксперты в листьях).

Фишка на собеседе

Отличие от голосования (билет 54) — главная мысль билета: голосование «слепо» к положению объекта (одинаковые веса везде). Стэкинг/смеси экспертов УЧАТСЯ, КОГДА какой базовой модели доверять — вес/комбинация зависит от x , а не фиксирован заранее. НМЕ расширяет идею: если ОДНОЙ gate-функции недостаточно, чтобы разбить пространство на осмысленные области компетентности — дробим рекурсивно, как дерево, пока каждая область не станет «по силам» своему эксперту.

Конспект продолжается по мере прохождения билетов (Разделы 8–13).