

Классический ML

конспект по билетам для собеса

14 разделов, 99 билетов
источник: ml_tickets.md

обновляется по ходу подготовки;
каждый билет: определения, выводы, численные примеры, фишки на собесах

Раздел 1. Линейная регрессия

Билет 1. Формализация задачи машинного обучения

Любая задача обучения с учителем формализуется через тройку компонент.

Определение: Три компоненты задачи обучения

- **Объекты** $x \in X$ — сущности, про которые предсказываем (клиент, картинка, дом). Сами по себе абстрактны; модель работает не с объектом, а с его числовым описанием.
- **Признаки** (features) $f_j: X \rightarrow \mathbb{R}$ — функции, сопоставляющие объекту измеримую характеристику. Вектор признаков $f(x) = (f_1(x), \dots, f_m(x)) \in \mathbb{R}^m$.
- **Целевая переменная** $y \in Y$ — то, что предсказываем. Существует истинная неизвестная зависимость $y: X \rightarrow Y$, которую восстанавливаем по данным.

Типы признаков

Бинарный ($\{0, 1\}$), числовой ($\mathbb{R}$), категориальный (номинальный, неупорядоченное конечное множество), порядковый (ординальный, упорядоченное: школа < бакалавр < магистр).

Матрица «объект–признак»

Выборка из n объектов даёт матрицу X размера $[n \times (m + 1)]$:

$$X = \begin{pmatrix} 1 & x_{11} & \cdots & x_{1m} \\ 1 & x_{21} & \cdots & x_{2m} \\ \vdots & & & \vdots \\ 1 & x_{n1} & \cdots & x_{nm} \end{pmatrix}, \quad y = (y_1, \dots, y_n)^\top.$$

Строка i — объект x_i ; столбец j — значения признака f_j по всем объектам. **Первый столбец из единиц** $f_0 \equiv 1$ — фиктивный признак под свободный член w_0 (bias). Отсюда размер $(m+1)$, а не m : это уловка, чтобы модель $f = w_0 + w_1x_1 + \dots$ записывалась одним скалярным произведением $w^\top x$ без отдельного слагаемого.

Определение: Типы обучения (по наличию y)

- **С учителем** (supervised): y_i известны для всех обучающих объектов. Учимся по парам (x_i, y_i) .
- **Без учителя** (unsupervised): y нет вообще. Ищем внутреннюю структуру — кластеры, плотность, снижение размерности. Нет «правильного ответа».
- **Частичное** (semi-supervised): y известны у малой части объектов. Разметка дорогая, сырых данных много.

Типы задач с учителем (по виду Y)

Регрессия ($Y = \mathbb{R}$, непрерывное число: цена, спрос) → Раздел 1. **Классификация** (Y — конечное неупорядоченное множество меток: спам/не спам) → Раздел 5. **Ранжирование** (Y — порядок объектов: поисковая выдача) → Билет 91.

Ключевое отличие регрессии от классификации — **тип** Y : непрерывный vs дискретный неупорядоченный. Это определяет функцию потерь, метрики и семейство моделей.

Фишка на собеседе

Semi-supervised работает, только если структура $p(x)$ коррелирует с $p(y | x)$. Два предположения (см. билет 67): **cluster assumption** — объекты в одном плотном кластере имеют один y , граница классов проходит через разреженные области; **manifold assumption** — данные лежат на низкоразмерном многообразии, y гладко меняется вдоль него. Если y не связан со структурой $p(x)$ (например, y — чётность случайного ID), неразмеченные данные не помогут вообще — кластеры есть, но с y не связаны.

Билет 2. Линейная регрессия: модель и метод наименьших квадратов

Определение: Модель линейной регрессии

$$f(x, w) = w_0 + w_1 f_1(x) + \dots + w_m f_m(x) = w^\top x,$$

где $x = (1, f_1(x), \dots, f_m(x))^\top$, $w = (w_0, \dots, w_m)^\top$. Для всей выборки: $\hat{y} = Xw$.

Определение: Критерий МНК (метод наименьших квадратов)

$$w = \arg \min_w \|y - Xw\|_2^2 = \arg \min_w \sum_{i=1}^n (y_i - w^\top x_i)^2.$$

Квадрат ошибки выбран не случайно: (1) даёт гладкую всюду дифференцируемую функцию (в отличие от $|\cdot|$); (2) сильнее штрафует большие отклонения (ошибка в 2 раза больше → вклад в 4 раза больше); (3) даёт аналитическое решение (билет 3) и статистическую интерпретацию как MLE при гауссовом шуме (билет 10).

Линейность по весам, а не по x

Модель «линейна», потому что линейна по параметрам w , а НЕ по признакам x . Замена $x \rightarrow \varphi(x)$ (полиномы $\varphi = (x, x^2, x^3)$, RBF $\varphi = e^{-\|x-c\|^2}$) оставляет модель линейной по w (тот же МНК, та же машинерия), но как функция от исходного x она нелинейна. **Полиномиальная регрессия** — это линейная регрессия над признаками $\{x, x^2, \dots, x^k\}$.

Геометрическая интерпретация

y — вектор в $\mathbb{R}^n$. Столбцы X (каждый — один признак по всем объектам) натягивают линейное подпространство (линейную оболочку) в $\mathbb{R}^n$. Модель Xw для любого w — точка этого подпространства. МНК ищет **ближайшую точку подпространства к y** — ортогональную проекцию y на линейную оболочку столбцов

X . Отсюда условие ортогональности невязки (билет 3).

Билет 3. Нормальное уравнение и матрица Грама

Вывод нормального уравнения

$\text{RSS}(w) = \|y - Xw\|^2 = (y - Xw)^T(y - Xw) = y^T y - 2w^T X^T y + w^T X^T X w$. Это квадратичная функция с единственным минимумом; берём градиент и приравниваем к нулю:

$$\nabla \text{RSS}(w) = -2X^T y + 2X^T X w = 0 \implies \boxed{X^T X w = X^T y} \implies w = (X^T X)^{-1} X^T y.$$

Определение: Матрица Грама

$X^T X$ размера $[(m+1) \times (m+1)]$. Свойства:

- **Симметрична:** $(X^T X)^T = X^T X$.
- **Положительно полуопределена:** $\forall v: v^T (X^T X) v = (Xv)^T (Xv) = \|Xv\|^2 \geq 0$.
Отсюда все собственные числа ≥ 0 (пригодится в SVD, билет 6).

Матрица $(X^T X)^{-1} X^T$ — псевдообратная Мура–Пенроуза (при полном ранге столбцов).

Геометрический смысл нормального уравнения

$X^T(y - X\hat{w}) = 0$ покомпонентно означает: $x^{(j)T}(y - \hat{y}) = 0$ для каждого столбца $x^{(j)}$, т.е. скалярное произведение = 0 — **невязка ортогональна каждому столбцу X** . Раз ортогональна всем векторам базиса плоскости — ортогональна всей линейной оболочке. Это ровно определение ортогональной проекции: кратчайшее расстояние от точки y до плоскости — по перпендикуляру.

Проблема обратимости и сложность

$X^T X$ обратима $\Leftrightarrow$ столбцы X линейно независимы ($\text{rank } X = m+1$). Ломается: (1) при **мультиколлинеарности** ($\text{rank } X < m+1$); (2) при $n < m$ ($\text{rank } X \leq n < m+1$ по размерности). Обращение стоит $O(m^3)$ — дорого при большом числе признаков; отсюда мотивация градиентного спуска (билет 5).

Фишка на собеседе

Обратимость ломается по ДВУМ разным причинам: мультиколлинеарность (зависимость столбцов) и $n < m$ (объектов меньше признаков). Это не одно и то же: при $n \gg m$ с одним признаком-дубликатом матрица всё равно вырождена — увеличение n не лечит, т.к. проблема в ранге по **СТОЛБЦАМ**, а не по строкам.

Билет 4. Мультиколлинеарность и вырожденность матрицы Грама

Определение: Мультиколлинеарность

Линейная зависимость (точная) или сильная корреляция (приближённая) между столбцами-признаками X .

- **Точная** ($x_3 = 2x_1 + x_2$): $X^T X$ строго вырождена, $\det = 0$, обратной нет.
- **Приближённая** (рост в см и в дюймах, $\rho \approx 0.999$): $X^T X$ формально обратима, но плохо обусловлена (cond огромен).

Взрыв весов и его смысл

При точной зависимости проекция $\hat{y} = Xw$ НЕ меняется, но w неединственно: бесконечно много комбинаций дают ту же $\hat{y}$ (можно забрать вес у x_1 и отдать эквивалент x_3). При приближённой — решение единственно, но крайне чувствительно к шуму: малое возмущение y или X даёт огромный скачок w , у коррелирующих признаков появляются большие веса ПРОТИВОПОЛОЖНОГО знака (модель «взаимно компенсирует» два похожих признака). Это переобучение под шум конкретной выборки.

Замечание: $n < m$ — отдельная причина

Это НЕ мультиколлинеарность, а размерность: $\text{rank } X \leq \min(n, m+1)$. Если признаков больше объектов, ранг упирается в n , матрица Грама $(m+1) \times (m+1)$ гарантированно вырождена, даже если признаки не коррелируют (геномные данные: сотни образцов, десятки тысяч генов).

Способы борьбы

Отбор признаков; регуляризация (Ridge: τE на диагональ гарантирует обратимость, сдвигая собственные числа на $+\tau$); PCA (декорреляция); псевдообратная через SVD (отбрасывание малых σ).

Фишка на собесе

VIF (Variance Inflation Factor): регрессируем x_j на остальные признаки, $\text{VIF}_j = 1/(1 - R_j^2)$. $\text{VIF} > 5-10$ — признак сильно объясняется остальными, кандидат на удаление.

Важно: мультиколлинеарность НЕ портит качество предсказаний ($\hat{y}$ та же), она портит интерпретируемость и устойчивость весов.

Билет 5. Градиентный спуск для линейной регрессии

Определение: Градиентный спуск

$$w_{k+1} = w_k - h \nabla L(w_k), \quad \nabla L(w) = 2X^T(Xw - y).$$

h — learning rate. Итерация: считаем $\hat{y} = Xw_k$, невязку $(Xw_k - y)$, проецируем через X^T (вклад каждого признака в ошибку), шаг против градиента.

Learning rate h

h большой $\rightarrow$ перепрыгивание минимума, расходимость. h малый $\rightarrow$ медленная сходимость. Безопасная граница $h \leq 1/L$, где $L = \lambda_{\max}(X^T X)$ — максимальная кривизна чаши потерь (билеты 17–18).

Критерии останова

$\|\nabla L(w_k)\| < \varepsilon$ (почти на дне); $\|w_{k+1} - w_k\| < \varepsilon$ (шаги микроскопические); лимит итераций.

Пример: Пошаговый расчёт GD

Данные: $x = (1, 2, 3)$, $y = (3, 5, 6)$, модель $w_0 + w_1x$, старт $w = (0, 0)$, $h = 0.1$.

Шаг 1: $\hat{y} = (0, 0, 0)$; невязка $r = \hat{y} - y = (-3, -5, -6)$; $X^T r = (-3-5-6, -3-10-18) = (-14, -31)$; $\nabla L = 2(-14, -31) = (-28, -62)$; $w \leftarrow (0, 0) - 0.1(-28, -62) = (2.8, 6.2)$. На сходимости $\nabla L = 2X^T r = 0 \Leftrightarrow X^T r = 0$ — то же условие ортогональности, что нормальное уравнение достигает за один шаг, а GD — постепенно.

	Нормальное уравнение	Градиентный спуск
Точность	точное за один расчёт	приближённое, зависит от # итераций
Сложность	$O(m^3)$ на обращение	$O(nm)$ за итерацию, итераций много
Обратимость $X^T X$	требуется	не требуется
Большие n, m	плохо	хорошо (+ mini-batch, билет 19)

Билет 6. Сингулярное разложение (SVD): определение и свойства**Определение: SVD**

Любую матрицу X $[n \times m]$ можно разложить:

$$X = USV^T, \quad U^T U = I \ (n \times n), \quad V^T V = I \ (m \times m), \quad S = \text{diag}(\sigma_1 \geq \dots \geq \sigma_r \geq 0),$$

U — левые, V — правые сингулярные векторы, σ_j — сингулярные числа, $r = \text{rank } X$.

Замечание

SVD существует для ЛЮБОЙ матрицы (прямоугольной, вырожденной). Собственное разложение — только для квадратных диагонализуемых. В этом огромное практическое преимущество SVD.

Связь с матрицей Грама

$$X^T X = (USV^T)^T (USV^T) = VS^T U^T USV^T = V(S^T S)V^T = V \operatorname{diag}(\sigma_j^2)V^T.$$

Использовали $U^T U = I$. Это форма собственного разложения: σ_j^2 — собственные числа $X^T X$, столбцы V — её собственные векторы. Отсюда $\sigma_j^2 \geq 0$ (полуопределённость). Мостик к PCA (билет 31): там $(X^T X)\operatorname{Rot} = \lambda \operatorname{Rot}$ даёт $\operatorname{Rot} = V$, $\lambda = \sigma^2$.

Геометрия: поворот–растяжение–поворот

Умножение на $X = USV^T$ = три действия: (1) поворот V^T в пространстве признаков; (2) растяжение по осям на $\sigma_1, \dots, \sigma_r$; (3) поворот U в пространстве объектов. Любое линейное отображение = поворот → растяжение → поворот.

Усечённое SVD и обусловленность

$X_k = \sum_{j=1}^k \sigma_j u_j v_j^T$ — оставляем top- k , отбрасываем остальные (наилучшее приближение ранга k , теорема Эккарта–Янга, билет 30). Число обусловленности $\operatorname{cond}(X) = \sigma_{\max}/\sigma_{\min} = \sigma_1/\sigma_r$.

Фишка на собесе

При усечении (оставляем top- k): $\operatorname{cond}(X_k) = \sigma_1/\sigma_k \leq \sigma_1/\sigma_r = \operatorname{cond}(X)$ — обусловленность **УМЕНЬШАЕТСЯ** (устойчивость растёт). Не путай направление: чем **БОЛЬШЕ** cond , тем **ХУЖЕ** устойчивость.

Билет 7. Решение МНК через SVD и псевдообратная матрица**Вывод**

Подставим $X = USV^T$ в $w = (X^T X)^{-1} X^T y$. Знаем $X^T X = V(S^T S)V^T$, значит $(X^T X)^{-1} = V(S^T S)^{-1}V^T$ (т.к. V ортогональна). $X^T = VS^T U^T$. Тогда

$$w = V(S^T S)^{-1}V^T \cdot VS^T U^T y = V(S^T S)^{-1}S^T U^T y = \sum_{j=1}^r \frac{1}{\sigma_j} V_j (U_j^T y).$$

Определение: Псевдообратная Мура–Пенроуза

$X^+ = VS^+U^T$, S^+ — S с ненулевыми σ_j , заменёнными на $1/\sigma_j$. $w = X^+ y$. Всегда определена, даже при вырожденной $X^T X$. При полном ранге совпадает с $(X^T X)^{-1} X^T y$; при вырожденности даёт решение **минимальной нормы** $\|w\|$ среди всех w с одинаковой (минимальной) ошибкой.

Смысл формулы по шагам

$U_j^T y$ — проекция y на j -е направление (сколько y вдоль него). Делим на σ_j — обратное растяжение (компенсируем, что X растягивал в σ_j раз). Умножаем на V_j — переносим в пространство весов.

Пример: Почему малое σ опасно

Пусть $\sigma_1 = 10$, $\sigma_2 = 0.001$, шум в y даёт $U_j^\top y = 0.5$ на обоих направлениях. Вклад в w : $(1/10) \cdot 0.5 = 0.05$ (норм) против $(1/0.001) \cdot 0.5 = 500$ (взрыв!). Одинаковый шум усилен в 10000 раз из-за деления на почти-ноль. Усечение (отбрасывание σ_2) убирает этот взрыв.

Фишка на собеседе

$\text{cond}(X^\top X) = \text{cond}(X)^2$, т.к. собственные числа $X^\top X$ — это σ_j^2 . Значит явное обращение $X^\top X$ численно вдвое хуже, чем работа напрямую с X через SVD. При $\text{cond}(X) = 100$ имеем $\text{cond}(X^\top X) = 10000$. Поэтому `numpy.linalg.lstsq`, `sklearn` решают МНК через SVD/QR, а не через обращение матрицы Грама.

Билет 8. Метрики качества регрессии**Замечание: Функция потерь $\neq$ метрика**

Функция потерь оптимизируется при обучении (MSE в МНК — дифференцируема, даёт аналитику). Метрика измеряет результат постфактум и может быть другой (обучали через MSE, отчитываемся через MAE ради интерпретируемости).

Определение: Метрики

- $\text{MSE} = \frac{1}{n} \sum (y_i - \hat{y}_i)^2$ — квадратичный штраф, не робастна к выбросам, единицы y^2 .
- $\text{RMSE} = \sqrt{\text{MSE}}$ — единицы y (интерпретируема), всё ещё чувствительна к выбросам.
- $\text{MAE} = \frac{1}{n} \sum |y_i - \hat{y}_i|$ — линейный штраф, робастна, не диф. в 0. Всегда $\text{MAE} \leq \text{RMSE}$.
- $\text{MAPE} = \frac{1}{n} \sum \frac{|y_i - \hat{y}_i|}{|y_i|}$ — в %, масштабно-независима, но ломается при $y_i \approx 0$ и НЕ робастна (чувствительна через знаменатель).
- $R^2 = 1 - \text{SS}_{\text{res}}/\text{SS}_{\text{tot}}$, $\text{SS}_{\text{res}} = \sum (y_i - \hat{y}_i)^2$, $\text{SS}_{\text{tot}} = \sum (y_i - \bar{y})^2$ — доля объяснённой дисперсии. $R^2 = 1$ идеал, $R^2 = 0$ — константный прогноз $\bar{y}$, $R^2 < 0$ хуже среднего.

Диагностика по соотношению RMSE/MAE

$\text{RMSE} \gg \text{MAE}$ — есть отдельные большие выбросы (квадрат раздувает RMSE). $\text{RMSE} \approx \text{MAE}$ — ошибки распределены равномерно. Для прода, где критичны редкие катастрофические ошибки, смотрят RMSE.

Определение: Adjusted R^2

$$R_{\text{adj}}^2 = 1 - (1 - R^2) \frac{n - 1}{n - p - 1}, \quad p = \# \text{ признаков.}$$

Фишка на собеседе

Обычный R^2 НИКОГДА не убывает при добавлении признаков (даже случайного шума) — у модели больше степеней свободы, в худшем случае вес нового признака = 0. Adjusted R^2 штрафует за p : при $p \rightarrow n$ знаменатель $(n - p - 1) \rightarrow 0$, дробь $\rightarrow \infty$, $R^2_{\text{adj}} \rightarrow -\infty$ — жёстко сигнализирует о переобучении, даже если обычный $R^2 \approx 1$.

Билет 9. Предобработка признаков: масштабирование и кодирование**Определение: Масштабирование числовых признаков**

Стандартизация (z-score): $x' = (x - \mu)/\sigma$ — центр 0, дисперсия 1. **Min-max**: $x' = (x - \min)/(\max - \min)$ — диапазон $[0, 1]$, чувствительна к выбросам.

Зачем масштабировать

(1) **Ускоряет GD**: разные масштабы признаков $\rightarrow$ разброс собственных чисел $X^T X \rightarrow$ плохая обусловленность $\rightarrow$ вытянутая эллиптическая чаша $\rightarrow$ зигзаг (билет 5/11). Масштабирование делает чашу круглее. (2) **Методы на расстояниях** (kNN, k-means, SVM-RBF): без масштабирования признак с большим диапазоном доминирует в евклидовом расстоянии. (3) **Сопоставимость весов** и справедливость регуляризации (иначе штраф сильнее давит на признаки малого масштаба).

Определение: Кодирование категорий

One-hot: столбец на значение. **Ordinal**: номер по порядку (ложный порядок для неупорядоченных). **Target/mean encoding**: категория $\rightarrow$ среднее y по ней (риск утечки). **Hashing**: хэш в фикс. число столбцов (коллизии). **Embeddings**: обучаемый плотный вектор.

Dummy trap

Если оставить все K one-hot столбцов: их сумма = вектор единиц = f_0 (фиктивный признак) $\Rightarrow$ точная линейная зависимость $\Rightarrow$ мультиколлинеарность, $X^T X$ вырождена. Решение: убрать один столбец ($K-1$ достаточно).

Замечание: Деревья

Деревьям масштабирование НЕ нужно: пороговые сплиты $[f_j \geq d_j]$ инвариантны к монотонным преобразованиям. По той же причине ordinal/target encoding для деревьев ОК даже без «настоящего» порядка.

Фишка на собеседе

Target encoding без out-of-fold — утечка: для объекта его собственный y_i участвует в его же признаке. Правильно: считать среднее по остальным фолдам + сглаживание (взвешивание с глобальным средним для редких категорий). Формально сглаживание = байесовская априорная оценка (см. билет 45, сглаживание Лапласа).

са).

Билет 10. Вероятностный взгляд на линейную регрессию

Определение: Вероятностная модель

$y = w^T x + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, \sigma^2)$, т.е. $p(y | x, w) = \mathcal{N}(y | w^T x, \sigma^2)$: среднее линейно по x , дисперсия σ^2 постоянна (гомоскедастичность).

МНК = максимум правдоподобия при гауссовом шуме

$L(w) = \prod_i \frac{1}{\sqrt{2\pi\sigma^2}} e^{-(y_i - w^T x_i)^2 / 2\sigma^2}$. Логарифм:

$$\log L(w) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_i (y_i - w^T x_i)^2.$$

Первое слагаемое не зависит от w , значит $\arg \max_w \log L = \arg \min_w \sum (y_i - w^T x_i)^2$ — это МНК.

Регуляризация как байесовская MAP-оценка

$p(w | y, X) \propto p(y | X, w) p(w)$. Максимизация log-апостериора = минимизация $\frac{1}{2\sigma^2} \|Xw - y\|^2 + [-\log p(w)]$:

- **Ridge** = гауссово априорное $p(w) = \mathcal{N}(0, \sigma_0^2 I)$: $-\log p(w) \propto \tau \|w\|^2$, $\tau = \sigma^2 / \sigma_0^2$.
- **Lasso** = лапласово априорное $p(w) \propto e^{-\lambda \sum |w_j|}$: острый пик в 0 $\rightarrow$ зануление.
- **MAE** = лапласовский шум (тяжёлые хвосты $\rightarrow$ робастность к выбросам).

τ = отношение дисперсии шума к дисперсии априорного: чем увереннее, что веса малы (малое σ_0^2), тем сильнее регуляризация.

Предположения модели

Независимость наблюдений; гауссов шум; гомоскедастичность (σ^2 не зависит от x).

Фишка на собеседе

Гетероскедастичность (дисперсия шума растёт с x): МНК-оценка w **ОСТАЁТСЯ** несмещённой (несмещённость требует лишь $\mathbb{E}[\varepsilon | X] = 0$, не постоянства σ^2). Ломается **ЭФФЕКТИВНОСТЬ**: по теореме Гаусса–Маркова МНК = BLUE только при гомоскедастичности; иначе есть оценки с меньшей дисперсией (WLS). Главное — стандартные ошибки $\text{Var}(w) = \sigma^2 (X^T X)^{-1}$ становятся неверными $\rightarrow$ доверительные интервалы и p -value некорректны. Лечение: робастные ошибки (White/Huber).

Раздел 2. Регуляризация и теория оптимизации

Билет 11. Число обусловленности и устойчивость решения

Определение: Число обусловленности

$$\text{cond}(A) = \|A\| \cdot \|A^{-1}\| = \frac{\sigma_{\max}}{\sigma_{\min}}, \quad \frac{\|\Delta x\|}{\|x\|} \leq \text{cond}(A) \frac{\|\Delta b\|}{\|b\|}.$$

cond — коэффициент усиления относительной ошибки входа в решении $Ax = b$ (у нас $A = X^T X$).

Геометрия «почти параллельных прямых»

Решение системы = пересечение прямых. Под прямым углом — точка чёткая. Почти параллельны — малейшее дрожание уносит пересечение далеко. Малый угол между строками $A \Rightarrow$ почти линейная зависимость строк $\Rightarrow$ вырождается ПОСЛЕДНЕЕ независимое направление $\Rightarrow \sigma_{\min} \rightarrow 0$ (не $\sigma_{\max}$: она определяется длиной строк). Для матрицы из единичных строк под углом θ : $\text{cond} \approx 2/\theta$ при малых θ .

Фишка на собесе

Одна цепочка эквивалентностей: мультиколлинеарность $\Rightarrow \sigma_{\min} \rightarrow 0 \Rightarrow \text{cond}$ огромен $\Rightarrow$ коэффициент $1/\sigma_{\min}$ в решении взрывается $\Rightarrow$ веса неустойчивы к шуму. Высокий $\text{cond} \Leftrightarrow$ мультиколлинеарность $\Leftrightarrow$ взрыв весов — одно явление, три описания. Лечится Ridge (τE сдвигает $\lambda_{\min} \rightarrow \lambda_{\min} + \tau$) и масштабированием.

Билет 12. Переобучение и недообучение

Определение: Определения через симптомы

Переобучение (overfitting): подстройка под шум train; ошибка на train мала (иногда ≈ 0), на test велика; симптом — огромные неустойчивые веса (high variance).

Недообучение (underfitting): модель слишком проста; ошибка велика и на train, и на test (high bias).

Train / Validation / Test

Train — считаются веса. Validation — подбираются гиперпараметры (τ , K , глубина). Test — используется ОДИН раз в конце для честной оценки. Подбор гиперпараметров по test превращает его во вторую validation $\rightarrow$ оптимистичное смещение (утечка, билет 23).

Фишка на собесе

Early stopping = implicit регуляризация без штрафного члена в loss. Механизм: норма весов $\|w\|$ монотонно РАСТЁТ по мере итераций GD (старт с $w \approx 0$). Обрыв обучения не даёт $\|w\|$ дорасти до величины несжатой МНК-оценки — функционально имитирует ограничение на $\|w\|$. Для линейной регрессии: раннее остановленный GD $\approx$ Ridge с $\tau \propto 1/(\# \text{ итераций})$. Для бустинга: меньше деревьев = меньше эффективная сложность.

Билет 13. Ridge-регрессия (L2-регуляризация)**Определение: Ridge**

$$L = \frac{1}{n} \|Xw - y\|^2 + \tau \|w\|_2^2, \quad w = (X^\top X + \tau E)^{-1} X^\top y.$$

Механизм добавки τE

Собственные числа λ_i матрицы $X^\top X$ (все ≥ 0) переходят в $\lambda_i + \tau > 0$ у $(X^\top X + \tau E)$. Матрица становится строго положительно определённой $\Rightarrow$ обратима всегда. $\text{cond} = (\lambda_{\max} + \tau)/(\lambda_{\min} + \tau)$ падает — лечится и обусловленность. **Ridge НЕ убивает корреляцию признаков** (данные не трогает), только сдвигает собственные числа — не путать с декорреляцией через PCA.

Свойства

w_0 (bias) обычно не регуляризуют (это сдвиг, не сложность). Ridge сжимает веса к нулю, но НЕ зануляет точно (обращение матрицы не даёт точный ноль при $X^\top y \neq 0$). Влияние τ : рост $\rightarrow \text{bias} \uparrow, \text{variance} \downarrow$.

Фишка на собесе

Чтобы по весам Ridge понять важность признаков — сначала СТАНДАРТИЗИРОВАТЬ X (иначе малый вес может значить «признак большого масштаба», а не «неважный»). Ridge даёт непрерывное ранжирование, но не автоматический отбор — для отбора нужен Lasso.

Билет 14. Lasso-регрессия (L1-регуляризация)**Определение: Lasso**

$$L = \frac{1}{n} \|Xw - y\|^2 + \lambda \|w\|_1, \quad \|w\|_1 = \sum_j |w_j|.$$

Главное свойство: ЗАНУЛЯЕТ веса неинформативных признаков $\rightarrow$ автоматический отбор признаков (sparsity), интерпретируемость.

Нет аналитики

$|w_j|$ не дифференцируема в 0 (излом: слева -1 , справа $+1$). Нужен субградиент (в

точке излома — весь отрезок $[-1, 1]$). Решают координатным спуском.

Soft-thresholding — механизм зануления

$$w_j^* = S_\lambda(\rho_j) = \text{sign}(\rho_j) \cdot \max(|\rho_j| - \lambda, 0),$$

ρ_j — «сырой» МНК-вклад признака j . Из $|\rho_j|$ вычитаем λ ; если результат отрицателен — обрезаем в ноль. Сравни с Ridge: там УМНОЖЕНИЕ на коэффициент < 1 (ноль недостижим), здесь ВЫЧИТАНИЕ-с-обрезкой $\rightarrow$ точный ноль при $|\rho_j| \leq \lambda$.

Пример: Soft-threshold

$\rho_j = 0.3$, $\lambda = 0.5$: $\max(0.3 - 0.5, 0) = \max(-0.2, 0) = 0$. Сигнал слабее порога — зануляется.

Фишка на собесе

Нестабильность Lasso при коллинеарной группе — НЕ из-за порядка обхода координат (координатный спуск сходится к глобальному оптимуму независимо от порядка). Причина: при почти идентичных признаках задача имеет ВЫРОЖДЕННОЕ решение — «весь вес на А» и «весь вес на В» дают почти одинаковый loss. Геометрически (билет 15): эллипсы RSS касаются ромба вдоль целого ребра, и в какой угол упрётся решение — решает шум. У Ridge решение гладко и единственно $\Rightarrow$ вес делится между коррелирующими признаками стабильно.

Билет 15. Геометрия регуляризации: L1 vs L2

Эквивалентная условная задача

$\min[\text{RSS}(w) + \lambda R(w)]$ (штрафная форма) $\Leftrightarrow \min \text{RSS}(w)$ при $R(w) \leq \beta$ (условная форма). Больше λ — меньше β .

Геометрическая картина

Линии уровня RSS — эллипсы вокруг w_{OLS} . Область ограничения: L2 — круг ($\|w\|_2 \leq \beta$), L1 — ромб ($\|w\|_1 \leq \beta$, вершины на осях). Решение — точка касания наименьшего эллипса с границей области.

Почему L1 разрезает, а L2 нет

L1 (ромб): острые углы НА ОСЯХ (точки $(\beta, 0)$, $(0, \beta)$, где один вес = 0). Углы «ловят» эллипс широким диапазоном направлений подхода $\Rightarrow$ решение часто в углу $\Rightarrow$ зануление. **L2 (круг)**: гладкая граница, касание в точке, которая с вероятностью 1 не на оси $\Rightarrow$ оба веса ненулевые, просто сжаты. То же явление, что soft-threshold vs умножение (билет 14) — геометрически.

Фишка на собесе

Ridge — когда все признаки полезны и есть коллинеарность; Lasso — когда нужен отбор из многих мусорных. Геометрически при коллинеарных ОБОИХ полезных признаках: круг не имеет привилегированных направлений $\rightarrow$ делит вес пропор-

ционально, устойчиво к шуму; ромб навязывает дискретный выбор «один признак = 0, другой = всё», причём выбор решает шум. L1 насильно вводит асимметрию туда, где данные симметричны.

Билет 16. Elastic Net и функция потерь Хубера

Определение: Elastic Net

$$L = \frac{1}{n} \|Xw - y\|^2 + \lambda_1 \|w\|_1 + \lambda_2 \|w\|_2^2.$$

L1 даёт зануление, L2 — устойчивость при коллинеарности. **Grouping effect:** $|w_i - w_j| \leq \frac{\text{const}}{\lambda_2} \sqrt{2(1 - \rho_{ij})}$ — сильно коррелирующие признаки ($\rho_{ij} \rightarrow 1$) получают близкие веса, L2 «склеивает» группу, L1 зануляет её целиком. «Lasso берёт один случайный из группы, Elastic Net — всю группу».

Определение: Функция потерь Хубера

$$L_\delta(r) = \begin{cases} \frac{1}{2}r^2, & |r| \leq \delta \\ \delta(|r| - \delta/2), & |r| > \delta \end{cases}, \quad r = y - \hat{y}.$$

Малые остатки — как MSE (гладко, хороший градиент), большие — как MAE (выброс не доминирует). Непрерывна и дифференцируема в стыке $|r| = \delta$ (в отличие от чистой MAE).

Предельные случаи Хубера

$\delta \rightarrow 0$: почти вся область — линейная ветка $\Rightarrow$ пропорциональна MAE. $\delta \rightarrow \infty$: условие $|r| \leq \delta$ для всех $r \Rightarrow$ только $\frac{1}{2}r^2 = \text{MSE}$. Чувствительность к выбросам: $\text{MSE} \gg \text{Huber} > \text{MAE}$.

Фишка на собеседе

Почему не всегда Elastic Net / Huber: они добавляют гиперпараметры ($\lambda_1, \lambda_2 / \delta$) — дороже подбор. MSE остаётся дефолтом: MLE при гауссовом шуме (ЦПТ), гладкость, простота. Elastic Net нужен при известной структуре коррелирующих групп; Huber — при известных тяжёлых выбросах.

Билет 17. Выпуклость, L-гладкость и сильная выпуклость

Определение: Три свойства

- **Выпуклость:** $f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$. Следствие: любой локальный минимум глобален.
- **L-гладкость:** $\|\nabla f(x) - \nabla f(y)\| \leq L \|x - y\|$ (липшицев градиент). Для дважды диф.: $L = \lambda_{\max}(\nabla^2 f)$. Даёт безопасный шаг $h \leq 1/L$.
- **μ -сильная выпуклость:** $f(x) - \frac{\mu}{2} \|x\|^2$ выпукла. Функция крутая везде, нет плато, минимум единственный.

Замечание: L-гладкость $\neq$ выпуклость

L-гладкость — ТОЛЬКО про скорость изменения градиента, НЕ гарантирует глобальность минимума. Функция потерь нейросети L-гладкая, но невыпуклая (много локальных минимумов). Гарантию «локальный = глобальный» дают только выпуклость и сильная выпуклость.

МНК как пример

МНК: выпукл, L-гладок с $L = \lambda_{\max}(X^T X)$, но не обязательно сильно выпукл ($\mu = \lambda_{\min} \approx 0$ при плохой обусловленности). МНК+L2 (Ridge): μ -сильно выпукл с $\mu = \tau$ (гессиан $2(X^T X + \tau E)$, мин. собств. число $\geq 2\tau$).

Фишка на собеседе

Зачем регуляризация, если она «уводит от истинного w »? МНК-оценка несмещена лишь В СРЕДНЕМ по многим выборкам, но у одной реальной выборки при мультиколлинеарности разброс (variance) огромен. Ridge жертвует малым bias ради резкого падения variance: аналогия — стрелок В (систематически чуть смещён, но кучно) на одном выстреле ближе к цели, чем стрелок А (в среднем точен, но разброс огромный). Ошибка = $\text{Bias}^2 + \text{Variance}$; окупается, когда variance доминирует.

Билет 18. Скорость сходимости градиентного спуска**Теорема: Геометрическая сходимость**

Для L-гладких μ -сильно выпуклых функций GD (шаг $h \leq 1/L$) сходится геометрически:

$$\|w^{(k+1)} - w^*\|^2 \leq q^k \|w^{(0)} - w^*\|^2, \quad q < 1, \quad K \approx O\left(\frac{L}{\mu} \ln \frac{1}{\varepsilon}\right).$$

Разбор формулы

$\ln(1/\varepsilon)$ — логарифмическая зависимость от точности: улучшить в 10 раз $\rightarrow$ не в 10 раз больше итераций, а константная добавка. L/μ — число обусловленности задачи; для МНК $L/\mu = \lambda_{\max}/\lambda_{\min} = \text{cond}(X^T X)$. Большое L/μ — вытянутая чаша (билет 5) — зигзаг, много итераций. $L/\mu \approx 1$ — сфера, быстро.

Почему не за один шаг

GD использует только градиент (1-й порядок) — «знает лишь наклон под ногами». Метод Ньютона (2-й порядок, гессиан) для квадратичной функции доходит за один шаг.

Фишка на собеседе

Рост τ в Ridge: $L/\mu = (\lambda_{\max} + \tau)/\tau = \lambda_{\max}/\tau + 1$ строго УБЫВАЕТ ($d/d\tau < 0$). При $\tau \rightarrow \infty$: $L/\mu \rightarrow 1$ (идеальная обусловленность, быстрая сходимость). Но GD

сходится к ДРУГОЙ, более смещённой точке (не w_{OLS} , а сжатое Ridge-решение). Скорость оптимизации и качество решения — разные оси: регуляризация упрощает саму оптимизацию И меняет то, что ищем.

Билет 19. Стохастический градиентный спуск (SGD) и mini-batch

Определение: SGD

Градиент по одному объекту / мини-батчу вместо всей выборки: $\nabla L_i(w) = 2x_i(x_i^T w - y_i)$. Итерация дешёвая, но оценка градиента шумная.

Несмещённость и дисперсия

При случайном равновероятном выборе i : $\mathbb{E}[\nabla L_i(w)] = \nabla L(w)$ (несмещена), но большая дисперсия — конкретный ∇L_i может сильно отличаться от истинного направления. Траектория SGD дрожит вокруг направления полного GD.

Теорема: Условия Роббинса–Монро

Для сходимости несмотря на шум расписание шага α_k должно удовлетворять

$$\sum_k \alpha_k = \infty \quad (\text{дотянуться до минимума}), \quad \sum_k \alpha_k^2 < \infty \quad (\text{успокоиться, не дрожать вечно}).$$

Пример: $\alpha_k = 1/k$ (гармонический ряд расходится, $\sum 1/k^2$ сходится). Только $\alpha_k = \text{const}$: вечное дрожание. Только $\alpha_k = 1/k^2$: сумма шагов конечна, до далёкого минимума не дойти.

Размер батча

Малый: шумно, дешёво, шум помогает выпрыгивать и регуляризует. Большой: стабильно, дорого. Mini-batch (32–512): компромисс + параллелизм GPU.

Фишка на собесе

Два РАЗНЫХ эффекта одного шума, работают одновременно (не последовательно): (1) **выпрыгивание из плохой ямы** — масштаб навигации по невыпуклому ландшафту (в какой долине окажемся); (2) **implicit regularization** — шум не даёт дойти до острого/переобученного дна ВНУТРИ хорошей ямы, склоняет к широким flat minima (лучше обобщают). Первое — «в какой долине», второе — «насколько остро вниз в этой долине сядем».

Билет 20. Ускоренные и адаптивные методы: Momentum, Adam

Определение: Momentum («тяжёлый шарик»)

$$v = \gamma v + \eta g, \quad w = w - v, \quad g = \nabla f(w), \quad \gamma \approx 0.9.$$

v — накопленная скорость (память о прошлых шагах). Вдоль пологого направления (стабильный g) скорость накапливается — разгон; вдоль крутого (знакопеременный g) вклады $+\eta g$ и $-\eta g$ гасят друг друга — демпфирование зигзага. **NAG**: градиент в упреждающей точке $w - \gamma v$.

Определение: Адаптивные методы (свой шаг каждому весу)

AdaGrad: $S = S + g^2$, $w = w - \eta g / (\sqrt{S} + \varepsilon)$ — шаг падает у весов с историей больших g ; минус: S растёт вечно, шаг затухает до нуля. **RMSProp**: $S = \beta S + (1 - \beta)g^2$ — ЕМА с забыванием, шаг не затухает навсегда.

Определение: Adam = Momentum + RMSProp

$$m = \beta_1 m + (1 - \beta_1)g \quad (\text{направление}), \quad v = \beta_2 v + (1 - \beta_2)g^2 \quad (\text{масштаб}),$$

$$\hat{m} = \frac{m}{1 - \beta_1^t}, \quad \hat{v} = \frac{v}{1 - \beta_2^t}, \quad w = w - \eta \frac{\hat{m}}{\sqrt{\hat{v}} + \varepsilon}.$$

$\beta_1 \approx 0.9$, $\beta_2 \approx 0.999$, t — номер итерации.

Зачем коррекция смещения

$m_0 = 0 \Rightarrow m_1 = \beta_1 \cdot 0 + (1 - \beta_1)g_1 = (1 - \beta_1)g_1$. При $\beta_1 = 0.9$: $m_1 = 0.1g_1$ — всего 10% истинного градиента (сильно занижено). Коррекция: $\hat{m}_1 = m_1 / (1 - \beta_1^1) = (1 - \beta_1)g_1 / (1 - \beta_1) = g_1$ — точно восстанавливает. При росте t множитель $(1 - \beta_1^t) \rightarrow 1$, коррекция автоматически выключается.

AdamW

В обычном Adam L2-штраф $2\tau w$ тоже делится на $\sqrt{v} \rightarrow$ у весов с большим градиентом регуляризация ослабляется непредсказуемо. AdamW применяет weight decay $w \leftarrow w(1 - \lambda)$ ОТДЕЛЬНО от адаптивной нормировки — корректная L2.

Фишка на собесе

Adam/AdamW — дефолт (быстро, мало настройки, устойчив к разномасштабным градиентам — NLP, трансформеры). SGD+Momentum часто даёт ЛУЧШЕЕ финальное обобщение (CV) — Adam иногда садится в острый минимум, а шум SGD ведёт к flat minima. State-of-the-art в CV нередко всё ещё SGD+momentum.

Билет 21. Разложение на смещение, дисперсию и шум (bias-variance)

Теорема: Bias–variance разложение

Для $y = f(x) + \varepsilon$, $\mathbb{E}\varepsilon = 0$, $\text{Var } \varepsilon = \sigma^2$, $\bar{f}(x) = \mathbb{E}_D[\hat{f}(x)]$:

$$\text{EPE}(x) = \underbrace{(f(x) - \bar{f}(x))^2}_{\text{Bias}^2} + \underbrace{\mathbb{E}_D[(\bar{f}(x) - \hat{f}(x))^2]}_{\text{Variance}} + \underbrace{\sigma^2}_{\text{Noise}}.$$

Обнуление перекрёстных членов

Раскрываем $\mathbb{E}[(f - \bar{f}) + (\bar{f} - \hat{f}) + \varepsilon]^2$. Перекрёстные члены зануляются: $(f - \bar{f})$ — константа; $\mathbb{E}[\bar{f} - \hat{f}] = 0$ по определению $\bar{f} = \mathbb{E}_D[\hat{f}]$; $\mathbb{E}\varepsilon = 0$ и ε независим от $\hat{f}$. Остаётся сумма трёх квадратов.

Смысл слагаемых

Bias^2 — систематическая неспособность модели выразить f (недообучение). Variance — чувствительность к конкретной выборке (переобучение; связь с билетом 11 — неустойчивость = высокая variance). Noise — неустранимый предел (σ^2).

Как зависят от сложности и n

Рост сложности: $\text{Bias} \downarrow$, $\text{Variance} \uparrow$. Регуляризация ($\tau \uparrow$): $\text{Bias} \uparrow$, $\text{Variance} \downarrow$. **Bias** — вопрос К МОДЕЛИ (форма/сложность), НЕ лечится ростом n . **Variance** — вопрос К ВЫБОРКЕ, ПАДАЕТ с ростом n (больше данных $\rightarrow$ выборки представительнее $\rightarrow \hat{f}$ меньше прыгает, ЗБЧ).

Фишка на собеседе

Learning curves: train-ошибка РАСТЁТ с n (сложнее подогнать больше точек, $\rightarrow \text{Bias}^2 + \text{Noise}$ сверху), val-ошибка ПАДАЕТ ($\text{Variance} \downarrow$, $\rightarrow$ тот же предел снизу), кривые сходятся к $\text{Bias}^2 + \text{Noise}$. Разрыв между ними = мера Variance . Частая ошибка: сказать «variance растёт с n » — наоборот, падает. Bias лечат сложнее моделью/признаками, Variance — данными/регуляризацией/бэггингом. Бэггинг и рост n снижают Variance почти бесплатно (не трогая Bias).

Билет 22. Энтропия, кросс-энтропия и KL-дивергенция**Определение: Три величины**

$$H(p) = - \sum_i p_i \log p_i, \quad H(p, q) = - \sum_i p_i \log q_i, \quad KL(p||q) = \sum_i p_i \log \frac{p_i}{q_i} = H(p, q) - H(p).$$

Информационный смысл

$H(p)$ — среднее число бит для оптимального кодирования $x \sim p$ (выводится однозначно из аксиом непрерывности, монотонности, аддитивности — теорема Шеннона). Максимум у равномерного (полная неопределённость). Честная монета: $H = 1$ бит. $H(p, q)$ — реальное число бит, если кодируем оптимально под q (модель), а данные приходят из p (истина); $H(p, q) \geq H(p)$, равенство $\Leftrightarrow q = p$. KL — лишние биты из-за $q \neq p$; $KL \geq 0$,

$= 0 \Leftrightarrow p = q$, НЕсимметрична (не метрика).

Связи с ML

Максимизация правдоподобия $\Leftrightarrow$ минимизация $KL(p_{\text{data}} \| p_{\text{model}})$. Кросс-энтропия = log-loss логрег/softmax. Энтропия = критерий ветвления деревьев (information gain).

Пример: Асимметрия KL на 3 точках

Истина $p = (0.5, 0, 0.5)$ (моды A, C; B невозможна). Кандидаты: $q_{\text{cover}} = (0.4, 0.2, 0.4)$ (покрывает обе моды, чуть «мусорит» в B), $q_{\text{single}} = (0, 0, 1)$ (игнорирует моду A). $KL(p \| q_{\text{single}})$: точка A даёт $0.5 \log(0.5/0) = \infty$. $KL(p \| q_{\text{cover}}) \approx 0.22$ (в B: $0 \cdot \log(0/0.2) = 0$, штрафа нет). **Forward KL** наказывает игнор моды, не наказывает лишнюю массу. $KL(q_{\text{single}} \| p) \approx 0.69$ (в A: $0 \cdot \log = 0$, штрафа за игнор нет). $KL(q_{\text{cover}} \| p)$: в B $0.2 \log(0.2/0) = \infty$. **Reverse KL** наказывает массу там, где истины нет.

Фишка на собеседе

Ключ к асимметрии — ВЕС перед логарифмом. $KL(p \| q) = \sum p_i \log(p_i/q_i)$ взвешен по p : штраф ∞ если $q \rightarrow 0$ там где $p > 0$; но 0 если $p = 0$ (лишняя масса q бесплатна) $\Rightarrow$ **mean-seeking**, накрывает все моды. $KL(q \| p)$ взвешен по q : штраф ∞ если $p \rightarrow 0$ там где $q > 0$; но 0 если $q = 0$ (игнор моды p бесплатен) $\Rightarrow$ **mode-seeking**, садится на одну моду.

Билет 23. Кросс-валидация и утечки данных

Определение: K-fold CV

Разбить на k фолдов; k раз обучать на $k-1$, валидировать на оставшемся; усреднить. Каждый объект ровно раз в роли validation. Надёжнее одного split (усредняет по разбиениям).

Разновидности

Stratified: сохраняет доли классов (критично при дисбалансе). **LOO** ($k = n$): почти несмещённая оценка, но дорого (n обучений) и высокая дисперсия (каждый фолд = один объект). **Time series split**: только прошлое $\rightarrow$ будущее.

Nested CV

Внешний цикл — честная оценка, внутренний — подбор гиперпараметров. Иначе (подбор на тех же фолдах, где меряем качество) — оптимистичное смещение.

Определение: Виды утечки данных (data leakage)

1. **Target leakage** — признак есть следствие таргета («дата выписки» при предсказании выписки).
2. **Препроцессинг** — статистики (μ, σ , target encoding, импутация) считать ТОЛЬКО на train внутри фолда.

3. **Временная** — будущее $\rightarrow$ прошлое.

4. **Дубликаты** train/test.

Симптом — подозрительно высокое качество, не подтверждающееся в проде.

Фишка на собеседе

Тонкая утечка через препроцессинг в CV: если μ, σ посчитаны по ВСЕЙ выборке до разбиения, то стандартизируя train-часть фолда, мы используем μ, σ , в которые внесли вклад объекты validation ЭТОГО фолда. Train-признаки статистически коррелируют со значениями validation $\Rightarrow$ модель косвенно «подглядывает». Правильно: пересчитывать μ, σ заново для train-части КАЖДОГО фолда (не один раз глобально).

Раздел 3. Оптимизация второго порядка

Раздел для полноты; на собеседах по classic ML спрашивают редко (кроме интуиции GD vs Ньютон vs BFGS). Изложено компактно.

Билет 24. Метод Ньютона

$$x_{k+1} = x_k - [\nabla^2 L(x_k)]^{-1} \nabla L(x_k).$$

Квадратичная аппроксимация по Тейлору (учитывает кривизну $\nabla^2 L =$ гессиан). Для квадратичной функции (МНК) — точный минимум за 1 шаг: «видит форму горы целиком».

Билет 25. Проблемы Ньютона и Левенберг–Марквардт

Минусы Ньютона: гессиан дорог ($O(m^3)$ на обращение), может быть необратим/плохо обусловлен, вдали от минимума расходится. **Левенберг–Марквардт** (нелинейный МНК): $(J^T J + \lambda I)p = -J^T f$. λI как Ridge гарантирует обратимость: большой $\lambda \rightarrow$ GD (надёжно, медленно), малый $\rightarrow$ Гаусс–Ньютон (быстро). λ адаптируется по успеху шага.

Билет 26. Демпфированный Ньютон и линейный поиск

$x_{k+1} = x_k + \gamma_k H^{-1} \nabla f$ — размер шага γ_k и приближённый (замороженный) H . Line search: при известном направлении p_k задача сводится к одномерной $\gamma_k^* = \arg \min_{\gamma} f(x_k + \gamma p_k)$; неточный поиск — условия Армихо/Вульфа (достаточное убывание).

Билет 27. Квазиньютоновские методы: секущее уравнение

Строим приближение $B_k \approx [\nabla^2 f]^{-1}$ по истории градиентов (только 1-е производные). $s_k = x_{k+1} - x_k$, $y_k = \nabla f(x_{k+1}) - \nabla f(x_k)$: секущее уравнение $s_k = B_{k+1} y_k$ (недоопределено $\rightarrow$ доп. требования: симметричность, $\succ 0$, близость к B_k).

Билет 28. Метод SR-1 (Symmetric Rank-1)

Добавка ранга 1: $B_{k+1} = B_k + \frac{(s_k - B_k y_k)(s_k - B_k y_k)^T}{(s_k - B_k y_k)^T y_k}$. При $k \rightarrow \infty$ сходится к обратному гессиану. Минус: может терять положительную определённость $\rightarrow$ направление не убывания.

Билет 29. Алгоритм BFGS и L-BFGS

Добавка ранга 2. Гарантия: если $B_0 \succ 0$ и $y_k^T s_k > 0$ (обеспечивает line search) — все $B_k \succ 0$, направление всегда убывающее. **L-BFGS**: хранит не всю матрицу, а последние

$\sim 10\text{--}20$ пар (s_k, y_k) — для больших размерностей.

Фишка на собеседе

Иерархия $\text{GD} \rightarrow \text{BFGS} \rightarrow \text{Ньютон}$ = сколько информации о кривизне (0/1/2-й порядок): GD — только наклон (дёшево, много шагов), Ньютон — точная кривизна (дорого, мало шагов), BFGS — приближает кривизну по истории градиентов (средне). Почему не всегда BFGS: (1) $O(m^2)$ память — невозможно для нейросетей с млрд параметров; (2) плохо совместим с mini-batch — шумная история градиентов ломает оценку кривизны. Поэтому в deep learning — SGD/Adam, а BFGS/L-BFGS — в классическом ML (логрег, CRF) с full-batch.

Раздел 4. Снижение размерности

Билет 30. Теорема о наилучшем низкоранговом приближении (Эккарта–Янга)

Теорема: Эккерт–Янг

$$\min_{B: \text{rank}(B)=k} \|X - B\| \implies B = \sum_{j=1}^k u_j \sigma_j v_j^T, \quad \|X - B\| = \sigma_{k+1}.$$

Наилучшее приближение ранга k (по норме Фробениуса/спектральной) = усечённое SVD (top- k троек). Ошибка = первое отброшенное сингулярное число.

Зачем снижать размерность

Борьба с шумом (малые σ = шумовые направления); визуализация; скорость; борьба с мультиколлинеарностью; проклятие размерности (kNN деградирует).

Фишка на собеседе

Оптимальность ГЛОБАЛЬНАЯ, не поточечная. $\|X - B\|_F^2 = \sum_i \|x_i - b_i\|^2$ — минимизируется СУММА по объектам, не каждое слагаемое. Нетипичный объект (вариация в отброшенных направлениях с малым σ) реконструируется плохо, даже если B оптимальна в среднем. Пример: PCA на лицах ловит общие вариации (освещение, поворот), но редкая особенность (шрам) уходит в отброшенные компоненты. Связь с выбросами (билет 94): низкоранговое приближение «стирает» редкие сигналы.

Билет 31. PCA через максимизацию дисперсии

Определение: Задача PCA

Найти ортогональное направление Rot ($\|\text{Rot}\| = 1$) с максимальной дисперсией проекций: $\max_{\text{Rot}} \|X \cdot \text{Rot}\|^2$ при $\|\text{Rot}\| = 1$.

Вывод через Лагранжиан

$\mathcal{L} = \text{Rot}^T (X^T X) \text{Rot} - \lambda (\text{Rot}^T \text{Rot} - 1)$. Градиент:

$$\nabla \mathcal{L} = 2(X^T X) \text{Rot} - 2\lambda \text{Rot} = 0 \implies (X^T X) \text{Rot} = \lambda \text{Rot}.$$

Направления максимальной дисперсии = собственные векторы $X^T X$ = столбцы V (SVD), $\lambda = \sigma^2$ = дисперсии проекций.

Эквивалентность двух взглядов

«Максимум дисперсии вдоль Rot » $\Leftrightarrow$ «минимум ошибки реконструкции $\perp \text{Rot}$ » (билет

30). Полная энергия $\sum \|x_i\|^2 = \text{const}$ раскладывается по теореме Пифагора на объяснённую дисперсию + ошибку реконструкции; максимизация первого минимизирует второе.

Фишка на собеседе

РСА (unsupervised, максимум дисперсии) vs LDA (supervised, максимум разделённости классов). Направление максимальной дисперсии может быть ПЕРПЕНДИКУЛЯРНО направлению разделения классов: два длинных узких облака классов, вытянутых вдоль одной оси, но сдвинутых перпендикулярно. РСА выберет ось вытянутости (максимум дисперсии), спроецирует на неё — классы схлопнутся и перемешаются. LDA нашёл бы ось разделения. Мораль: РСА-препроцессинг перед классификацией может УНИЧТОЖИТЬ разделимость.

Билет 32. РСА: геометрия, выбор числа компонент, центрирование

Переход к главным компонентам

$X \cdot \text{Rot} = K$, где Rot — первые d правых сингулярных векторов V (билет 31). Компоненты K взаимно ОРТОГОНАЛЬНЫ (не коррелируют) — следствие ортонормированности столбцов V . Это и есть декорреляция данных.

Определение: Информативность компонент

$\sigma_1 \geq \dots \geq \sigma_r$. Сохранённая доля: $S_d/\tilde{S}$, $S_d = \sum_{i=1}^d \sigma_i$, $\tilde{S} = \sum_{j=1}^r \sigma_j$. На практике чаще через дисперсию (explained variance ratio): доля = $\sum_{i=1}^d \sigma_i^2 / \sum_j \sigma_j^2$ (т.к. $\lambda = \sigma^2$ — дисперсия проекции, билет 31).

Scree plot и метод локтя

График σ_i по номеру компоненты. **Метод локтя**: ищем точку излома, где резкое падение сменяется плато — субъективно, хорош при чёткой границе сигнал/шум, плохо работает при плавном убывании (нет однозначного излома). **Порог % дисперсии** (напр. 95%): объективен, воспроизводим для автоматизации, но выбор порога произволен и не различает «резкий сигнал+шум» от «плавно убывающей значимости».

КРИТИЧНО: центрирование

Без вычитания среднего РСА максимизирует $\|X \cdot \text{Rot}\|^2$ — это ВТОРОЙ МОМЕНТ, не дисперсия. Матрица, которую диагонализировать: $X^T X = n \cdot (\text{ковариация}) + n\mu\mu^T$. Если μ велико относительно разброса, слагаемое $n\mu\mu^T$ доминирует — первая «компонента» указывает в сторону среднего (куда смещено облако), а не в сторону реальной вариации данных вокруг центра. Обязательно центрировать (и обычно стандартизировать) перед РСА.

Фишка на собеседе

Различай масштаб как АРТЕФАКТ единиц измерения (рубли vs годы — стандартизируй ОБЯЗАТЕЛЬНО, иначе смена единиц меняет главную компоненту)

от масштаба как СОДЕРЖАТЕЛЬНОЙ информации (10 признаков, 9 — сигнал с большим разбросом, 1 — шум с крошечным естественным разбросом). Во втором случае стандартизация РАЗДУВАЕТ дисперсию шумового признака до 1 (как у всех), он формирует собственное отдельное направление с $\lambda \approx 1$, искусственно неотличимое в scree plot от сигнальных компонент — прячет реальную границу сигнал/шум, которая без стандартизации была видна по естественной разнице масштабов. Правило: одинаковые единицы + разный контентный разброс — стандартизация может ВРЕДИТЬ, пробуй оба варианта.

Билет 33. Степенной метод (Power Iteration) и deflation

Определение: Power Iteration

Найти главный собственный вектор $A = X^T X$ без полного SVD:

$$x^{(k+1)} = \frac{Ax^{(k)}}{\|Ax^{(k)}\|}.$$

Сходится к собственному вектору, соответствующему МАКСИМАЛЬНОМУ собственному числу λ_1 .

Почему сходится к v_1

Разложим $x^{(0)} = c_1 v_1 + c_2 v_2 + \dots + c_r v_r$ по базису собственных векторов ($\lambda_1 > \lambda_2 \geq \dots$). Тогда

$$A^k x^{(0)} = c_1 \lambda_1^k v_1 + c_2 \lambda_2^k v_2 + \dots = \lambda_1^k \left(c_1 v_1 + c_2 \left(\frac{\lambda_2}{\lambda_1} \right)^k v_2 + \dots \right).$$

Т.к. $(\lambda_2/\lambda_1)^k \rightarrow 0$ (строго убывает при $\lambda_1 > \lambda_2$), после нормировки все слагаемые кроме v_1 «вымирают». Скорость сходимости зависит от $|\lambda_2/\lambda_1|$ — чем меньше, тем быстрее (та же логика, что скорость GD, билет 18).

Замечание: Случай $\lambda_1 = \lambda_2$

Метод НЕ «плохо сходится» — он сходится к вектору внутри ДВУМЕРНОГО собственного подпространства $\text{span}(v_1, v_2)$ (оба слагаемых домножаются на один и тот же λ_1^k , не затухают друг относительно друга). Какая именно комбинация $c_1 v_1 + c_2 v_2$ получится — зависит от случайного старта $x^{(0)}$: результат не единственен, потому что единственного «главного» направления в этом случае просто не существует.

Определение: Deflation (исчерпывание)

Для следующей компоненты вычитаем вклад найденной:

$$A_{\text{new}} = A - \lambda_1 v_1 v_1^T.$$

Повторяем power iteration на A_{new} .

Почему максимум A_{new} = второе по величине λ исходной A

Действие на v_1 : $A_{\text{new}}v_1 = Av_1 - \lambda_1v_1(v_1^T v_1) = \lambda_1v_1 - \lambda_1v_1 = 0$ — направление v_1 обнулено.

Действие на v_2 (или любой v_j , $j \neq 1$): $A_{\text{new}}v_2 = Av_2 - \lambda_1v_1(v_1^T v_2) = \lambda_2v_2 - \lambda_1v_1 \cdot 0 = \lambda_2v_2$ (т.к. собственные векторы симметричной матрицы ОРТОГОНАЛЬНЫ, $v_1^T v_2 = 0$) — v_2 остаётся собственным вектором с ТЕМ ЖЕ λ_2 , не тронут. Итог: собственные числа $A_{\text{new}} = \{0, \lambda_2, \lambda_3, \dots\}$ — максимум теперь λ_2 . Ортогональность собственных векторов — ключевой факт, делающий deflation «хирургически точным».

Когда выгодно

Нужно лишь несколько top- k компонент из БОЛЬШОЙ матрицы — полное SVD $O(\min(n, m)^3)$ избыточно дорого; power iteration + deflation даёт k компонент за $O(k)$ проходов умножения матрицы на вектор.

Билет 34. Kernel PCA и ядра**Проблема и идея**

Линейный PCA ищет направления как линейные комбинации исходных признаков — не ловит нелинейную структуру (кольца, спирали). Идея: отобразить $x \rightarrow \varphi(x)$ в пространство БОЛЬШЕЙ размерности, где структура линеаризуется, и применить PCA там.

Пример: Кольца

Красные точки в центре, синие вокруг кольцом — в 2D неразделимо линией. При $z = x^2 + y^2$ («выдавить» центр вверх) красные (маленький радиус, маленький z) окажутся внизу, синие (большой радиус, большой z) — наверху; в 3D разделяются плоскостью. Заметь: $z = x^2 + y^2 = \langle (x, y), (x, y) \rangle$ — это КВАДРАТ РАДИУСА (в полярных: $r^2 \cos^2 \theta + r^2 \sin^2 \theta = r^2$), т.е. ровно та характеристика, которая и различает классы (радиус), угол θ — шумовая координата.

Определение: Kernel trick

Если алгоритм использует данные только через скалярные произведения $\langle \varphi(x_i), \varphi(x_j) \rangle$ (PCA можно переформулировать через матрицу Грама в новом пространстве), заменяем это на функцию ЯДРА:

$$K(x_i, x_j) = \langle \varphi(x_i), \varphi(x_j) \rangle,$$

вычисляемую НАПРЯМУЮ по исходным x , без явного построения $\varphi(x)$.

Популярные ядра

Полиномиальное: $K(x, y) = (c + \langle x, y \rangle)^d$ (взаимодействия признаков). RBF: $K(x, y) = \exp(-\gamma \|x - y\|^2)$ — соответствует БЕСКОНЕЧНОМЕРНОМУ пространству признаков (теорема Мерсера ниже).

Теорема: Условие Мерсера

K годится как ядро $\Leftrightarrow K$ симметрична и ПОЛОЖИТЕЛЬНО ПОЛУОПРЕДЕЛЕНА (матрица $K(x_i, x_j)$ для любого набора точек — PSD). Это ровно аксиома 3 скалярного произведения из функана ($\langle x, x \rangle \geq 0$): отрицательное собственное число матрицы Грама означало бы $\|\varphi(x)\|^2 < 0$ для какого-то вектора — невозможно для настоящего скалярного произведения. Без PSD не существует φ , для которого K было бы честным $\langle \varphi(x), \varphi(y) \rangle$ — вся геометрическая схема (существование RKHS, гарантии выпуклости SVM) ломается.

Теорема Мерсера (явная формула, связь с функаном)

Для непрерывного симметричного PSD-ядра существует ортонормированный базис собственных функций $\{\psi_i\}$ интегрального оператора $(T_K f)(x) = \int K(x, y) f(y) dy$ с собственными числами $\lambda_i \geq 0$:

$$K(x, y) = \sum_i \lambda_i \psi_i(x) \psi_i(y).$$

Это спектральное разложение ОПЕРАТОРА (аналог $X = USV^T$ для матрицы, билет 6, только в бесконечномерном функциональном пространстве). Отсюда явный feature map $\varphi(x) = (\sqrt{\lambda_1} \psi_1(x), \sqrt{\lambda_2} \psi_2(x), \dots)$ — для RBF сумма бесконечна, вот откуда «RBF = бесконечномерное пространство признаков».

RKHS (Reproducing Kernel Hilbert Space)

Гильбертово пространство H_K , канонически связанное с K , со свойством воспроизведения $f(x) = \langle f, K(x, \cdot) \rangle_{H_K}$. Строится (теорема Мура–Аронжайна) как пополнение линейных комбинаций $\sum_i c_i K(x_i, \cdot)$ со скалярным произведением $\langle K(x, \cdot), K(y, \cdot) \rangle := K(x, y)$ — та же операция пополнения по Коши, что при построении L^2 в функане. Биекция между PSD-ядрами и RKHS: выбор ядра K полностью определяет пространство H_K , в котором работает алгоритм.

Фишка на собесе

‘[Николенко]’ Ядро — функция похожести = скалярное произведение в (возможно неявном) пространстве признаков (RKHS). Та же идея «ядризации» применима к любому алгоритму, зависящему от данных только через $\langle x_i, x_j \rangle$ — в частности к SVM (билет 43): подставляем K вместо $\langle x_i, x_j \rangle$ и никогда не вычисляем $\varphi(x)$ явно, даже если оно бесконечномерно.

Билет 35. Нелинейное снижение размерности: t-SNE и UMAP**Отличие от PCA**

PCA/Kernel PCA сохраняют ГЛОБАЛЬНУЮ структуру (расстояния, дисперсию). t-SNE/UMAP сохраняют ЛОКАЛЬНУЮ структуру (кто с кем сосед), жертвуя точностью глобальных расстояний — инструменты для визуализации, не общий препроцессинг.

Определение: t-SNE: сходства в исходном пространстве

$$p_{j|i} = \frac{\exp(-\|x_i - x_j\|^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|x_i - x_k\|^2 / 2\sigma_i^2)}, \quad p_{ij} = \frac{p_{j|i} + p_{i|j}}{2n}.$$

σ_i СВОЯ для каждой точки, подбирается так, чтобы энтропия $H(P_i)$ (билет 22) соответствовала заданной **perplexity** $= 2^{H(P_i)}$ (эффективное число соседей, обычно 5–50).

Определение: t-SNE: сходства в 2D и loss

$$q_{ij} = \frac{(1 + \|y_i - y_j\|^2)^{-1}}{\sum_{k \neq l} (1 + \|y_k - y_l\|^2)^{-1}}, \quad \text{Loss} = KL(P \| Q) = \sum_{ij} p_{ij} \log \frac{p_{ij}}{q_{ij}}.$$

P фиксирован, Q зависит от оптимизируемых координат $\{y_i\}$ (GD, билет 5). t-распределение (1 степень свободы) вместо гауссианы — ключевое решение.

Crowding problem и почему именно тяжёлые хвосты

В высокой размерности вокруг точки помещается много «умеренно далёких» соседей; в 2D/3D физически не хватает места разместить их на том же ОТНОСИТЕЛЬНОМ расстоянии (объём растёт с размерностью). Простое увеличение σ у гауссианы НЕ решает проблему: хвост всё равно убывает ЭКСПОНЕНЦИАЛЬНО ($\exp(-x^2)$), вероятностная масса жмётся в узкий пик — скученность в центре. t-распределение убывает СТЕПЕННО ($\propto 1/d^2$ при больших d) — гораздо медленнее, даёт умеренно удалённым точкам достаточно «вероятностной массы», чтобы расселиться на больших дистанциях в 2D без катастрофического штрафа KL.

Почему forward $KL(P \| Q)$, а не reverse

P — истина (высокая размерность), Q — модель (2D-расположение). Forward KL сильно наказывает, если q_{ij} мало там, где p_{ij} велико (билет 22) — реальные соседи, оказавшиеся далеко в 2D, штрафуются жёстко. Это обеспечивает главное свойство t-SNE: сохранение локальных соседств любой ценой, даже за счёт искажения глобальной геометрии.

Определение: UMAP: fuzzy simplicial set

Граф k ближайших соседей, вес ребра

$$w_{ij} = \exp\left(-\frac{d(x_i, x_j) - \rho_i}{\sigma_i}\right),$$

ρ_i — расстояние до ближайшего соседа (гарантирует связность весом 1). Симметризация через fuzzy union: $W_{ij} = w_{ij} + w_{ji} - w_{ij}w_{ji}$. В 2D: $v_{ij} = (1 + a \|y_i - y_j\|^{2b})^{-1}$.

UMAP loss — cross-entropy, не KL

$$\text{Loss} = \sum_{ij} \left[W_{ij} \log \frac{W_{ij}}{v_{ij}} + (1 - W_{ij}) \log \frac{1 - W_{ij}}{1 - v_{ij}} \right].$$

Первое слагаемое — притяжение похожих точек (как t-SNE). Второе — ЯВНОЕ отталкивание непохожих, встроенное прямо в loss (у t-SNE отталкивание — лишь

побочный эффект нормировки знаменателя Q). Отсюда лучшая сохранность глобальной структуры у UMAP — кластеры не «слипаются» бесконтрольно.

Почему UMAP быстрее

Приближённый поиск соседей (не точный k -NN); negative sampling (случайная выборка «негативных» пар вместо всех $O(n^2)$, как в word2vec); более информативный градиент (явные притяжение+отталкивание).

Фишка на собесе

Отсутствие out-of-sample у t-SNE — НЕ просто «дорого пересчитывать, как в kNN». У PCA есть явная параметрическая формула ($x_{\text{new}} \cdot \text{Rot}$), применимая к любой новой точке независимо. У t-SNE координат $\{y_i\}$ — это результат СОВМЕСТНОЙ глобальной оптимизации по всем n точкам сразу (единая система, не независимое отображение точка-за-точкой). Новую точку нельзя вставить в формулу — либо переоптимизировать всё целиком (старые y могут сдвинуться, в отличие от PCA), либо грубо приблизить, зафиксировав старые y .

Автокодировщики и когда что выбирать

Автокодировщик (нейросеть с bottleneck) — обучаемое НЕЛИНЕЙНОЕ обобщение PCA (PCA = автокодировщик с линейными активациями). **PCA**: линейно/быстро/интерпретируемо, глобальная структура, общий препроцессинг. **t-SNE/UMAP**: визуализация кластеров при нелинейной структуре. **UMAP** предпочтительнее t-SNE на практике (быстрее, стабильнее, годится как препроцессинг перед кластеризацией, напр. HDBSCAN, билет 64).

Конспект продолжается по мере прохождения билетов (Разделы 5–13).